

# Matematici Asistate de Calculator

Prof. Dr. Călin-Adrian POPA

## Cursul 4

11 Martie 2026

## 3.4 Metode iterative

- eliminarea gaussiană este o secvență finită de operații care au ca rezultat o soluție
- din acest motiv, eliminarea gaussiană este numită o metodă **directă** de rezolvare a sistemelor de ecuații liniare
- metodele directe, teoretic, dau soluția exactă într-un număr finit de pași
- metodele directe sunt în contrast cu metodele de găsire a soluțiilor descrise în Capitolul 2, care au o formă iterativă
- așa-numitele metode **iterative** pot fi de asemenea aplicate pentru rezolvarea sistemelor de ecuații liniare
- asemenea iterației de punct fix, metodele încep de la o valoare inițială pe care o rafinează la fiecare pas, convergând către vectorul soluție

## 3.4.1 Metoda lui Jacobi

- metoda lui Jacobi este o formă a iterației de punct fix pentru un sistem de ecuații
- în IPF, primul pas este să rescriem ecuațiile, pentru a găsi necunoscuta
- primul pas în metoda lui Jacobi este să facem acest lucru în următoarea formă standardizată: rezolvăm a  $i$ -a ecuație pentru a găsi a  $i$ -a necunoscută
- apoi, se iterează ca în iterația de punct fix, începând de la valoarea inițială

### Exemplul 1

- aplicați metoda lui Jacobi sistemului  $3u + v = 5$ ,  $u + 2v = 5$
- începem prin a rezolva prima ecuație pentru a găsi  $u$  și a doua ecuație pentru a găsi  $v$
- vom folosi valoarea inițială  $(u_0, v_0) = (0, 0)$

## 3.4.1 Metoda lui Jacobi

- avem că

$$\begin{aligned}u &= \frac{5-v}{3} \\v &= \frac{5-u}{2}.\end{aligned}\tag{1}$$

- cele două ecuații sunt iterate:

$$\begin{aligned}\begin{bmatrix} u_0 \\ v_0 \end{bmatrix} &= \begin{bmatrix} 0 \\ 0 \end{bmatrix} \\ \begin{bmatrix} u_1 \\ v_1 \end{bmatrix} &= \begin{bmatrix} \frac{5-v_0}{3} \\ \frac{5-u_0}{2} \end{bmatrix} = \begin{bmatrix} \frac{5-0}{3} \\ \frac{5-0}{2} \end{bmatrix} = \begin{bmatrix} \frac{5}{3} \\ \frac{5}{2} \end{bmatrix} \\ \begin{bmatrix} u_2 \\ v_2 \end{bmatrix} &= \begin{bmatrix} \frac{5-v_1}{3} \\ \frac{5-u_1}{2} \end{bmatrix} = \begin{bmatrix} \frac{5-5/2}{3} \\ \frac{5-5/3}{2} \end{bmatrix} = \begin{bmatrix} \frac{5}{6} \\ \frac{5}{3} \end{bmatrix} \\ \begin{bmatrix} u_3 \\ v_3 \end{bmatrix} &= \begin{bmatrix} \frac{5-v_2}{3} \\ \frac{5-u_2}{2} \end{bmatrix} = \begin{bmatrix} \frac{5-5/3}{3} \\ \frac{5-5/6}{2} \end{bmatrix} = \begin{bmatrix} \frac{10}{9} \\ \frac{25}{12} \end{bmatrix}.\end{aligned}\tag{2}$$

- pașii următori din metoda lui Jacobi arată o convergență către soluție, care este  $[1, 2]^T$



## 3.4.1 Metoda lui Jacobi

- acum să presupunem că ecuațiile sunt date în ordine inversă

### Exemplul 2

- aplicați metoda lui Jacobi sistemului  $u + 2v = 5$ ,  $3u + v = 5$
- rezolvăm prima ecuație pentru a găsi prima variabilă  $u$  și a doua ecuație pentru a găsi pe  $v$
- începem cu

$$\begin{aligned}u &= 5 - 2v \\ v &= 5 - 3u.\end{aligned}\tag{3}$$

### 3.4.1 Metoda lui Jacobi

- cele două ecuații sunt iterate ca mai înainte, dar rezultatele sunt destul de diferite:

$$\begin{aligned}\begin{bmatrix} u_0 \\ v_0 \end{bmatrix} &= \begin{bmatrix} 0 \\ 0 \end{bmatrix} \\ \begin{bmatrix} u_1 \\ v_1 \end{bmatrix} &= \begin{bmatrix} 5 - 2v_0 \\ 5 - 3u_0 \end{bmatrix} = \begin{bmatrix} 5 \\ 5 \end{bmatrix} \\ \begin{bmatrix} u_2 \\ v_2 \end{bmatrix} &= \begin{bmatrix} 5 - 2v_1 \\ 5 - 3u_1 \end{bmatrix} = \begin{bmatrix} -5 \\ -10 \end{bmatrix} \\ \begin{bmatrix} u_3 \\ v_3 \end{bmatrix} &= \begin{bmatrix} 5 - 2v_2 \\ 5 - 3u_2 \end{bmatrix} = \begin{bmatrix} 25 \\ 20 \end{bmatrix}. \end{aligned} \tag{4}$$

- în acest caz, metoda lui Jacobi eșuează, deoarece iterația diverge
- deoarece metoda lui Jacobi nu reușește întotdeauna, este folositor să știm condițiile în care funcționează
- o condiție importantă este dată de următoarea definiție:

## 3.4.1 Metoda lui Jacobi

### Definiția 1

Matricea  $n \times n$   $A = (a_{ij})$  este **strict diagonal dominantă** dacă, pentru orice  $1 \leq i \leq n$ ,  $|a_{ii}| > \sum_{j \neq i} |a_{ij}|$ . Cu alte cuvinte, fiecare intrare de pe diagonala principală domină rândul pe care se află în sensul în care este mai mare în valoare absolută decât suma valorilor absolute ale celorlalte intrări de pe rândul respectiv.

### Teorema 1

Dacă matricea  $n \times n$   $A$  este strict diagonal dominantă, atunci (1)  $A$  este o matrice nesingulară, și (2) pentru orice vector  $b$  și orice valoare inițială, metoda lui Jacobi aplicată ecuației  $Ax = b$  converge către soluția unică.

- Teorema 1 spune că, dacă  $A$  este strict diagonal dominantă, atunci metoda lui Jacobi aplicată ecuației  $Ax = b$  converge către o soluție pentru orice valoare inițială

### 3.4.1 Metoda lui Jacobi

- în Exemplul 1, matricea coeficienților este la început

$$A = \begin{bmatrix} 3 & 1 \\ 1 & 2 \end{bmatrix},$$

care este strict diagonal dominantă, deoarece  $3 > 1$  și  $2 > 1$

- convergența este garantată în acest caz
- pe de altă parte, în Exemplul 2, metoda lui Jacobi este aplicată matricii

$$A = \begin{bmatrix} 1 & 2 \\ 3 & 1 \end{bmatrix},$$

care nu este diagonal dominantă, și nu există o astfel de garanție

- observăm că strict diagonal dominanța este doar o condiție suficientă
- metoda lui Jacobi s-ar putea totuși să convergă chiar și în absența acestei condiții

## 3.4.1 Metoda lui Jacobi

### Exemplul 3

- determinați dacă matricile

$$A = \begin{bmatrix} 3 & 1 & -1 \\ 2 & -5 & 2 \\ 1 & 6 & 8 \end{bmatrix} \text{ și } B = \begin{bmatrix} 3 & 2 & 6 \\ 1 & 8 & 1 \\ 9 & 2 & -2 \end{bmatrix}$$

sunt strict diagonal dominante

- matricea  $A$  este diagonal dominantă, deoarece  $|3| > |1| + |-1|$ ,  $|-5| > |2| + |2|$ , și  $|8| > |1| + |6|$
- $B$  nu este diagonal dominantă, deoarece, de exemplu  $|3| > |2| + |6|$  nu are loc
- totuși, dacă primul și al treilea rând ale lui  $B$  sunt interschimbate, atunci  $B$  este strict diagonal dominantă și avem garanția că metoda lui Jacobi va converge



## 3.4.1 Metoda lui Jacobi

- metoda lui Jacobi este o formă a iterației de punct fix
- fie  $D$  diagonală principală a lui  $A$ ,  $L$  triunghiul inferior al lui  $A$  (intrările de sub diagonală principală), și  $U$  triunghiul superior al lui  $A$  (intrările de deasupra diagonalei principale)
- atunci  $A = L + D + U$ , și ecuația care trebuie rezolvată este  $Lx + Dx + Ux = b$
- observăm că această utilizare a lui  $L$  și  $U$  diferă de cea din factorizarea LU, deoarece toate intrările diagonale pentru acești  $L$  și  $U$  sunt zero
- sistemul de ecuații  $Ax = b$  poate fi rearanjat sub forma unei iterații de punct fix:

$$\begin{aligned} Ax &= b \\ (D + L + U)x &= b \\ Dx &= b - (L + U)x \\ x &= D^{-1}(b - (L + U)x). \end{aligned} \tag{5}$$

- deoarece  $D$  este o matrice diagonală, inversa ei este matricea diagonală a inverselor intrărilor matricii  $A$
- metoda lui Jacobi este doar iterația de punct fix din (5):

## 3.4.1 Metoda lui Jacobi

### Algoritmul 1 (Metoda lui Jacobi)

$x_0$  = vectorul inițial

$$x_{k+1} = D^{-1}(b - (L + U)x_k) \text{ for } k = 0, 1, 2, \dots \quad (6)$$

- pentru Exemplul 1,

$$\begin{bmatrix} 3 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} u \\ v \end{bmatrix} = \begin{bmatrix} 5 \\ 5 \end{bmatrix},$$

iterația de punct fix (6) cu  $x_k = \begin{bmatrix} u_k \\ v_k \end{bmatrix}$  este

$$\begin{aligned} \begin{bmatrix} u_{k+1} \\ v_{k+1} \end{bmatrix} &= D^{-1}(b - (L + U)x_k) \\ &= \begin{bmatrix} 1/3 & 0 \\ 0 & 1/2 \end{bmatrix} \left( \begin{bmatrix} 5 \\ 5 \end{bmatrix} - \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} u_k \\ v_k \end{bmatrix} \right) \\ &= \begin{bmatrix} \frac{5-v_k}{3} \\ \frac{5-u_k}{2} \end{bmatrix}, \end{aligned}$$

care este aceeași cu versiunea originală



## 3.4.2 Metoda Gauss–Seidel și SRS

- în strânsă legătură cu metoda lui Jacobi este o metodă iterativă numită metoda **Gauss–Seidel**
- singura diferență între metodele Gauss–Seidel și Jacobi este aceea că în prima, cele mai recent actualizate valori ale necunoscutelor sunt utilizate la fiecare pas, chiar dacă actualizarea a avut loc în pasul curent
- întorcându-ne la Exemplul 1, vedem că metoda Gauss–Seidel arată după cum urmează:

$$\begin{aligned}\begin{bmatrix} u_0 \\ v_0 \end{bmatrix} &= \begin{bmatrix} 0 \\ 0 \end{bmatrix} \\ \begin{bmatrix} u_1 \\ v_1 \end{bmatrix} &= \begin{bmatrix} \frac{5-v_0}{3} \\ \frac{5-u_1}{2} \end{bmatrix} = \begin{bmatrix} \frac{5-0}{3} \\ \frac{5-5/3}{2} \end{bmatrix} = \begin{bmatrix} \frac{5}{3} \\ \frac{5}{3} \end{bmatrix} \\ \begin{bmatrix} u_2 \\ v_2 \end{bmatrix} &= \begin{bmatrix} \frac{5-v_1}{3} \\ \frac{5-u_2}{2} \end{bmatrix} = \begin{bmatrix} \frac{5-5/3}{3} \\ \frac{5-10/9}{2} \end{bmatrix} = \begin{bmatrix} \frac{10}{9} \\ \frac{35}{18} \end{bmatrix} \\ \begin{bmatrix} u_3 \\ v_3 \end{bmatrix} &= \begin{bmatrix} \frac{5-v_2}{3} \\ \frac{5-u_3}{2} \end{bmatrix} = \begin{bmatrix} \frac{5-35/18}{3} \\ \frac{5-55/54}{2} \end{bmatrix} = \begin{bmatrix} \frac{55}{54} \\ \frac{215}{108} \end{bmatrix}. \quad (7)\end{aligned}$$

### 3.4.2 Metoda Gauss–Seidel și SRS

- observăm diferența dintre metodele Gauss–Seidel și Jacobi: definiția lui  $v_1$  folosește  $u_1$ , nu  $u_0$
- vedem convergența către soluția  $[1, 2]^T$ , ca în metoda lui Jacobi, dar cu ceva mai mare precizie în același număr de pași
- metoda Gauss–Seidel adesea converge mai repede decât metoda lui Jacobi, dacă este convergentă
- metoda Gauss–Seidel, la fel ca metoda lui Jacobi, converge către soluție dacă matricea coeficienților este strict diagonal dominantă
- metoda Gauss–Seidel poate fi scrisă în formă matricială și identificată ca o iterație de punct fix în care izolăm ecuația  $(L + D + U)x = b$  în forma

$$(L + D)x_{k+1} = -Ux_k + b.$$

- observăm că folosirea intrărilor nou determinate ale lui  $x_{k+1}$  este realizată prin includerea triunghiului inferior al lui  $A$  în partea stângă a ecuației
- rearanjând această ecuație, obținem metoda Gauss–Seidel

## 3.4.2 Metoda Gauss–Seidel și SRS

### Algoritmul 2 (Metoda Gauss–Seidel)

$x_0$  = vectorul inițial

$$x_{k+1} = D^{-1}(b - Ux_k - Lx_{k+1}) \text{ for } k = 0, 1, 2, \dots$$

### Exemplul 4

- aplicați metoda Gauss–Seidel sistemului

$$\begin{bmatrix} 3 & 1 & -1 \\ 2 & 4 & 1 \\ -1 & 2 & 5 \end{bmatrix} \begin{bmatrix} u \\ v \\ w \end{bmatrix} = \begin{bmatrix} 4 \\ 1 \\ 1 \end{bmatrix}.$$

- iterația Gauss–Seidel este

$$\begin{aligned} u_{k+1} &= \frac{4 - v_k + w_k}{3} \\ v_{k+1} &= \frac{1 - 2u_{k+1} - w_k}{4} \\ w_{k+1} &= \frac{1 + u_{k+1} - 2v_{k+1}}{5}. \end{aligned}$$

### 3.4.2 Metoda Gauss–Seidel și SRS

- începând cu  $x_0 = [u_0, v_0, w_0]^T = [0, 0, 0]^T$ , calculăm

$$\begin{bmatrix} u_1 \\ v_1 \\ w_1 \end{bmatrix} = \begin{bmatrix} \frac{4-0+0}{3} \\ \frac{1-2(4/3)-0}{4} \\ \frac{1+(4/3)-2(-5/12)}{5} \end{bmatrix} = \begin{bmatrix} \frac{4}{3} \\ -\frac{5}{12} \\ \frac{19}{30} \end{bmatrix} \approx \begin{bmatrix} 1.3333 \\ -0.4167 \\ 0.6333 \end{bmatrix}$$

și

$$\begin{bmatrix} u_2 \\ v_2 \\ w_2 \end{bmatrix} = \begin{bmatrix} \frac{101}{60} \\ -\frac{3}{4} \\ \frac{251}{300} \end{bmatrix} \approx \begin{bmatrix} 1.6833 \\ -0.7500 \\ 0.8367 \end{bmatrix}.$$

- sistemul este strict diagonal dominant, și prin urmare iterația va converge către soluția  $[2, -1, 1]^T$

## 3.4.2 Metoda Gauss–Seidel și SRS

- metoda numită a **supra-relaxărilor succesive (SRS)** preia direcția dată de metoda Gauss–Seidel înspre soluție și „depășește măsura” în încercarea de a accelera convergența
- fie  $\omega$  un număr real, și definim fiecare componentă a noii aproximări  $x_{k+1}$  ca o medie ponderată de  $\omega$  ori formula Gauss–Seidel și de  $1 - \omega$  ori aproximarea curentă  $x_k$
- numărul  $\omega$  se numește **parametru de relaxare**, și când  $\omega > 1$  vorbim despre **supra-relaxare**

### Exemplul 5

- aplicați SRS cu  $\omega = 1.25$  sistemului din Exemplul 4
- metoda supra-relaxărilor succesive ne dă

$$\begin{aligned}u_{k+1} &= (1 - \omega)u_k + \omega \frac{4 - v_k + w_k}{3} \\v_{k+1} &= (1 - \omega)v_k + \omega \frac{1 - 2u_{k+1} - w_k}{4} \\w_{k+1} &= (1 - \omega)w_k + \omega \frac{1 + u_{k+1} - 2v_{k+1}}{5}.\end{aligned}$$



### 3.4.2 Metoda Gauss–Seidel și SRS

- începând cu  $[u_0, v_0, w_0]^T = [0, 0, 0]^T$ , calculăm

$$\begin{bmatrix} u_1 \\ v_1 \\ w_1 \end{bmatrix} \approx \begin{bmatrix} 1.6667 \\ -0.7292 \\ 1.0312 \end{bmatrix}$$

și

$$\begin{bmatrix} u_2 \\ v_2 \\ w_2 \end{bmatrix} \approx \begin{bmatrix} 1.9835 \\ -1.0672 \\ 1.0216 \end{bmatrix}.$$

- în acest exemplu, iterația SRS converge mai repede decât Jacobi și Gauss–Seidel către soluția  $[2, -1, 1]^T$
- la fel ca în cazul metodelor Jacobi și Gauss–Seidel, o deducere alternativă a SRS rezultă din tratarea sistemului ca o problemă de punct fix



### 3.4.2 Metoda Gauss–Seidel și SRS

- problema  $Ax = b$  poate fi scrisă  $(L + D + U)x = b$ , și, când înmulțim cu  $\omega$  și rearanjăm, avem

$$(\omega L + \omega D + \omega U)x = \omega b$$

$$(\omega L + D)x = \omega b - \omega Ux + (1 - \omega)Dx$$

$$x = (\omega L + D)^{-1}[(1 - \omega)Dx - \omega Ux] + \omega(D + \omega L)^{-1}b.$$

#### Algoritmul 3 (Metoda supra-relaxărilor succesive (SRS))

$$x_0 = \text{vectorul inițial}$$

$$x_{k+1} = (\omega L + D)^{-1}[(1 - \omega)Dx_k - \omega Ux_k] + \omega(D + \omega L)^{-1}b \text{ for } k = 0, 1, 2, \dots$$

- SRS cu  $\omega = 1$  este exact Gauss–Seidel
- parametrul  $\omega$  poate de asemenea să fie mai mic decât 1, dând astfel naștere unei metode numită metoda sub-relaxărilor succesive

## 3.5 Metode pentru matrici simetrice și pozitiv definite

- matricile simetrice au o poziție privilegiată în analiza sistemelor liniare datorită structurii lor speciale și pentru că au doar aproximativ jumătate din numărul de intrări independente al unor matrici generale
- aceasta ridică întrebarea dacă nu cumva factorizări ca factorizarea LU pot fi realizate la jumătate din complexitatea computațională, și folosind doar jumătate din locațiile de memorie
- pentru matricile simetrice și pozitiv definite, acest scop poate fi atins de către factorizarea Cholesky
- matricile simetrice și pozitiv definite permit de asemenea o abordare destul de diferită pentru rezolvarea ecuației  $Ax = b$ , care nu depinde de o factorizare matricială
- această nouă abordare, numită metoda gradientilor conjugați, este utilă mai ales pentru matrici mari
- în debutul secțiunii, definim conceptul de pozitiv definire pentru o matrice simetrică
- apoi, arătăm că orice matrice simetrică și pozitiv definită  $A$  poate fi factorizată sub forma  $A = R^T R$  pentru o matrice superior triangulară  $R$ , fapt ce reprezintă factorizarea Cholesky
- încheiem secțiunea cu algoritmul gradientilor conjugați

## 3.5.1 Matrici simetrice și pozitiv definite

### Definiția 2

Matricea  $n \times n$   $A$  este **simetrică** dacă  $A^T = A$ . Matricea  $A$  este **pozitiv definită** dacă  $x^T A x > 0$  pentru orice vector  $x \neq 0$ .

### Exemplul 6

- arătați că matricea  $A = \begin{bmatrix} 2 & 2 \\ 2 & 5 \end{bmatrix}$  este simetrică și pozitiv definită
- evident,  $A$  este simetrică
- pentru a arăta că este pozitiv definită, aplicăm definiția:

$$\begin{aligned} x^T A x &= \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 2 & 2 \\ 2 & 5 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \\ &= 2x_1^2 + 4x_1x_2 + 5x_2^2 \\ &= 2(x_1 + x_2)^2 + 3x_2^2. \end{aligned}$$

- această expresie este întotdeauna nenegativă, și nu poate fi zero decât dacă  $x_2 = 0$  și  $x_1 + x_2 = 0$ , care împreună implică  $x = 0$

## 3.5 Metode pentru matrici simetrice și pozitiv definite

### Exemplul 7

- arătați că matricea simetrică  $A = \begin{bmatrix} 2 & 4 \\ 4 & 5 \end{bmatrix}$  nu este pozitiv definită
- calculăm  $x^T Ax$  prin completarea pătratului:

$$\begin{aligned} x^T Ax &= \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 2 & 4 \\ 4 & 5 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \\ &= 2x_1^2 + 8x_1x_2 + 5x_2^2 \\ &= 2(x_1^2 + 4x_1x_2) + 5x_2^2 \\ &= 2(x_1 + 2x_2)^2 - 8x_2^2 + 5x_2^2 \\ &= 2(x_1 + 2x_2)^2 - 3x_2^2. \end{aligned}$$

- luând  $x_1 = -2$  și  $x_2 = 1$ , de exemplu, rezultatul va fi mai mic decât zero, ceea ce contrazice definiția unei matrici pozitiv definite
- observăm că o matrice simetrică și pozitiv definită trebuie să fie nesară, deoarece este imposibil ca un vector nenul  $x$  să satisfacă  $Ax = 0$



## 3.5 Metode pentru matrici simetrice și pozitiv definite

- există încă trei fapte importante care au loc pentru această clasă de matrici

### Teorema 2

Presupunem că  $A$  este o matrice simetrică  $n \times n$  cu intrări reale. Atunci valorile proprii ale lui  $A$  sunt numere reale, și mulțimea vectorilor proprii unitari ai lui  $A$  este o mulțime ortonormală  $\{w_1, \dots, w_n\}$  care formează o bază a lui  $\mathbb{R}^n$ .

### Faptul 1

Dacă matricea  $n \times n$   $A$  este simetrică, atunci  $A$  este pozitiv definită dacă și numai dacă toate valorile proprii ale sale sunt pozitive.

- Teorema 2 ne spune că mulțimea vectorilor proprii este ortonormală și formează o bază a lui  $\mathbb{R}^n$
- dacă  $A$  este pozitiv definită și  $Av = \lambda v$  pentru un vector nenul  $v$ , atunci  $0 < v^T Av = v^T (\lambda v) = \lambda \|v\|_2^2$ , deci  $\lambda > 0$

## 3.5 Metode pentru matrici simetrice și pozitiv definite

- pe de altă parte, dacă toate valorile proprii ale lui  $A$  sunt pozitive, atunci putem scrie orice vector nenul  $x = c_1 v_1 + \dots + c_n v_n$ , unde  $v_i$  sunt vectori unitari ortonormali și nu toți  $c_i$  sunt zero
- atunci  $x^T A x = (c_1 v_1 + \dots + c_n v_n)^T (\lambda_1 c_1 v_1 + \dots + \lambda_n c_n v_n) = \lambda_1 c_1^2 + \dots + \lambda_n c_n^2 > 0$ , deci  $A$  este pozitiv definită
- valorile proprii ale lui  $A$  din Exemplul 6 sunt 6 și 1
- valorile proprii ale lui  $A$  din Exemplul 7 sunt aproximativ 7.77 și  $-0.77$

### Faptul 2

Dacă  $A$  este o matrice  $n \times n$  simetrică și pozitiv definită și  $X$  este o matrice  $n \times m$  de rang maxim, cu  $n \geq m$ , atunci  $X^T A X$  este o matrice  $m \times m$  simetrică și pozitiv definită.

- matricea este simetrică deoarece  $(X^T A X)^T = X^T A X$
- considerăm un  $m$ -vector nenul  $v$
- observăm că  $v^T (X^T A X) v = (Xv)^T A (Xv) \geq 0$ , cu egalitate doar dacă  $Xv = 0$ , datorită faptului că  $A$  este pozitiv definită
- deoarece  $X$  are rang maxim, coloanele ei sunt liniar independente, astfel că  $Xv = 0$  implică  $v = 0$



## 3.5 Metode pentru matrici simetrice și pozitiv definite

### Definiția 3

O submatrice **principală** a matricii pătratică  $A$  este o submatrice pătratică ale cărei intrări diagonale sunt intrări diagonale ale lui  $A$ .

### Faptul 3

Orice submatrice principală a unei matrici simetrice și pozitiv definite este de asemenea simetrică și pozitiv definită.

- de exemplu, dacă

$$\begin{bmatrix} a_{11} & a_{12} & a_{13} & a_{14} \\ a_{21} & a_{22} & a_{23} & a_{24} \\ a_{31} & a_{32} & a_{33} & a_{34} \\ a_{41} & a_{42} & a_{43} & a_{44} \end{bmatrix}$$

este simetrică și pozitiv definită, atunci la fel este și

$$\begin{bmatrix} a_{22} & a_{23} \\ a_{32} & a_{33} \end{bmatrix}.$$

## 3.5.2 Factorizarea Cholesky

- pentru a demonstra ideea principală, începem cu cazul  $2 \times 2$
- toate problemele importante apar în acest caz, extensia la cazul general fiind imediată
- considerăm matricea simetrică și pozitiv definită

$$\begin{bmatrix} a & b \\ b & c \end{bmatrix}.$$

- din Faptul 3 despre matricile simetrice și pozitiv definite, știm că  $a > 0$
- în plus, știm că determinantul  $ac - b^2$  al lui  $A$  este pozitiv, deoarece determinantul este produsul valorilor proprii, care sunt toate pozitive, conform Faptului 1
- scriind  $A = R^T R$  unde  $R$  este o matrice superior triangulară, implică forma

$$\begin{bmatrix} a & b \\ b & c \end{bmatrix} = \begin{bmatrix} \sqrt{a} & 0 \\ u & v \end{bmatrix} \begin{bmatrix} \sqrt{a} & u \\ 0 & v \end{bmatrix} = \begin{bmatrix} a & u\sqrt{a} \\ u\sqrt{a} & u^2 + v^2 \end{bmatrix},$$

și vrem să verificăm dacă acest lucru este posibil

- comparând partea dreaptă și partea stângă, obținem identitățile  
 $u = b/\sqrt{a}$  și  $v^2 = c - u^2$
- observăm că  $v^2 = c - (b/\sqrt{a})^2 = c - b^2/a > 0$ , care rezultă din faptul că determinantul este pozitiv

## 3.5.2 Factorizarea Cholesky

- deducem că  $v$  poate fi definit ca un număr real, și deci factorizarea Cholesky

$$A = \begin{bmatrix} a & b \\ b & c \end{bmatrix} = \begin{bmatrix} \sqrt{a} & 0 \\ \frac{b}{\sqrt{a}} & \sqrt{c - b^2/a} \end{bmatrix} \begin{bmatrix} \sqrt{a} & \frac{b}{\sqrt{a}} \\ 0 & \sqrt{c - b^2/a} \end{bmatrix} = R^T R$$

există pentru matrici  $2 \times 2$  simetrice și pozitiv definite

- factorizarea Cholesky nu este unică; puteam la fel de bine să alegem  $v$  ca fiind rădăcina pătrată a lui  $c - b^2/a$  cu semnul minus
- următorul rezultat garantează că aceeași idee funcționează și pentru cazul  $n \times n$

### Teorema 3 (Teorema factorizării Cholesky)

Dacă  $A$  este o matrice  $n \times n$  simetrică și pozitiv definită, atunci există o matrice  $n \times n$  superior triangulară  $R$  astfel încât  $A = R^T R$ .

- construim pe  $R$  prin inducție după  $n$
- cazul  $n = 2$  a fost făcut mai sus

## 3.5.2 Factorizarea Cholesky

- considerăm că  $A$  este partiționată ca

$$A = \left[ \begin{array}{c|c} a & b^T \\ \hline b & C \end{array} \right]$$

unde  $b$  este un  $(n - 1)$ -vector și  $C$  este o submatrice  $(n - 1) \times (n - 1)$

- vom folosi înmulțirea pe blocuri pentru a simplifica argumentul
- luăm  $u = b/\sqrt{a}$ , ca în cazul  $2 \times 2$
- luând  $A_1 = C - uu^T$  și definind matricea inversabilă

$$S = \left[ \begin{array}{c|c} \sqrt{a} & u^T \\ \hline 0 & \\ \vdots & I \\ 0 & \end{array} \right]$$

## 3.5.2 Factorizarea Cholesky

- avem că

$$\begin{aligned} S^T \left[ \begin{array}{c|ccc} 1 & 0 & \dots & 0 \\ \hline 0 & & & \\ \vdots & & A_1 & \\ 0 & & & \end{array} \right] S &= \left[ \begin{array}{c|ccc} \sqrt{a} & 0 & \dots & 0 \\ \hline u & & I & \\ & & & A_1 \\ 0 & & & \end{array} \right] \left[ \begin{array}{c|ccc} 1 & 0 & \dots & 0 \\ \hline 0 & & & \\ \vdots & & & \\ 0 & & & \end{array} \right] \left[ \begin{array}{c|c} \sqrt{a} & u^T \\ \hline 0 & \\ \vdots & I \\ 0 & \end{array} \right] \\ &= \left[ \begin{array}{c|c} a & b^T \\ \hline b & uu^T + A_1 \end{array} \right] = A. \end{aligned}$$

- observăm că  $A_1$  este simetrică și pozitiv definită
- aceasta rezultă din faptul că

$$\left[ \begin{array}{c|ccc} 1 & 0 & \dots & 0 \\ \hline 0 & & & \\ \vdots & & A_1 & \\ 0 & & & \end{array} \right] = (S^T)^{-1} A S^{-1}$$

este simetrică și pozitiv definită din Faptul 2, și la fel este și submatricea principală  $(n-1) \times (n-1)$   $A_1$  din Faptul 3

- din ipoteza de inducție,  $A_1 = V^T V$ , unde  $V$  este superior triangulară



## 3.5.2 Factorizarea Cholesky

- în final, definim matricea superior triangulară

$$R = \left[ \begin{array}{c|c} \sqrt{a} & u^T \\ \hline 0 & \\ \vdots & V \\ 0 & \end{array} \right]$$

și verificăm că

$$R^T R = \left[ \begin{array}{c|ccc} \sqrt{a} & 0 & \dots & 0 \\ \hline u & & V^T & \end{array} \right] \left[ \begin{array}{c|c} \sqrt{a} & u^T \\ \hline 0 & \\ \vdots & V \\ 0 & \end{array} \right] = \left[ \begin{array}{c|c} a & b^T \\ \hline b & uu^T + V^T V \end{array} \right] = A,$$

încheind astfel demonstrația

- construcția demonstrației se poate face explicit, în ceea ce a devenit algoritmul standard pentru factorizarea Cholesky
- matricea  $R$  este construită din exterior înspre interior
- mai întâi, găsim  $r_{11} = \sqrt{a_{11}}$  și luăm restul primului rând al lui  $R$  ca fiind  $u^T = b^T / r_{11}$

## 3.5.2 Factorizarea Cholesky

- atunci  $uu^T$  este scăzut din submatricea principală  $(n-1) \times (n-1)$  inferioară, și aceiași pași sunt repetați pentru a umple al doilea rând al lui  $R$
- acești pași sunt continuați până când toate rândurile lui  $R$  sunt determinate
- potrivit teoremei, noua submatrice principală este pozitiv definită la fiecare pas al construcției, deci, din Faptul 3, rezultă că intrarea din colțul din stânga sus este pozitivă, și extragerea rădăcinii pătrate este validă
- această abordare poate fi pusă direct în următorul algoritm
- folosim notația cu „două puncte” pentru a specifica submatricile respective

## 3.5.2 Factorizarea Cholesky

### Algoritmul 4 (Factorizarea Cholesky)

```
for  $k = 1, 2, \dots, n$   
  if  $A_{kk} < 0$ , stop, end  
   $R_{kk} = \sqrt{A_{kk}}$   
   $u^T = \frac{1}{R_{kk}} A_{k,k+1:n}$   
   $R_{k,k+1:n} = u^T$   
   $A_{k+1:n,k+1:n} = A_{k+1:n,k+1:n} - uu^T$   
end
```

- matricea  $R$  rezultată este superior triangulară și satisface  $A = R^T R$

### Exemplul 8

- găsiți factorizarea Cholesky a lui  $\begin{bmatrix} 4 & -2 & 2 \\ -2 & 2 & -4 \\ 2 & -4 & 11 \end{bmatrix}$

## 3.5.2 Factorizarea Cholesky

- primul rând al lui  $R$  este  $R_{11} = \sqrt{a_{11}} = 2$ , urmat de  $R_{1,2:3} = [-2, 2]/R_{11} = [-1, 1]$ :

$$R = \left[ \begin{array}{c|cc} 2 & -1 & 1 \\ \hline & & \end{array} \right].$$

- scăzând produsul  $uu^T = \begin{bmatrix} -1 \\ 1 \end{bmatrix} \begin{bmatrix} -1 & 1 \end{bmatrix}$  din submatricea principală  $2 \times 2$  inferioară  $A_{2:3,2:3}$  a lui  $A$ , obținem

$$\left[ \begin{array}{c|cc} & 2 & -4 \\ \hline -4 & 11 \end{array} \right] - \left[ \begin{array}{c|cc} & 1 & -1 \\ \hline -1 & 1 \end{array} \right] = \left[ \begin{array}{c|cc} & 1 & -3 \\ \hline -3 & 10 \end{array} \right].$$

- acum, repetăm aceiași pași pentru submatricea  $2 \times 2$  și găsim  $R_{22} = 1$  și  $R_{23} = -3/1 = -3$ :

$$R = \left[ \begin{array}{c|cc} 2 & -1 & 1 \\ \hline & 1 & -3 \\ \hline & & \end{array} \right].$$

## 3.5.2 Factorizarea Cholesky

- submatricea principală  $1 \times 1$  inferioară a lui  $A$  este  $10 - (-3)(-3) = 1$ , deci  $R_{33} = \sqrt{1}$
- factorul Cholesky al lui  $A$  este

$$R = \begin{bmatrix} 2 & -1 & 1 \\ 0 & 1 & -3 \\ 0 & 0 & 1 \end{bmatrix}.$$

- rezolvarea sistemului  $Ax = b$  pentru matricea simetrică și pozitiv definită  $A$  urmează aceeași idee ca și factorizarea LU
- acum că  $A = R^T R$  este un produs a două matrici triangulare, trebuie să rezolvăm sistemul inferior triangular  $R^T c = b$  și sistemul superior triangular  $Rx = c$  pentru a determina soluția  $x$



### 3.5.3 Metoda gradientilor conjugați

- metoda gradientilor conjugați se bazează pe generalizarea ideii cunoscute de produs scalar
- produsul scalar euclidian  $(v, w) = v^T w$  este simetric și liniar în intrările  $v$  și  $w$ , deoarece  $(v, w) = (w, v)$  și  $(\alpha v + \beta w, u) = \alpha(v, u) + \beta(w, u)$ , pentru orice scalari  $\alpha$  și  $\beta$
- produsul scalar euclidian este de asemenea și pozitiv definit, prin aceea că  $(v, v) > 0$  dacă  $v \neq 0$

#### Definiția 4

Fie  $A$  o matrice  $n \times n$  simetrică și pozitiv definită. Pentru doi  $n$ -vectori  $v$  și  $w$ , definim  **$A$ -produsul scalar** prin  $(v, w)_A = v^T A w$ . Vectorii  $v$  și  $w$  sunt  $A$ -conjugați dacă  $(v, w)_A = 0$ .

- observăm că noul produs scalar moștenește proprietățile de simetrie, liniaritate și pozitiv definire de la matricea  $A$
- deoarece  $A$  este simetrică, la fel este și  $A$ -produsul scalar:  
$$(v, w)_A = v^T A w = (v^T A w)^T = w^T A v = (w, v)_A$$

### 3.5.3 Metoda gradientilor conjugați

- A-produsul scalar este de asemenea liniar, iar pozitiv definirea rezultă din faptul că dacă  $A$  este pozitiv definită, atunci

$$(v, v)_A = v^T A v > 0, \text{ dacă } v \neq 0$$

- în sens strict, metoda gradientilor conjugați este o metodă directă, și ajunge la soluția  $x$  a sistemului simetric și pozitiv definit  $Ax = b$  cu următoarea buclă finită:

#### Algoritmul 5 (Metoda gradientilor conjugați)

```
 $x_0 = \text{vectorul inițial}$   
 $d_0 = r_0 = b - Ax_0$   
for  $k = 0, 1, 2, \dots, n - 1$   
  if  $r_k = 0$ , stop, end  
   $\alpha_k = \frac{r_k^T r_k}{d_k^T A d_k}$   
   $x_{k+1} = x_k + \alpha_k d_k$   
   $r_{k+1} = r_k - \alpha_k A d_k$   
   $\beta_k = \frac{r_{k+1}^T r_{k+1}}{r_k^T r_k}$   
   $d_{k+1} = r_{k+1} + \beta_k d_k$   
end
```

### 3.5.3 Metoda gradientilor conjugați

- dăm acum o descriere informală a acestei iterații, care va fi urmată de demonstrația faptelor necesare în Teorema 4
- iterația gradientilor conjugați actualizează trei vectori diferiți la fiecare pas
- vectorul  $x_k$  este aproximarea soluției la pasul  $k$
- vectorul  $r_k$  reprezintă rezidualul aproximării  $x_k$
- acest lucru este clar pentru  $r_0$  din definiție, și, în timpul iterației, observăm că

$$\begin{aligned}Ax_{k+1} + r_{k+1} &= A(x_k + \alpha_k d_k) + r_k - \alpha_k A d_k \\ &= Ax_k + r_k,\end{aligned}$$

și astfel prin inducție  $r_k = b - Ax_k$ , pentru orice  $k$

- în final, vectorul  $d_k$  reprezintă noua direcție de căutare folosită pentru a actualiza aproximarea  $x_k$  în versiunea îmbunătățită  $x_{k+1}$
- metoda reușește deoarece fiecare rezidual este definit astfel încât să fie ortogonal pe toți rezidualii anteriori
- dacă acest lucru poate fi făcut, metoda va rămâne fără direcții ortogonale în care să caute și va trebui să ajungă la un rezidual egal cu zero și la o soluție corectă în cel mult  $n$  pași

### 3.5.3 Metoda gradientilor conjugați

- cheia pentru a realiza ortogonalitatea între reziduali se dovedește a fi alegerea direcțiilor de căutare  $d_k$  ca fiind conjugate două câte două
- conceptul de conjugare generalizează conceptul de ortogonalitate, dând și numele algoritmului
- acum vom explica alegerile lui  $\alpha_k$  și  $\beta_k$
- direcțiile  $d_k$  sunt alese din subspațiul liniar generat de rezidualii anteriori, după cum se poate vedea prin inducție din ultima linie a buclei algoritmului
- pentru a asigura faptul că următorul rezidual este ortogonal pe toți rezidualii anteriori,  $\alpha_k$  este ales tocmai pentru ca noul rezidual  $r_{k+1}$  să fie ortogonal pe direcția  $d_k$ :

$$\begin{aligned}x_{k+1} &= x_k + \alpha_k d_k \\b - Ax_{k+1} &= b - Ax_k - \alpha_k Ad_k \\r_{k+1} &= r_k - \alpha_k Ad_k \\0 = d_k^T r_{k+1} &= d_k^T r_k - \alpha_k d_k^T Ad_k \\\alpha_k &= \frac{d_k^T r_k}{d_k^T Ad_k}.\end{aligned}$$



### 3.5.3 Metoda gradientilor conjugați

- aceasta nu este exact forma lui  $\alpha_k$  din algoritm, dar observăm că, deoarece  $d_{k-1}$  este ortogonal pe  $r_k$ , avem

$$\begin{aligned}d_k - r_k &= \beta_{k-1} d_{k-1} \\ r_k^T d_k - r_k^T r_k &= 0,\end{aligned}$$

ceea ce justifică rescrierea  $r_k^T d_k = r_k^T r_k$

- în al doilea rând, coeficientul  $\beta_k$  este ales pentru a asigura A-conjugarea direcțiilor  $d_k$  două câte două:

$$\begin{aligned}d_{k+1} &= r_{k+1} + \beta_k d_k \\ 0 = d_k^T A d_{k+1} &= d_k^T A r_{k+1} + \beta_k d_k^T A d_k \\ \beta_k &= -\frac{d_k^T A r_{k+1}}{d_k^T A d_k}.\end{aligned}$$

- expresia pentru  $\beta_k$  poate fi rescrisă în forma mai simplă folosită în algoritm, după cum se arată în ecuația (9) de mai jos
- Teorema 4 de mai jos verifică faptul că toți rezidualii  $r_k$  produși de către iterația gradientilor conjugați sunt ortogonali unii pe alții



### 3.5.3 Metoda gradientilor conjugați

- deoarece ei sunt vectori  $n$ -dimensionali, cel mult  $n$  din rezidualii  $r_k$  pot fi ortogonali doi câte doi, deci ori  $r_n$  ori un  $r_k$  anterior trebuie să fie zero, rezolvând astfel  $Ax = b$
- prin urmare, după cel mult  $n$  pași, metoda gradientilor conjugați ajunge la o soluție
- în teorie, metoda este una directă, și nu una iterativă
- înainte de a ajunge la teorema care garantează succesul metodei gradientilor conjugați, este instructiv să urmărim un exemplu în aritmetică exactă

#### Exemplul 9

- rezolvați  $\begin{bmatrix} 2 & 2 \\ 2 & 5 \end{bmatrix} \begin{bmatrix} u \\ v \end{bmatrix} = \begin{bmatrix} 6 \\ 3 \end{bmatrix}$  folosind metoda gradientilor conjugați

### 3.5.3 Metoda gradientilor conjugați

- urmând algoritmul de mai sus, avem că

$$x_0 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, r_0 = d_0 = \begin{bmatrix} 6 \\ 3 \end{bmatrix}$$

$$\alpha_0 = \frac{\begin{bmatrix} 6 \\ 3 \end{bmatrix}^T \begin{bmatrix} 6 \\ 3 \end{bmatrix}}{\begin{bmatrix} 6 \\ 3 \end{bmatrix}^T \begin{bmatrix} 2 & 2 \\ 2 & 5 \end{bmatrix} \begin{bmatrix} 6 \\ 3 \end{bmatrix}} = \frac{45}{6 \cdot 18 + 3 \cdot 27} = \frac{5}{21}$$

$$x_1 = \begin{bmatrix} 0 \\ 0 \end{bmatrix} + \frac{5}{21} \begin{bmatrix} 6 \\ 3 \end{bmatrix} = \begin{bmatrix} 10/7 \\ 5/7 \end{bmatrix}$$

$$r_1 = \begin{bmatrix} 6 \\ 3 \end{bmatrix} - \frac{5}{21} \begin{bmatrix} 18 \\ 27 \end{bmatrix} = \begin{bmatrix} 12/7 \\ -24/7 \end{bmatrix}$$

$$\beta_0 = \frac{r_1^T r_1}{r_0^T r_0} = \frac{144 \cdot 5/49}{36 + 9} = \frac{16}{49}$$

$$d_1 = \begin{bmatrix} 12/7 \\ -24/7 \end{bmatrix} + \frac{16}{49} \begin{bmatrix} 6 \\ 3 \end{bmatrix} = \begin{bmatrix} 180/49 \\ -120/49 \end{bmatrix}$$

$$\alpha_1 = \frac{\begin{bmatrix} 12/7 \\ -24/7 \end{bmatrix}^T \begin{bmatrix} 12/7 \\ -24/7 \end{bmatrix}}{\begin{bmatrix} 180/49 \\ -120/49 \end{bmatrix}^T \begin{bmatrix} 2 & 2 \\ 2 & 5 \end{bmatrix} \begin{bmatrix} 180/49 \\ -120/49 \end{bmatrix}} = \frac{7}{10}$$

$$x_2 = \begin{bmatrix} 10/7 \\ 5/7 \end{bmatrix} + \frac{7}{10} \begin{bmatrix} 180/49 \\ -120/49 \end{bmatrix} = \begin{bmatrix} 4 \\ -1 \end{bmatrix}$$

$$r_2 = \begin{bmatrix} 12/7 \\ -24/7 \end{bmatrix} - \frac{7}{10} \begin{bmatrix} 2 & 2 \\ 2 & 5 \end{bmatrix} \begin{bmatrix} 180/49 \\ -120/49 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

- deoarece  $r_2 = b - Ax_2 = 0$ , soluția este  $x_2 = [4, -1]^T$

## 3.5.3 Metoda gradientilor conjugați

### Teorema 4

Fie  $A$  o matrice  $n \times n$  simetrică și pozitiv definită și fie  $b \neq 0$  un vector. În metoda gradientilor conjugați, presupunem că  $r_k \neq 0$  pentru  $k < n$  (dacă  $r_k = 0$ , ecuația este rezolvată). Atunci, pentru orice  $1 \leq k \leq n$ ,

(a) următoarele trei subspații liniare ale lui  $\mathbb{R}^n$  sunt egale:

$$\langle x_1, \dots, x_k \rangle = \langle r_0, \dots, r_{k-1} \rangle = \langle d_0, \dots, d_{k-1} \rangle,$$

(b) rezidualii  $r_k$  sunt ortogonali doi câte doi:  $r_k^T r_j = 0$  pentru  $j < k$ ,

(c) direcțiile  $d_k$  sunt  $A$ -conjugate două câte două:  $d_k^T A d_j = 0$  pentru  $j < k$ .

- (a) pentru  $k = 1$ , observăm că  $\langle x_1 \rangle = \langle d_0 \rangle = \langle r_0 \rangle$ , deoarece  $x_0 = 0$
- prin definiție  $x_k = x_{k-1} + \alpha_{k-1} d_{k-1}$
- aceasta implică prin inducție faptul că  $\langle x_1, \dots, x_k \rangle = \langle d_0, \dots, d_{k-1} \rangle$
- un argument similar folosind  $d_k = r_k + \beta_{k-1} d_{k-1}$  arată că  $\langle r_0, \dots, r_{k-1} \rangle$  este egal cu  $\langle d_0, \dots, d_{k-1} \rangle$
- pentru (b) și (c), folosim inducția
- dacă  $k = 0$  nu există nimic de demonstrat

### 3.5.3 Metoda gradientilor conjugați

- presupunem că (b) și (c) au loc pentru  $k$ , și vom demonstra (b) și (c) pentru  $k + 1$
- înmulțim definiția lui  $r_{k+1}$  cu  $r_j^T$  la stânga:

$$r_j^T r_{k+1} = r_j^T r_k - \frac{r_k^T r_k}{d_k^T A d_k} r_j^T A d_k. \quad (8)$$

- dacă  $j \leq k - 1$ , atunci  $r_j^T r_k = 0$  din ipoteza de inducție (b)
- deoarece  $r_j$  poate fi exprimat ca o combinație de  $d_0, \dots, d_j$ , avem  $r_j^T A d_k = 0$  din ipoteza de inducție (c), și deci (b) are loc
- pe de altă parte, dacă  $j = k$ , atunci  $r_k^T r_{k+1} = 0$  rezultă din nou din (8), deoarece  $d_k^T A d_k = r_k^T A d_k + \beta_{k-1} d_{k-1}^T A d_k = r_k^T A d_k$ , folosind ipoteza de inducție (c)
- aceasta demonstrează (b)
- acum că  $r_k^T r_{k+1} = 0$ , ecuația (8) cu  $j = k + 1$  ne spune că

$$\frac{r_{k+1}^T r_{k+1}}{r_k^T r_k} = - \frac{r_{k+1}^T A d_k}{d_k^T A d_k}. \quad (9)$$



### 3.5.3 Metoda gradientilor conjugați

- aceasta, împreună cu înmulțirea definiției lui  $d_{k+1}$  la stânga cu  $d_j^T A$ , ne dau

$$d_j^T A d_{k+1} = d_j^T A r_{k+1} - \frac{r_{k+1}^T A d_k}{d_k^T A d_k} d_j^T A d_k. \quad (10)$$

- dacă  $j = k$ , atunci  $d_k^T A d_{k+1} = 0$  din (10), folosind simetria lui  $A$
- dacă  $j \leq k - 1$ , atunci  $A d_j = (r_j - r_{j+1})/\alpha_j$  (din definiția lui  $r_{k+1}$ ) este ortogonal pe  $r_{k+1}$ , arătând că primul termen din partea dreaptă a lui (10) este zero, și al doilea termen este zero din ipoteza de inducție, ceea ce completează argumentul pentru (c)
- în Exemplul 9, observăm că  $r_1$  este ortogonal pe  $r_0$ , după cum ne garantează Teorema 4
- acest fapt este cheia succesului metodei gradientilor conjugați: fiecare nou rezidual  $r_i$  este ortogonal pe toți rezidualii  $r_i$  anteriori
- dacă unul dintre  $r_i$  se dovedește a fi zero, atunci  $Ax_i = b$  și  $x_i$  este soluția
- dacă nu, după  $n$  pași ai buclei,  $r_n$  este ortogonal pe spațiul liniar generat de cei  $n$  vectori ortogonali doi câte doi  $r_0, \dots, r_{n-1}$ , care trebuie să fie egal cu  $\mathbb{R}^n$
- deci  $r_n$  trebuie să fie vectorul zero, și  $Ax_n = b$



## 3.6 Sisteme de ecuații neliniare

- Capitolul 2 prezintă metode de rezolvare a unei ecuații într-o necunoscută, de obicei neliniară
- în acest capitol, am studiat metode de găsim a soluțiilor pentru sisteme de ecuații, dar am impus condiția ca ecuațiile să fie liniare
- combinarea dintre neliniaritate și „mai mult decât o ecuație” ridică gradul de dificultate în mod considerabil
- această secțiune descrie metoda lui Newton și variante ale ei pentru găsirea soluției sistemelor de ecuații neliniare

## 3.6.1 Metoda lui Newton pentru mai multe variabile

- metoda lui Newton pentru o singură variabilă

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}$$

oferă ideea principală pentru metoda lui Newton pentru mai multe variabile

- ambele sunt deduse pornind de la aproximarea liniară oferită de dezvoltarea în serie Taylor
- de exemplu, fie

$$\begin{aligned}f_1(u, v, w) &= 0 \\f_2(u, v, w) &= 0 \\f_3(u, v, w) &= 0\end{aligned}\tag{11}$$

trei ecuații neliniare în trei necunoscute  $u, v, w$

- definim funcția cu valori vectoriale  $F(u, v, w) = (f_1, f_2, f_3)$ , și notăm problema (11) prin  $F(x) = 0$ , unde  $x = (u, v, w)$

### 3.6.1 Metoda lui Newton pentru mai multe variabile

- analogul derivatei  $f'$  din cazul unei singure variabile este **matricea jacobiană** definită prin

$$DF(x) = \begin{bmatrix} \frac{\partial f_1}{\partial u} & \frac{\partial f_1}{\partial v} & \frac{\partial f_1}{\partial w} \\ \frac{\partial f_2}{\partial u} & \frac{\partial f_2}{\partial v} & \frac{\partial f_2}{\partial w} \\ \frac{\partial f_3}{\partial u} & \frac{\partial f_3}{\partial v} & \frac{\partial f_3}{\partial w} \end{bmatrix}.$$

- dezvoltarea în serie Taylor pentru funcții vectoriale în jurul lui  $x_0$  este

$$F(x) = F(x_0) + DF(x_0) \cdot (x - x_0) + O((x - x_0)^2).$$

- scriem  $f(x) = O(g(x))$  dacă și numai dacă există  $M > 0$  astfel încât  $|f(x)| \leq M|g(x)|$
- de exemplu, dezvoltarea liniară a lui  $F(u, v) = (e^{u+v}, \sin u)$  în jurul lui  $x_0 = (0, 0)$  este

$$\begin{aligned} F(x) &= \begin{bmatrix} 1 \\ 0 \end{bmatrix} + \begin{bmatrix} e^0 & e^0 \\ \cos 0 & 0 \end{bmatrix} \begin{bmatrix} u \\ v \end{bmatrix} + O(x^2) \\ &= \begin{bmatrix} 1 \\ 0 \end{bmatrix} + \begin{bmatrix} u + v \\ u \end{bmatrix} + O(x^2). \end{aligned}$$

- metoda lui Newton se bazează pe o aproximare liniară, ignorând termenii  $O(x^2)$

## 3.6.1 Metoda lui Newton pentru mai multe variabile

- ca în cazul unei singure variabile, fie  $x = r$  rădăcina, și fie  $x_0$  aproximarea curentă
- atunci

$$0 = F(r) \approx F(x_0) + DF(x_0) \cdot (r - x_0),$$

sau

$$-DF(x_0)^{-1} F(x_0) \approx r - x_0. \quad (12)$$

- prin urmare, o mai bună aproximare a rădăcinii rezultă din rezolvarea ecuației (12) pentru a găsi  $r$

### Algoritmul 6 (Metoda lui Newton pentru mai multe variabile)

$x_0$  = vectorul inițial

$x_{k+1} = x_k - (DF(x_k))^{-1} F(x_k)$  **for**  $k = 0, 1, 2, \dots$

- deoarece calculul inverselor este dificil din punct de vedere computațional, vom folosi un truc pentru a evita acest calcul
- la fiecare pas, în loc să urmărim definiția anterioară literal, luăm  $x_{k+1} = x_k - s$ , unde  $s$  este soluția ecuației  $DF(x_k)s = F(x_k)$

## 3.6.1 Metoda lui Newton pentru mai multe variabile

- acum, doar eliminarea gaussiană este necesară pentru a realiza un pas al metodei, în loc de calculul inversei, care necesită de trei ori mai multe operații
- prin urmare, pasul de iterare pentru metoda lui Newton pentru mai multe variabile este

$$\begin{cases} DF(x_k)s = -F(x_k) \\ x_{k+1} = x_k + s. \end{cases} \quad (13)$$


### Exemplul 10

- folosiți metoda lui Newton cu vectorul inițial  $(1, 2)$  pentru a găsi o soluție a sistemului

$$\begin{aligned} v - u^3 &= 0 \\ u^2 + v^2 - 1 &= 0. \end{aligned}$$



### 3.6.1 Metoda lui Newton pentru mai multe variabile



**Figura 1: Metoda lui Newton pentru Exemplul 10.** Cele două rădăcini sunt punctele de pe cerc. Metoda lui Newton produce punctele care converg către soluția aproximativă (0.8260, 0.5636).

## 3.6.1 Metoda lui Newton pentru mai multe variabile

- Figura 1 prezintă mulțimile pe care  $f_1(u, v) = v - u^3$  și  $f_2(u, v) = u^2 + v^2 - 1$  sunt zero și cele două puncte de intersecție ale lor, care sunt soluțiile sistemului de ecuații
- matricea jacobiană este

$$DF(u, v) = \begin{bmatrix} -3u^2 & 1 \\ 2u & 2v \end{bmatrix}.$$

- folosind punctul inițial  $x_0 = (1, 2)$ , în primul pas trebuie să rezolvăm ecuația matricială (13):

$$\begin{bmatrix} -3 & 1 \\ 2 & 4 \end{bmatrix} \begin{bmatrix} s_1 \\ s_2 \end{bmatrix} = - \begin{bmatrix} 1 \\ 4 \end{bmatrix}.$$

- soluția este  $s = (0, -1)$ , astfel că prima iterație produce  $x_1 = x_0 + s = (1, 1)$

## 3.6.1 Metoda lui Newton pentru mai multe variabile

- al doilea pas necesită rezolvarea ecuației

$$\begin{bmatrix} -3 & 1 \\ 2 & 2 \end{bmatrix} \begin{bmatrix} s_1 \\ s_2 \end{bmatrix} = - \begin{bmatrix} 0 \\ 1 \end{bmatrix}.$$

- soluția este  $s = (-1/8, -3/8)$  și  $x_2 = x_1 + s = (7/8, 5/8)$
- ambele iterații sunt prezentate în Figura 1
- următorii pași sunt detaliați în tabelul de mai jos:

| pasul | $u$                | $v$                |
|-------|--------------------|--------------------|
| 0     | 1.0000000000000000 | 2.0000000000000000 |
| 1     | 1.0000000000000000 | 1.0000000000000000 |
| 2     | 0.8750000000000000 | 0.6250000000000000 |
| 3     | 0.82903634826712   | 0.56434911242604   |
| 4     | 0.82604010817065   | 0.56361977350284   |
| 5     | 0.82603135773241   | 0.56362416213163   |
| 6     | 0.82603135765419   | 0.56362416216126   |
| 7     | 0.82603135765419   | 0.56362416216126   |

## 3.6.1 Metoda lui Newton pentru mai multe variabile

- familiara dublare a numărului de zecimale exacte la fiecare pas, caracteristică pătratic convergenței, este evidentă în acest tabel
- simetria ecuațiilor arată că dacă  $(u, v)$  este o soluție, atunci și  $(-u, -v)$  este o soluție, după cum se poate observa în Figura 1
- a doua soluție poate fi de asemenea găsită prin aplicarea metodei lui Newton cu un punct inițial aflat în vecinătatea acesteia

### Exemplul 11

- folosiți metoda lui Newton pentru a găsi soluțiile sistemului

$$f_1(u, v) = 6u^3 + uv - 3v^3 - 4 = 0$$

$$f_2(u, v) = u^2 - 18uv^2 + 16v^3 + 1 = 0.$$

- observăm că  $(u, v) = (1, 1)$  este o soluție
- mai există însă altele două

### 3.6.1 Metoda lui Newton pentru mai multe variabile

- matricea jacobiană este

$$DF(u, v) = \begin{bmatrix} 18u^2 + v & u - 9v^2 \\ 2u - 18v^2 & -36uv + 48v^2 \end{bmatrix}.$$

- care soluție este găsită de metoda lui Newton depinde de punctul inițial, exact ca în cazul unidimensional
- folosind punctul inițial  $(u_0, v_0) = (2, 2)$ , iterarea formulei anterioare ne dă următorul tabel:



### 3.6.1 Metoda lui Newton pentru mai multe variabile

| pasul | $u$                | $v$                |
|-------|--------------------|--------------------|
| 0     | 2.0000000000000000 | 2.0000000000000000 |
| 1     | 1.37258064516129   | 1.34032258064516   |
| 2     | 1.07838681200443   | 1.05380123264984   |
| 3     | 1.00534968896520   | 1.00269261871539   |
| 4     | 1.00003367866506   | 1.00002243772010   |
| 5     | 1.00000000111957   | 1.00000000057894   |
| 6     | 1.0000000000000000 | 1.0000000000000000 |
| 7     | 1.0000000000000000 | 1.0000000000000000 |

- alți vectori inițiali conduc la alte două rădăcini, care sunt aproximativ  $(0.865939, 0.462168)$  și  $(0.886809, -0.294007)$
- metoda lui Newton este o alegere bună dacă jacobianul poate fi calculat
- dacă nu, cea mai bună alternativă este metoda lui Broyden, subiectul subsecțiunii următoare

## 3.6.2 Metoda lui Broyden

- metoda lui Newton pentru rezolvarea unei ecuații într-o necunoscută necesită cunoașterea derivatei
- dezvoltarea acestei metode în Capitolul 2 a fost urmată de discuția despre metoda secantei, folosită pentru cazul în care derivata nu este disponibilă sau este prea greu de evaluat
- acum că avem o versiune a metodei lui Newton pentru sisteme de ecuații neliniare  $F(x) = 0$ , ne confruntăm cu aceeași întrebare: Ce se întâmplă dacă matricea jacobiană  $DF$  nu este disponibilă?
- deși nu există o extensie simplă a metodei lui Newton la o metodă a secantei pentru sisteme, Broyden a sugerat o metodă care se apropie cel mai mult de acest deziderat
- să presupunem că  $A_i$  este cea mai bună aproximare a matricii jacobiene disponibilă la pasul  $i$ , și că a fost folosită pentru a da naștere următoarei aproximări astfel:

$$x_{i+1} = x_i - A_i^{-1} F(x_i). \quad (14)$$

## 3.6.2 Metoda lui Broyden

- pentru a actualiza  $A_i$  la  $A_{i+1}$  pentru pasul următor, am dori să respectăm aspectul de derivată al jacobianului  $DF$ , care trebuie să satisfacă

$$A_{i+1}\delta_{i+1} = \Delta_{i+1}, \quad (15)$$

unde  $\delta_{i+1} = x_{i+1} - x_i$  și  $\Delta_{i+1} = F(x_{i+1}) - F(x_i)$

- pe de altă parte, pentru complementul ortogonal al lui  $\delta_{i+1}$ , nu avem alte informații noi
- prin urmare, cerem ca

$$A_{i+1}w = A_iw \quad (16)$$

pentru orice  $w$  care satisface  $\delta_{i+1}^T w = 0$

- o matrice care satisface atât (15) cât și (16) este

$$A_{i+1} = A_i + \frac{(\Delta_{i+1} - A_i\delta_{i+1})\delta_{i+1}^T}{\delta_{i+1}^T\delta_{i+1}}. \quad (17)$$

- metoda lui Broyden folosește pasul din metoda lui Newton (14) pentru a găsi aproximarea următoare, și actualizează aproximarea jacobianului ca în (17)
- rezumând, algoritmul începe cu un vector inițial  $x_0$  și o aproximare inițială a jacobianului  $A_0$ , care poate fi aleasă matricea identitate

## 3.6.2 Metoda lui Broyden

### Algoritmul 7 (Metoda lui Broyden I)

$x_0$  = vectorul inițial

$A_0$  = matricea inițială

**for**  $i = 0, 1, 2, \dots$

$$x_{i+1} = x_i - A_i^{-1} F(x_i)$$

$$A_{i+1} = A_i + \frac{(\Delta_{i+1} - A_i \delta_{i+1}) \delta_{i+1}^T}{\delta_{i+1}^T \delta_{i+1}}.$$

**end**

unde  $\delta_{i+1} = x_{i+1} - x_i$  și  $\Delta_{i+1} = F(x_{i+1}) - F(x_i)$ .

- observăm că pasul de tip Newton se realizează prin rezolvarea ecuației  $A_i \delta_{i+1} = F(x_i)$ , la fel ca în metoda lui Newton
- tot ca metoda lui Newton, metoda lui Broyden nu oferă garanția convergenței către o soluție
- o a doua abordare a metodei lui Broyden evită pasul relativ dificil din punct de vedere computațional  $A_i \delta_{i+1} = F(x_i)$
- deoarece oricum doar aproximăm derivata  $DF$  în timpul iterației, mai bine aproximăm inversa lui  $DF$ , cea de care avem nevoie în pasul Newton



## 3.6.2 Metoda lui Broyden

- refacem deducerea metodei lui Broyden din punctul de vedere al matricii  $B_i = A_i^{-1}$
- ne-ar plăcea să avem

$$\delta_{i+1} = B_{i+1} \Delta_{i+1}, \quad (18)$$

unde  $\delta_{i+1} = x_{i+1} - x_i$  și  $\Delta_{i+1} = F(x_{i+1}) - F(x_i)$ , și, pentru orice  $w$  care satisface  $\delta_{i+1}^T w = 0$ , să avem  $A_{i+1} w = A_i w$ , sau

$$B_{i+1} A_i w = w. \quad (19)$$

- o matrice care satisface atât (18) cât și (19) este

$$B_{i+1} = B_i + \frac{(\delta_{i+1} - B_i \Delta_{i+1}) \delta_{i+1}^T B_i}{\delta_{i+1}^T B_i \Delta_{i+1}}. \quad (20)$$

- noua versiune a iterației, care nu necesită rezolvarea vreunei ecuații, este

$$x_{i+1} = x_i - B_i F(x_i). \quad (21)$$

- algoritmul rezultat se numește metoda lui Broyden II



## 3.6.2 Metoda lui Broyden

### Algoritmul 8 (Metoda lui Broyden II)

$x_0$  = vectorul inițial

$B_0$  = matricea inițială

**for**  $i = 0, 1, 2, \dots$

$$x_{i+1} = x_i - B_i F(x_i)$$

$$B_{i+1} = B_i + \frac{(\delta_{i+1} - B_i \Delta_{i+1}) \delta_{i+1}^T B_i}{\delta_{i+1}^T B_i \Delta_{i+1}}$$

**end**

unde  $\delta_{i+1} = x_{i+1} - x_i$  și  $\Delta_{i+1} = F(x_{i+1}) - F(x_i)$ .

- la început, un vector inițial  $x_0$  și o aproximare inițială pentru  $B_0$  sunt necesare
- dacă este imposibil să se calculeze derivate, alegerea  $B_0 = I$  poate fi folosită

## 3.6.2 Metoda lui Broyden

- un dezavantaj al metodei lui Broyden II este că aproximările jacobianului, necesare pentru anumite aplicații, nu sunt ușor disponibile
- matricea  $B_i$  este o aproximare a inversei matricii jacobiene
- metoda lui Broyden I, pe de altă parte, actualizează pe  $A_i$ , care reprezintă o aproximare a jacobianului
- ambele versiuni ale metodei lui Broyden au o convergență superliniară, fiind ușor mai lente decât convergența pătratică a metodei lui Newton
- dacă o formulă a jacobianului este disponibilă, are loc o accelerare a convergenței dacă se folosește inversa lui  $DF(x_0)$  pe post de matrice inițială  $B_0$

Vă mulțumesc!