

19 Generalități despre corelație.

Corelație liniară

În statistică adesea apar probleme de genul următor: pentru aceeași populație avem două seturi de date corespunzătoare la două variabile distincte și se pune întrebarea dacă între cele două variabile există vreo legătură (relație)? Dacă da, care este această relație? Cum sunt aceste variabile corelate? Relațiile pe care le discutăm aici nu sunt neapărat de tip cauză-efect. Ele sunt relații matematice care permit anticiparea comportamentului unei variabile în funcție de comportamentul celeilalte. Iată câteva exemple:

Exemplul 19.1.

- În general o persoană care crește în înălțime crește și în greutate. Se pune întrebarea: există vreo relație între înălțime și greutate?
- Studenții își petrec timpul la universitate învățând sau dând examene. Se pune întrebarea: studiind mai mult, obții note mai mari?
- Doctorii care testează un nou medicament prescriu cantități diferite și observă răspunsul pacienților; se pune întrebarea: cantitatea de medicament prescrisă determină oare timpul de însănătoșire al pacientului?

Problemele din exemplul precedent cer analiza corelației dintre două variabile.

În cazul în care pentru o populație avem două seturi de date corespunzătoare la două variabile distincte se formează perechile de date (x, y) , în care x este valoarea primei variabile și y este valoarea celei de-a doua variabile. De exemplu, x este înălțimea și y este greutatea.

O pereche ordonată de date (x, y) se numește **dată bidimensională**.

În mod tradițional, variabila X (având valorile x) se numește **variabilă de intrare (variabilă independentă)**, iar variabila Y (având valorile y) se numește **variabilă de ieșire (variabilă dependentă)**.

Variabila de intrare X este cea măsurată sau controlată pentru a prezice variabila Y .

În cazul testării medicamentului doctorii (măsoară) controlează cantitatea de medicament prescrisă și deci această cantitate x este valoarea variabilei de intrare (independentă) X . Timpul de recuperare y este valoarea variabilei de ieșire (dependente) Y .

În cazul înălțimii și greutateii oricare din variabile poate fi atât variabilă de intrare cât și variabilă de ieșire. Rezultatele analizei vor fi însă funcție de alegerea făcută.


În cazul problemelor de analiză a corelației dintre două variabile datele eșantionului se prezintă sub forma unei diagrame de împrăștiere.

Definiția 19.1. O **diagramă de împrăștiere** sau **nor de puncte** este reprezentarea grafică a perechilor de date într-un sistem de coordonate ortogonal. Valorile x ale variabilei de intrare X sunt reprezentate pe axa Ox , iar valorile y ale variabilei de ieșire Y sunt reprezentate pe axa Oy .

Exemplul 19.2. Pentru un eșantion de 15 studenți următorul tabel de date reprezintă numărul de ore de studiu x pentru un examen și nota y obținută la acel examen:

x	2	3	3	4	4	5	5	6	6	6	7	7	7	8	8
y	5	5	7	5	7	7	8	6	9	8	7	9	10	8	9


Diagrama de împrăștiere în acest caz este:



Exemplul 19.3. Diagrama de împrăștiere în cazul tabelului de date:

x	2	12	4	6	9	4	11	3	10	11	3	1	13	12	14	7	2	8
y	4	8	10	9	10	8	8	5	10	9	8	3	9	8	8	11	6	9

este:




Analiza de corelație are ca obiectiv să stabilească legătura dintre cele două variabile.

Vom prezenta câteva diagrame de împrăștiere pentru a ilustra corelații posibile dintre variabila de intrare X și variabila de ieșire Y .

Definiția 19.2. Dacă pentru valorile x crescânde ale variabilei de intrare X nu există o deplasare clară (bine definită) ale valorilor y ale variabilei Y , atunci zicem că **nu avem corelație** sau că **nu există legătură între X și Y** .

Diagrama de împrăștiere în cazul în care nu avem corelație este următoarea:



Definiția 19.3. Dacă pentru valorile x crescânde ale variabilei de intrare X există o deplasare clară (bine definită) ale valorilor y ale variabilei Y zicem că **avem o corelație**. Zicem că avem o **corelație pozitivă** dacă y tinde să crească și avem o **corelație negativă** dacă y tinde să descrească odată cu creșterea lui x .

Precizia schimbării lui y atunci când x crește determină cât de puternică este corelația. Diagramele de împrăștiere care urmează ilustrează aceste idei:




Figura 19: Diagramă de împrăștiere în cazul unei corelații pozitive




Figura 20: Diagramă de împrăștiere în cazul unei corelații pozitive strânse




Figura 21: Diagramă de împrăștiere în cazul unei corelații negative




Figura 22: Diagramă de împrăștiere în cazul unei corelații negative strânse

Definiția 19.4. Dacă perechile (x, y) tind să urmeze o dreaptă zicem că avem o **corelație liniară**.

Definiția 19.5. Dacă toate perechile (x, y) se găsesc pe o dreaptă (care nu este nici orizontală nici verticală) atunci zicem că avem o **corelație liniară perfectă**.




Figura 23: Diagramă de împrăștiere în cazul unei corelații pozitive liniare perfecte

Remarca 19.1. Dacă toate perechile (x, y) se găsesc pe o dreaptă orizontală sau verticală nu există corelație între cele două variabile. Aceasta întrucât schimbarea uneia nu afectează valoarea celeilalte variabile.

Remarca 19.2. Diagramele de împrăștiere nu sunt totdeauna de genul celor prezentate până acum și sugerează corelații care sunt de altă natură.




Figura 24: Diagramă de împrăștiere în cazul unei corelații neliniare

Definiția 19.6. Coeficientul de corelație liniară r măsoară cât de puternică este corelația liniară dintre cele două variabile. Reflectă consistența efectului pe care-l are schimbarea valorii variabilei independente X asupra variabilei dependente Y .

Remarca 19.3. Valoarea coeficientului de corelație liniară r permite să se formuleze un răspuns la întrebarea: există o corelație liniară între cele două variabile considerate? Coeficientul de corelație liniară r are valoarea între -1 și $+1$. Valoarea $r = +1$ înseamnă o corelație liniară pozitivă perfectă, iar valoarea $r = -1$ înseamnă o corelație liniară negativă perfectă.

Dacă pentru x crescând rezultă o creștere generală a valorilor lui y , atunci r indică o corelație liniară pozitivă.

De exemplu, în cazul copiilor dacă x este vârsta și y este înălțimea, atunci ne așteptăm ca r să fie pozitiv, pentru că în mod natural, înălțimea copilului crește o dată cu vârsta. În

cazul automobilelor de serie, dacă x este vârsta, iar y este valoarea, atunci ne așteptăm ca r să fie negativ pentru că în mod uzual valoarea automobilului descrește cu vârsta lui.

Definiția 19.7. Coeficientul de corelație liniară r în cazul unui eșantion este prin definiție:

$$r = \frac{\sum (x - \bar{x}) \cdot (y - \bar{y})}{n \cdot s_x \cdot s_y}$$

în care s_x, s_y sunt deviațiile standard ale variabilelor x, y , iar n este numărul de perechi (x, y) .

Remarca 19.4. Pentru a calcula r de obicei se folosește o formulă alternativă echivalentă:

$$r = \frac{SS(x, y)}{\sqrt{SS(x) \cdot SS(y)}}$$

unde: $SS(x) = \sum x^2 - \frac{1}{n} \cdot \left(\sum x\right)^2$, $SS(y) = \sum y^2 - \frac{1}{n} \cdot \left(\sum y\right)^2$, $SS(x, y) = \sum x \cdot y - \frac{1}{n} \cdot \left(\sum x \cdot \sum y\right)$.

Exemplul 19.4. Să se determine coeficientul de corelație liniară r în cazul unui eșantion aleator de mărime 10, dacă tabelul de date este:

x	27	22	15	35	30	52	35	55	40	40
y	30	26	25	42	38	40	32	54	50	43

Folosind aceste date avem:

$$SS(x) = 1396,9 \quad SS(y) = 858,0 \quad SS(x, y) = 919,0$$

de unde găsim:

$$r = \frac{919,0}{\sqrt{(1396,9) \cdot (858,0)}} = 0,8394 \approx 0,84.$$

Remarca 19.5. Dacă valoarea calculată r este apropiată de 0, atunci **nu** există corelație liniară.

Dacă valoarea calculată r este aproape de $+1$ sau -1 , atunci bănuim că între cele două variabile există corelație liniară.

Între 0 și 1 există o valoare numită punct de decizie care indică dacă există sau nu există corelație liniară. Un punct simetric există și între -1 și 0. Valoarea punctului de decizie depinde de mărimea eșantionului.

În tabelul următor sunt trecute puncte de decizie pozitive pentru diferite mărimi de eșantionare cuprinse între 5 și 100.

n	punct de decizie	n	punct de decizie	n	punct de decizie	n	punct de decizie
5	0,878	12	0,576	19	0,456	30	0,301
6	0,811	13	0,553	20	0,444	40	0,312
7	0,754	14	0,532	22	0,423	50	0,279
8	0,707	15	0,514	24	0,404	60	0,254
9	0,666	16	0,497	26	0,388	80	0,220
10	0,632	17	0,482	28	0,374	100	0,196
11	0,602	18	0,468				

Tabelul 1: Punctele de decizie pozitive pentru corelație liniară

Valorile punctelor de decizie descresc dacă n crește.


Dacă r se găsește între punctul de decizie negativ și cel pozitiv nu avem argumente ca să susținem că între cele două variabile există o corelație liniară.

Dacă r este mai mare decât punctul de decizie pozitiv sau mai mic decât punctul de decizie negativ atunci între cele două variabile există o corelație liniară.


Existența unei corelații între cele două variabile nu înseamnă că există o relație cauză efect. Astfel, de exemplu, dacă X este alocația pentru copii în ultimii 10 ani și Y este consumul de băuturi alcoolice în ultimii 10 ani, un eșantion de aceste date arată o corelație pozitivă strânsă fără ca alocația pentru copii să fie cauza vânzării băuturilor alcoolice sau viceversa.

O metodă rapidă de estimare a coeficientului de corelație liniară r în cazul unui eșantion este următoarea:


- a) Se desenează o curbă închisă în jurul valorii mulțimii de perechi (x, y) :





b) Se determină lungimea D a diametrului maxim:



c) Se determină lungimea diametrului minim d :



d) Valoarea r se estimează cu $\pm \left(1 - \frac{d}{D}\right)$, în care semnul se alege în funcție de orientarea diametrului D :



Trebuie subliniat că această estimare este grosieră. Este foarte sensibilă la împrăștiere. Cu toate acestea dacă plaja de valori a lui X este aproximativ aceeași ca plaja de valori a lui Y aproximația este utilă.


20 Analiză de corelație liniară

În secțiunea 20 am văzut care este formula coeficientului de corelație liniară r între două variabile X, Y menit să măsoare cât de strânsă este relația de dependență liniară dintre cele două variabile.


În cele ce urmează vom prezenta o analiză mai amănunțită a acestei formule. Considerăm pentru ilustrație următorul set de date bidimensionale:

x	2	3	6	8	11	12
y	1	5	3	2	6	1


Diagrama de împrăștiere în acest caz este:



Media $\bar{x}$ a variabilei x este 7: $\bar{x} = 7$, iar media variabilei y este 3: $\bar{y} = 3$. Punctul $(\bar{x}, \bar{y})$ este punctul $(7, 3)$ și se numește **centroid** al datelor:



Dacă prin punctul de coordonate $(\bar{x}, \bar{y})$ se duc paralele la axele de coordonate, setul de date se împarte în patru submulțimi. Fiecare dată (x, y) se găsește la o anumită distanță de aceste linii; $x - \bar{x}$ este distanța cu semn de la (x, y) la paralela la axa Oy și $y - \bar{y}$ este distanță cu semn de la (x, y) la paralela Ox . Distanțele cu semn sunt pozitive sau negative în funcție de poziția lui (x, y) față de $(\bar{x}, \bar{y})$.



O măsură a dependenței liniare ar putea fi covarianța. Covarianța dintre X și Y este definită ca suma produselor distanțelor cu semn $x - \bar{x}$ și $y - \bar{y}$ a tuturor datelor la centroid împărțită la n :

$$covar(x, y) = \frac{\sum_{i=1}^n (x_i - \bar{x}) \cdot (y_i - \bar{y})}{n}$$

Covarianța în cazul tabelului de date considerate este 0,6.

Covarianța pozitivă înseamnă că diagrama de dispersie este dominată de date care se găsesc deasupra și în dreapta centroidului sau dedesubt și în stânga acestuia. Aceasta întrucât produsele $(x - \bar{x}) \cdot (y - \bar{y})$ în puncte din aceste regiuni sunt pozitive.

Dacă diagrama de dispersie este dominată de date care se găsesc deasupra și în stânga sau dedesubt și în dreapta centroidului atunci covarianța este negativă pentru că produsele $(x - \bar{x}) \cdot (y - \bar{y})$ pentru puncte din aceste regiuni sunt negative.

Covarianța însă nu este convenabilă pentru a măsura cât este de strânsă relația de dependență liniară între două variabile fiindcă depinde de unitățile de măsură ale datelor. Covarianța nu are o unitate de măsură standardizată și împrăștierea datelor influențează foarte mult mărimea covarianței.

Astfel de exemplu dacă înmulțim datele din tabelul considerat anterior cu 10 obținem tabelul de date:

x	20	30	60	80	110	120
y	10	50	30	20	60	10

Covarianța în cazul acestui tabel de date este 60, dar aceasta nu înseamnă nicidecum că relația de dependență liniară între X, Y este mai strânsă. Relația de dependență liniară

este aceeași și doar datele sunt mai împrăștiate. Aceasta este problema cu covarianța atunci când vrem să măsurăm cu ajutorul ei dependența liniară între două variabile.

Trebuie să găsim o cale de eliminare a efectului împrăștierii datelor atunci când măsurăm dependența.

Dacă standardizăm X și Y împărțind deviația fiecăreia de la media sa cu deviația standard:

$$x' = \frac{x - \bar{x}}{s_x} \quad \text{și} \quad y' = \frac{y - \bar{y}}{s_y}$$

și calculăm covarianța lui X' și Y' , vom avea o covarianță care nu mai este influențată de împrăștierea datelor. Exact acest lucru este realizat prin introducerea coeficientului de corelație liniar r . Astfel coeficientul de corelație liniar este:

$$r = \text{covar}(X', Y') = \frac{\text{covar}(X, Y)}{s_x \cdot s_y}$$

Coeficientul de corelație liniară standardizează măsura dependenței și ne permite să comparăm cât de strânsă este dependența liniară a diferitelor seturi de date bidimensionale. Formula coeficientului de corelație liniară adesea poartă denumirea de momentul produs Pearson.

Valoarea coeficientului de corelație liniară r în cazul setului de date considerat la început este:

$$r = \frac{0,6}{(4,099) \cdot (2,098)} = 0,07$$

Pentru că determinarea coeficientului de corelație liniară cu ajutorul formulei:

$$r = \frac{\text{covar} X, Y}{s_x \cdot s_y}$$

este greoaie, în locul ei se folosește una practică:

$$r = \frac{SS(X, Y)}{\sqrt{SS(X) \cdot SS(Y)}}$$

Aceasta din urmă formulă evită calculul separat al lui $\bar{x}$, $\bar{y}$, s_x , s_y precum și calculul deviațiilor de la medie.