

# Matematici Asistate de Calculator

Prof. Dr. Călin-Adrian POPA

## Cursul 7

24 Martie 2026

## 5.2.2 Liniarizarea datelor

- creșterea exponențială a unei populații poate fi dedusă atunci când rata de creștere este proporțională cu mărimea populației
- în condiții perfecte, atunci când mediul de creștere este neschimbat și când populația este mult sub capacitatea maximă a mediului, modelul este o reprezentare bună
- **modelul exponențial**

$$y = c_1 e^{c_2 t} \quad (1)$$

nu poate fi interpolat direct de cele mai mici pătrate, deoarece  $c_2$  nu apare liniar în ecuația modelului

- imediat ce punctele sunt substituite în model, dificultatea este clară: ecuațiile care trebuie rezolvate pentru a găsi coeficienții sunt neliniare și nu pot fi exprimate ca un sistem liniar  $Ax = b$
- prin urmare, deducerea ecuațiilor normale este irelevantă
- există două moduri de a trata problema coeficienților neliniari
- modul mai dificil este de a minimiza direct eroarea în sensul celor mai mici pătrate, și anume, de a rezolva problema de tip cele mai mici pătrate neliniară
- vom reveni la această problemă în Secțiunea 5.4
- modul mai simplu este de a schimba problema

## 5.2.2 Liniarizarea datelor

- în loc să rezolvăm problema inițială în sensul celor mai mici pătrate, putem rezolva o altă problemă, care este legată de cea inițială, prin „liniarizarea” modelului
- în cazul modelului exponențial (1), acesta este liniarizat prin aplicarea logaritmului natural:

$$\ln y = \ln(c_1 e^{c_2 t}) = \ln c_1 + c_2 t. \quad (2)$$

- observăm că pentru modelul exponențial, graficul lui  $\ln y$  este un grafic liniar în  $t$
- la prima vedere, pare că doar am schimbat o problemă cu o alta
- coeficientul  $c_2$  este acum liniar în model, dar  $c_1$  nu mai este
- totuși, dacă renotăm  $k = \ln c_1$ , putem scrie

$$\ln y = k + c_2 t. \quad (3)$$

- acum ambii coeficienți  $k$  și  $c_2$  sunt liniari în model
- după rezolvarea ecuațiilor normale pentru a găsi cele mai bune valori  $k$  și  $c_2$ , putem afla valoarea corespunzătoare  $c_1 = e^k$  dacă dorim acest lucru
- trebuie să observăm că modul de a ieși din dificultatea coeficienților neliniari a fost să schimbăm problema

## 5.2.2 Liniarizarea datelor

- problema inițială de tip cele mai mici pătrate a fost să interpolăm datele folosind (1)—și anume, de a găsi  $c_1, c_2$  care minimizează

$$(c_1 e^{c_2 t_1} - y_1)^2 + \cdots + (c_1 e^{c_2 t_m} - y_m)^2, \quad (4)$$

suma pătratelor rezidualilor ecuațiilor  $c_1 e^{c_2 t_i} = y_i$  pentru  $i = 1, \dots, m$

- deocamdată, rezolvăm problema revizuită a minimizării erorii în sensul celor mai mici pătrate în „spațiul logaritm”—și anume, aceea de a găsi  $c_1, c_2$  care minimizează

$$(\ln c_1 + c_2 t_1 - \ln y_1)^2 + \cdots + (\ln c_1 + c_2 t_m - \ln y_m)^2, \quad (5)$$

suma pătratelor rezidualilor ecuațiilor  $\ln c_1 + c_2 t_i = \ln y_i$  pentru  $i = 1, \dots, m$

- acestea sunt două minimizări diferite și au soluții diferite, ceea ce înseamnă că în general dau valori diferite pentru coeficienții  $c_1, c_2$
- care metodă este corectă pentru această problemă, metoda neliniară a celor mai mici pătrate din (4) sau versiunea liniarizată din (5)?
- prima este metoda celor mai mici pătrate, după cum am definit-o
- cea de-a doua nu este
- totuși, depinzând de contextul datelor, oricare dintre cele două poate fi alegerea mai naturală



## 5.2.2 Liniarizarea datelor

- pentru a răspunde la întrebare, utilizatorul trebuie să se decidă care erori sunt cel mai important de minimizat, erorile în sensul inițial sau erorile în „spațiul logaritm”
- de fapt, modelul logaritm este liniar, și s-ar putea argumenta că, doar după transformarea logaritmică a datelor astfel încât să aibă o relație liniară, este natural să evaluăm acuratețea modelului

### Exemplul 1


- folosiți liniarizarea modelului pentru a găsi cea mai bună interpolare exponențială în sensul celor mai mici pătrate  $y = c_1 e^{c_2 t}$  pentru numărul total de mașini existente în lume:

| an   | mașini ( $\times 10^6$ ) |
|------|--------------------------|
| 1950 | 53.05                    |
| 1955 | 73.04                    |
| 1960 | 98.31                    |
| 1965 | 139.78                   |
| 1970 | 193.48                   |
| 1975 | 260.20                   |
| 1980 | 320.39                   |

## 5.2.2 Liniarizarea datelor

- datele descriu numărul de automobile care se află în exploatare în lume într-un anumit an
- definim variabila de timp  $t$  în termeni de ani din 1950
- rezolvând problema de tip cele mai mici pătrate liniară, obținem  $k \approx 3.9896$ ,  $c_2 \approx 0.06152$
- deoarece  $c_1 \approx e^{3.9896} \approx 54.03$ , modelul este  $y = 54.03e^{0.06152t}$
- valoarea REMP-ului modelului liniarizat în spațiul logaritm este  $\approx 0.0357$ , în timp ce REMP-ul modelului exponențial inițial este  $\approx 9.56$
- cel mai bun model împreună cu datele sunt reprezentate grafic în Figura 1

## 5.2.2 Liniarizarea datelor



**Figura 1: Interpolare exponențială pentru numărul total de mașini existente în lume, folosind liniarizarea.** Cea mai bună interpolare în sensul celor mai mici pătrate este  $y = 54.03e^{0.06152t}$ . Comparați cu Figura 7.

## 5.2.2 Liniarizarea datelor

### Exemplul 2

- numărul de tranzistoare din CPU-urile Intel de la începutul anilor 1970 sunt date în tabelul următor; interpolați modelul  $y = c_1 e^{c_2 t}$  pentru aceste date

| CPU         | an   | tranzistoare |
|-------------|------|--------------|
| 4004        | 1971 | 2,250        |
| 8008        | 1972 | 2,500        |
| 8080        | 1974 | 5,000        |
| 8086        | 1978 | 29,000       |
| 286         | 1982 | 120,000      |
| 386         | 1985 | 275,000      |
| 486         | 1989 | 1,180,000    |
| Pentium     | 1993 | 3,100,000    |
| Pentium II  | 1997 | 7,500,000    |
| Pentium III | 1999 | 24,000,000   |
| Pentium 4   | 2000 | 42,000,000   |
| Itanium     | 2002 | 220,000,000  |
| Itanium 2   | 2003 | 410,000,000  |



## 5.2.2 Liniarizarea datelor

- parametrii vor fi găsiți folosind liniarizarea modelului (2)
- liniarizarea modelului ne dă

$$\ln y = k + c_2 t.$$

- vom considera că  $t = 0$  corespunde anului 1970
- înlocuind datele în modelul liniarizat, obținem

$$\begin{aligned}k + c_2(1) &= \ln 2250 \\k + c_2(2) &= \ln 2500 \\k + c_2(4) &= \ln 5000 \\k + c_2(8) &= \ln 29000,\end{aligned}\tag{6}$$

și așa mai departe

## 5.2.2 Liniarizarea datelor

- ecuația matricială este  $Ax = b$ , unde  $x = [k, c_2]^T$ ,

$$A = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 4 \\ 1 & 8 \\ \vdots & \vdots \\ 1 & 33 \end{bmatrix}, \quad b = \begin{bmatrix} \ln 2250 \\ \ln 2500 \\ \ln 5000 \\ \ln 29000 \\ \vdots \\ \ln 410000000 \end{bmatrix}. \quad (7)$$


- ecuațiile normale  $A^T Ax = A^T b$  sunt

$$\begin{bmatrix} 13 & 235 \\ 235 & 5927 \end{bmatrix} \begin{bmatrix} k \\ c_2 \end{bmatrix} = \begin{bmatrix} 176.90 \\ 3793.23 \end{bmatrix},$$

care au soluția  $k \approx 7.197$  și  $c_2 \approx 0.3546$ , ceea ce conduce la  $c_1 = e^k \approx 1335.3$

- curba exponențială  $y = 1335.3e^{0.3546t}$  este prezentată în Figura 2 împreună cu datele

## 5.2.2 Liniarizarea datelor



**Figura 2: Graficul semilog al legii lui Moore.** Numărul de tranzistoare dintr-un CPU pe an.

- timpul de dublare pentru această lege este  $\ln 2 / c_2 \approx 1.95$  ani
- Gordon C. Moore, cofondator Intel, a prezis în 1965 că pe parcursul deceniului următor, puterea de procesare se va dubla la fiecare 2 ani
- în mod surprinzător, această rată exponențială a continuat timp de 40 de ani

## 5.2.2 Liniarizarea datelor

- un alt exemplu important cu coeficienți neliniari este modelul **lege de putere**  $y = c_1 t^{c_2}$
- acest model poate fi de asemenea simplificat utilizând liniarizarea, luând logaritmul ambelor părți:

$$\begin{aligned}\ln y &= \ln c_1 + c_2 \ln t \\ &= k + c_2 \ln t.\end{aligned}\tag{8}$$

- înlocuirea datelor în acest model ne va da

$$\begin{aligned}k + c_2 \ln t_1 &= \ln y_1 \\ &\vdots \\ k + c_2 \ln t_m &= \ln y_m,\end{aligned}\tag{9}$$

ceea ce rezultă în forma matricială

$$A = \begin{bmatrix} 1 & \ln t_1 \\ \vdots & \vdots \\ 1 & \ln t_m \end{bmatrix}, \quad b = \begin{bmatrix} \ln y_1 \\ \vdots \\ \ln y_m \end{bmatrix}.\tag{10}$$

- ecuațiile normale permit determinarea lui  $k$  și  $c_2$ , și  $c_1 = e^k$

## 5.2.2 Liniarizarea datelor

### Exemplul 3

- folosiți liniarizarea pentru a interpola dependența greutate–înălțime folosind un model de tip lege de putere
- greutatea și înălțimea medie a copiilor de 2–11 ani sunt date în tabelul de mai jos:


| vârsta (ani) | înălțimea (m) | greutatea (kg) |
|--------------|---------------|----------------|
| 2            | 0.9120        | 13.7           |
| 3            | 0.9860        | 15.9           |
| 4            | 1.0600        | 18.5           |
| 5            | 1.1300        | 21.3           |
| 6            | 1.1900        | 23.5           |
| 7            | 1.2600        | 27.2           |
| 8            | 1.3200        | 32.7           |
| 9            | 1.3800        | 36.0           |
| 10           | 1.4100        | 38.6           |
| 11           | 1.4900        | 43.7           |

- urmând strategia precedentă, legea de putere rezultată pentru greutate versus înălțime este  $W = 16.3H^{2.42}$



## 5.2.2 Liniarizarea datelor

- această relație este reprezentată grafic în Figura 3
- deoarece greutatea este un indicator al volumului, coeficientul  $c_2 \approx 2.42$  poate fi considerat ca fiind „dimensiunea efectivă” a corpului uman



**Figura 3: Legea de putere pentru dependența greutate–înălțime pentru copii de 2–11 ani. Cea mai bună formulă este  $W = 16.3H^{2.42}$ .**

## 5.2.2 Liniarizarea datelor

- concentrația de medicament  $y$  din fluxul sanguin este bine descrisă de modelul

$$y = c_1 t e^{c_2 t} \quad (11)$$

unde  $t$  denotă timpul scurs de la administrarea medicamentului

- caracteristicile modelului sunt date de o creștere rapidă pe măsură ce medicamentul intră în fluxul sanguin, urmată de o ușoară descreștere exponențială
- timpul de înjumătățire** al medicamentului este timpul scurs de când are loc concentrația maximă până când aceasta scade la jumătate din acea valoare
- modelul poate fi liniarizat prin aplicarea logaritmului natural în ambele părți, ceea ce ne dă

$$\begin{aligned} \ln y &= \ln c_1 + \ln t + c_2 t \\ k + c_2 t &= \ln y - \ln t, \end{aligned}$$

unde am notat  $k = \ln c_1$

## 5.2.2 Liniarizarea datelor

- aceasta ne conduce la ecuația matricială  $Ax = b$ , unde

$$A = \begin{bmatrix} 1 & t_1 \\ \vdots & \vdots \\ 1 & t_m \end{bmatrix}, \quad b = \begin{bmatrix} \ln y_1 - \ln t_1 \\ \vdots \\ \ln y_m - \ln t_m \end{bmatrix}. \quad (12)$$

- ecuațiile normale se pot rezolva pentru a găsi  $k$  și  $c_2$ , și  $c_1 = e^k$


### Exemplul 4

- interpolați modelul (11) pentru nivelul măsurat al concentrației medicamentului norfluoxetine din fluxul sanguin al unui pacient, dat în tabelul următor:

| ora | concentrația (ng/ml) |
|-----|----------------------|
| 1   | 8.0                  |
| 2   | 12.3                 |
| 3   | 15.5                 |
| 4   | 16.8                 |
| 5   | 17.1                 |
| 6   | 15.8                 |
| 7   | 15.2                 |
| 8   | 14.0                 |

## 5.2.2 Liniarizarea datelor

- rezolvând ecuațiile normale, obținem  $k \approx 2.28$  și  $c_2 \approx -0.215$ , și  $c_1 \approx e^{2.28} \approx 9.77$
- cea mai bună versiune a modelului este  $y = 9.77te^{-0.215t}$ , reprezentată grafic în Figura 4
- din acest model, ora la care se înregistrează concentrația maximă și timpul de înjumătățire al medicamentului pot fi estimate



**Figura 4: Reprezentarea grafică a concentrației de medicament din fluxul sanguin.** Modelul (11) arată descreșterea exponențială după creșterea inițială.

## 5.2.2 Liniarizarea datelor

- este important să înțelegem că liniarizarea modelului schimbă problema de tip cele mai mici pătrate
- soluția obținută va minimiza REMP-ul pentru problema liniarizată, nu neapărat pentru problema inițială, care în general va avea un set diferit de parametri optimi
- dacă apar în model neliniar, atunci parametrii nu pot fi calculați din ecuațiile normale, și avem nevoie de tehnici neliniare de a rezolva problema de tip cele mai mici pătrate inițială
- acest lucru poate fi făcut folosind metoda Gauss–Newton din Secțiunea 5.4, unde vom discuta din nou problema numărului de mașini existente în lume și vom compara interpolarea realizată de modelul exponențial atât în forma liniarizată, cât și în forma neliniarizată




## 5.3 Factorizarea QR

- în Capitolul 3, factorizarea LU a fost folosită pentru a rezolva ecuații matriciale
- factorizarea este utilă deoarece oferă o reprezentare compactă a pașilor eliminării gaussiene
- în această secțiune, vom dezvolta factorizarea QR ca o modalitate de a rezolva probleme de tip cele mai mici pătrate, care este superioară ecuațiilor normale

## 5.3.1 Ortogonalizarea Gram–Schmidt și cele mai mici pătrate

- metoda Gram–Schmidt ortogonalizează o mulțime de vectori
- dându-se o mulțime de vectori  $m$ -dimensionali, scopul este de a găsi un sistem de coordonate ortogonal pentru subspațiul liniar generat de această mulțime de vectori
- mai precis, dându-se  $n$  vectori liniar independenți, metoda determină  $n$  vectori unitari perpendiculari care generează același subspațiu ca vectorii dați
- lungimea unitară este în funcție de norma euclidiană sau 2-norma, care este folosită în cuprinsul Capitolului 5
- fie  $A_1, \dots, A_n$  vectori liniar independenți din  $\mathbb{R}^m$
- rezultă  $n \leq m$
- metoda Gram–Schmidt începe prin împărțirea lui  $A_1$  la lungimea lui, pentru a-l face vector unitar

## 5.3.1 Ortogonalizarea Gram–Schmidt și cele mai mici pătrate



**Figura 5: Ortogonalizarea Gram–Schmidt.** Vectorii dați sunt  $A_1$  și  $A_2$ , iar ieșirea este mulțimea ortonormală constând din  $q_1$  și  $q_2$ . Al doilea vector ortogonal  $q_2$  este format prin scăderea proiecției lui  $A_2$  în direcția lui  $q_1$  din  $A_2$ , urmată de normalizare.

## 5.3.1 Ortogonalizarea Gram–Schmidt și cele mai mici pătrate

- definim

$$y_1 = A_1 \text{ și } q_1 = \frac{y_1}{\|y_1\|_2}. \quad (13)$$

- pentru a determina al doilea vector unitar, scădem din  $A_2$  proiecția lui  $A_2$  în direcția lui  $q_1$ , și normalizăm rezultatul:

$$y_2 = A_2 - q_1(q_1^T A_2) \text{ și } q_2 = \frac{y_2}{\|y_2\|_2}. \quad (14)$$

- atunci  $q_1^T y_2 = q_1^T (A_2 - q_1(q_1^T A_2)) = q_1^T A_2 - q_1^T A_2 = 0$ , deci  $q_1$  și  $q_2$  sunt ortogonali, după cum se arată în Figura 5
- la pasul  $j$ , definim

$$y_j = A_j - q_1(q_1^T A_j) - q_2(q_2^T A_j) - \cdots - q_{j-1}(q_{j-1}^T A_j) \text{ și } q_j = \frac{y_j}{\|y_j\|_2}. \quad (15)$$

- este clar că  $q_j$  este ortogonal pe fiecare dintre vectorii anteriori  $q_i$  pentru  $i = 1, \dots, j-1$ , deoarece (15) implică

$$\begin{aligned} q_i^T y_j &= q_i^T A_j - q_i^T q_1 q_1^T A_j - \cdots - q_i^T q_{j-1} q_{j-1}^T A_j \\ &= q_i^T A_j - q_i^T q_i q_i^T A_j = 0, \end{aligned}$$

## 5.3.1 Ortogonalizarea Gram–Schmidt și cele mai mici pătrate

- unde, prin ipoteza de inducție, vectorii  $q_i$  sunt ortogonali doi câte doi pentru  $i < j$
- geometric, (15) corespunde scăderii din  $A_j$  a proiecțiilor lui  $A_j$  pe vectorii ortogonali anterior determinați  $q_i$ ,  $i = 1, \dots, j - 1$
- ceea ce rămâne este ortogonal pe vectorii  $q_i$  și, după împărțirea cu lungimea lui pentru a deveni un vector unitar, va fi folosit ca  $q_j$
- prin urmare, mulțimea  $\{q_1, \dots, q_n\}$  constă din vectori ortogonali doi câte doi care generează același subspațiu al lui  $\mathbb{R}^m$  ca  $\{A_1, \dots, A_n\}$
- rezultatul ortogonalizării Gram–Schmidt poate fi scris în formă matricială prin introducerea unei notații noi pentru produsele scalare implicate în calculul de mai sus
- definim  $r_{jj} = \|y_j\|_2$  și  $r_{ij} = q_i^T A_j$
- atunci (13) și (14) pot fi scrise astfel:

$$\begin{aligned} A_1 &= r_{11} q_1 \\ A_2 &= r_{12} q_1 + r_{22} q_2, \end{aligned}$$



## 5.3.1 Ortogonalizarea Gram–Schmidt și cele mai mici pătrate

- și cazul general (15) se traduce în

$$A_j = r_{1j}q_1 + \cdots + r_{j-1,j}q_{j-1} + r_{jj}q_j.$$

- prin urmare, rezultatul ortogonalizării Gram–Schmidt poate fi scris în formă matricială astfel:

$$(A_1 | \cdots | A_n) = (q_1 | \cdots | q_n) \begin{bmatrix} r_{11} & r_{12} & \cdots & r_{1n} \\ & r_{22} & \cdots & r_{2n} \\ & & \ddots & \vdots \\ & & & r_{nn} \end{bmatrix}, \quad (16)$$

sau  $A = QR$ , unde considerăm  $A$  ca fiind matricea constând din coloanele  $A_j$

- vom numi aceasta **factorizarea QR redusă**; versiunea completă va fi detaliată mai jos
- presupunerea că vectorii  $A_j$  sunt liniar independenți garantează faptul că intrările de pe diagonala principală  $r_{jj}$  sunt nenule
- în schimb, dacă  $A_j$  se află în subspațiul generat de  $A_1, \dots, A_{j-1}$ , atunci proiecțiile pe acești din urmă vectori dau însumate tot vectorul  $A_j$ , și  $r_{jj} = \|y_j\|_2 = 0$

## 5.3.1 Ortogonalizarea Gram–Schmidt și cele mai mici pătrate

### Exemplul 5

- găsiți factorizarea QR redusă prin aplicarea ortogonalizării

Gram–Schmidt coloanelor matricii  $A = \begin{bmatrix} 1 & -4 \\ 2 & 3 \\ 2 & 2 \end{bmatrix}$

- luăm  $y_1 = A_1 = \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix}$

- atunci  $r_{11} = \|y_1\|_2 = \sqrt{1^2 + 2^2 + 2^2} = 3$ , și primul vector unitar este

$$q_1 = \frac{y_1}{\|y_1\|_2} = \begin{bmatrix} \frac{1}{3} \\ \frac{2}{3} \\ \frac{2}{3} \end{bmatrix}.$$

## 5.3.1 Ortogonalizarea Gram–Schmidt și cele mai mici pătrate

- pentru a găsi al doilea vector unitar, luăm

$$y_2 = A_2 - q_1 q_1^T A_2 = \begin{bmatrix} -4 \\ 3 \\ 2 \end{bmatrix} - \begin{bmatrix} 1/3 \\ 2/3 \\ 2/3 \end{bmatrix} 2 = \begin{bmatrix} -14/3 \\ 5/3 \\ 2/3 \end{bmatrix}$$

și

$$q_2 = \frac{y_2}{\|y_2\|_2} = \frac{1}{5} \begin{bmatrix} -14/3 \\ 5/3 \\ 2/3 \end{bmatrix} = \begin{bmatrix} -14/15 \\ 1/3 \\ 2/15 \end{bmatrix}.$$

- deoarece  $r_{12} = q_1^T A_2 = 2$  și  $r_{22} = \|y_2\|_2 = 5$ , rezultatul scris în forma matricială (16) este

$$A = \begin{bmatrix} 1 & -4 \\ 2 & 3 \\ 2 & 2 \end{bmatrix} = \begin{bmatrix} 1/3 & -14/15 \\ 2/3 & 1/3 \\ 2/3 & 2/15 \end{bmatrix} \begin{bmatrix} 3 & 2 \\ 0 & 5 \end{bmatrix} = QR.$$

## 5.3.1 Ortogonalizarea Gram–Schmidt și cele mai mici pătrate

- folosim termenul „clasică” pentru această versiune a metodei Gram–Schmidt, deoarece vom da o versiune actualizată, sau „modificată” la sfârșitul acestei secțiuni

### Algoritmul 1 (Ortogonalizarea Gram–Schmidt clasică)

Fie  $A_j, j = 1, \dots, n$  vectori liniar independenți.

```
for  $j = 1, 2, \dots, n$   
     $y = A_j$   
    for  $i = 1, 2, \dots, j - 1$   
         $r_{ij} = q_i^T A_j$   
         $y = y - r_{ij} q_i$   
    end  
     $r_{jj} = \|y\|_2$   
     $q_j = y / r_{jj}$   
end
```

## 5.3.1 Ortogonalizarea Gram–Schmidt și cele mai mici pătrate

- când metoda înregistrează un succes, se obișnuiește să se completeze matricea vectorilor ortogonali unitari pentru a da o bază completă a lui  $\mathbb{R}^m$ , și a obține astfel factorizarea QR „completă”
- acest lucru poate fi făcut, de exemplu, adăugând  $m - n$  vectori suplimentari la  $A_j$ , astfel încât cei  $m$  vectori generează pe  $\mathbb{R}^m$ , și apoi aplicând metoda Gram–Schmidt
- în termenii bazei lui  $\mathbb{R}^m$  formată din  $q_1, \dots, q_m$ , vectorii inițiali pot fi exprimați astfel:

$$(A_1 | \dots | A_n) = (q_1 | \dots | q_m) \begin{bmatrix} r_{11} & r_{12} & \cdots & r_{1n} \\ & r_{22} & \cdots & r_{2n} \\ & & \ddots & \vdots \\ & & & r_{nn} \\ 0 & \cdots & \cdots & 0 \\ \vdots & & & \vdots \\ 0 & \cdots & \cdots & 0 \end{bmatrix}. \quad (17)$$



## 5.3.1 Ortogonalizarea Gram–Schmidt și cele mai mici pătrate

- această ecuație matricială reprezintă **factorizarea QR completă** a matricii  $A = (A_1 | \cdots | A_n)$ , formată din vectorii inițiali
- observăm că dimensiunile matricilor din factorizarea QR completă sunt:  $A$  este de dimensiune  $m \times n$ ,  $Q$  este pătratică de dimensiune  $m \times m$ , și matricea superior triangulară  $R$  are dimensiune  $m \times n$ , aceeași ca matricea  $A$
- matricea  $Q$  din factorizarea QR completă ocupă un loc special în analiza numerică și îi vom da o definiție specială

### Definiția 1

O matrice pătratică  $Q$  este **ortogonală** dacă  $Q^T = Q^{-1}$ .

- observăm că o matrice pătratică este ortogonală dacă și numai dacă are coloanele reprezentate prin vectori ortogonali unitari
- prin urmare, factorizarea QR completă este ecuația  $A = QR$ , unde  $Q$  este o matrice pătratică ortogonală și  $R$  este o matrice superior triangulară care are aceeași dimensiune cu  $A$

## 5.3.1 Ortogonalizarea Gram–Schmidt și cele mai mici pătrate

- proprietatea de bază a unei matrici ortogonale este că păstrează norma euclidiană a unui vector

### Lema 1

Dacă  $Q$  este o matrice ortogonală  $m \times m$  și  $x$  este un vector  $m$ -dimensional, atunci  $\|Qx\|_2 = \|x\|_2$ .

- $\|Qx\|_2^2 = (Qx)^T Qx = x^T Q^T Qx = x^T x = \|x\|_2^2$
- produsul a două matrici ortogonale  $m \times m$  este tot o matrice ortogonală
- factorizarea QR a unei matrici  $m \times m$  folosind metoda Gram–Schmidt necesită aproximativ  $m^3$  înmulțiri/împărțiri, de trei ori mai multe decât factorizarea LU, plus încă la fel de multe adunări

## 5.3.1 Ortogonalizarea Gram–Schmidt și cele mai mici pătrate

### Exemplul 6

- găsiți factorizarea QR completă a matricii  $A = \begin{bmatrix} 1 & -4 \\ 2 & 3 \\ 2 & 2 \end{bmatrix}$
  - în Exemplul 5, am găsit vectorii ortogonali unitari  $q_1 = \begin{bmatrix} \frac{1}{\sqrt{3}} \\ \frac{2}{\sqrt{3}} \\ \frac{2}{\sqrt{3}} \end{bmatrix}$  și
- $$q_2 = \begin{bmatrix} -\frac{14}{15} \\ \frac{1}{3} \\ \frac{2}{15} \end{bmatrix}$$

## 5.3.1 Ortogonalizarea Gram–Schmidt și cele mai mici pătrate

- adăugând un al treilea vector  $A_3 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}$ , avem că

$$\begin{aligned} y_3 &= A_3 - q_1 q_1^T A_3 - q_2 q_2^T A_3 \\ &= \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} - \begin{bmatrix} \frac{1}{3} \\ \frac{2}{3} \\ \frac{2}{3} \end{bmatrix} \frac{1}{3} - \begin{bmatrix} -\frac{14}{15} \\ \frac{1}{3} \\ \frac{2}{15} \end{bmatrix} \left(-\frac{14}{15}\right) = \frac{2}{225} \begin{bmatrix} 2 \\ 10 \\ -11 \end{bmatrix}, \end{aligned}$$

$$\text{și } q_3 = y_3 / \|y_3\| = \begin{bmatrix} \frac{2}{15} \\ \frac{10}{15} \\ -\frac{11}{15} \end{bmatrix}$$

- punând cele trei părți împreună, obținem factorizarea QR completă

$$A = \begin{bmatrix} 1 & -4 \\ 2 & 3 \\ 2 & 2 \end{bmatrix} = \begin{bmatrix} 1/3 & -14/15 & 2/15 \\ 2/3 & 1/3 & 2/3 \\ 2/3 & 2/15 & -11/15 \end{bmatrix} \begin{bmatrix} 3 & 2 \\ 0 & 5 \\ 0 & 0 \end{bmatrix} = QR.$$

## 5.3.1 Ortogonalizarea Gram–Schmidt și cele mai mici pătrate

- observăm că alegerea lui  $A_3$  a fost arbitrară
  - orice al treilea vector coloană liniar independent față de primii doi vectori coloană poate fi folosit
  - comparăm acest rezultat cu factorizarea QR redusă din Exemplul 5
- 
- există trei aplicații importante ale factorizării QR
  - vom descrie două dintre ele aici; a treia este algoritmul QR pentru calculul valorilor proprii, introdus în Capitolul 10
  - în primul rând, factorizarea QR poate fi folosită pentru a rezolva un sistem de  $n$  ecuații cu  $n$  necunoscute  $Ax = b$
  - factorizăm  $A = QR$ , și ecuația  $Ax = b$  devine  $QRx = b$  și  $Rx = Q^T b$
  - presupunând că  $A$  este nesingulară, intrările diagonale ale matricii superior triangulare  $R$  sunt nenule, astfel că  $R$  este nesingulară
  - o substituție înapoi triangulară ne dă soluția  $x$
  - cum am menționat anterior, această abordare este de aproximativ trei ori mai costisitoare computațional față de abordarea LU
  - a doua aplicație este pentru metoda celor mai mici pătrate



## 5.3.1 Ortogonalizarea Gram–Schmidt și cele mai mici pătrate

- fie  $A$  o matrice  $m \times n$  cu  $m \geq n$
- pentru a minimiza  $\|Ax - b\|_2$ , o rescriem sub forma  $\|QRx - b\|_2 = \|Rx - Q^T b\|_2$  folosind Lema 1
- vectorul din norma euclidiană este

$$\begin{bmatrix} e_1 \\ \vdots \\ e_n \\ e_{n+1} \\ \vdots \\ e_m \end{bmatrix} = \begin{bmatrix} r_{11} & r_{12} & \cdots & r_{1n} \\ & r_{22} & \cdots & r_{2n} \\ & & \ddots & \vdots \\ & & & r_{nn} \\ 0 & \cdots & \cdots & 0 \\ \vdots & & & \vdots \\ 0 & \cdots & \cdots & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} - \begin{bmatrix} d_1 \\ \vdots \\ d_n \\ d_{n+1} \\ \vdots \\ d_m \end{bmatrix}, \quad (18)$$

unde  $d = Q^T b$

- presupunem că  $r_{ii} \neq 0$
- atunci partea superioară  $(e_1, \dots, e_n)$  a vectorului de eroare  $e$  poate fi făcută zero prin substituție înapoi

## 5.3.1 Ortogonalizarea Gram–Schmidt și cele mai mici pătrate

- alegerea valorilor  $x_i$  nu schimbă cu nimic partea inferioară a vectorului de eroare; evident,  $(e_{n+1}, \dots, e_m) = (-d_{n+1}, \dots, -d_m)$
- prin urmare, soluția în sensul celor mai mici pătrate este minimizată folosind vectorul  $x$  obținut din substituția înapoi a părții superioare, și eroarea în sensul celor mai mici pătrate este  $\|e\|_2^2 = d_{n+1}^2 + \dots + d_m^2$

### Algoritmul 2 (Cele mai mici pătrate folosind factorizarea QR)

Dându-se sistemul inconsistent  $m \times n$   $Ax = b$ , găsim factorizarea QR completă  $A = QR$  și luăm

$\hat{R}$  = submatricea  $n \times n$  superioară a lui  $R$

$\hat{d}$  = primele  $n$  intrări superioare ale lui  $d = Q^T b$ .

Rezolvăm  $\hat{R}\bar{x} = \hat{d}$  pentru a găsi soluția în sensul celor mai mici pătrate  $\bar{x}$ .

## 5.3.1 Ortogonalizarea Gram–Schmidt și cele mai mici pătrate

### Exemplul 7

- folosiți factorizarea QR completă pentru a rezolva problema de tip cele mai mici pătrate  $\begin{bmatrix} 1 & -4 \\ 2 & 3 \\ 2 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} -3 \\ 15 \\ 9 \end{bmatrix}$
- trebuie să rezolvăm  $Rx = Q^T b$ , sau

$$\begin{bmatrix} 3 & 2 \\ 0 & 5 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \frac{1}{15} \begin{bmatrix} 5 & 10 & 10 \\ -14 & 5 & 2 \\ 2 & 10 & -11 \end{bmatrix} \begin{bmatrix} -3 \\ 15 \\ 9 \end{bmatrix} = \begin{bmatrix} 15 \\ 9 \\ 3 \end{bmatrix}.$$

- eroarea în sensul celor mai mici pătrate va fi  $\|e\|_2 = \|(0, 0, 3)\|_2 = 3$
- egalizând părțile superioare, obținem

$$\begin{bmatrix} 3 & 2 \\ 0 & 5 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 15 \\ 9 \end{bmatrix},$$

a cărei soluție este  $\bar{x}_1 = 3.8$ ,  $\bar{x}_2 = 1.8$

## 5.4 Cele mai mici pătrate neliniare

- soluția în sensul celor mai mici pătrate a sistemului liniar de ecuații  $Ax = b$  minimizează norma euclidiană a rezidualului  $\|Ax - b\|_2$
- am învățat două metode de a găsi soluția  $x$ , una bazată pe ecuațiile normale și alta bazată pe factorizarea QR
- niciuna dintre cele două metode nu poate fi aplicată dacă ecuațiile sunt neliniare
- în această secțiune, vom dezvolta metoda Gauss–Newton de rezolvare a problemelor neliniare de tip cele mai mici pătrate
- în plus față de ilustrarea utilizării acestei metode pentru a rezolva probleme de tip intersecție de cercuri, vom aplica metoda Gauss–Newton pentru a interpola datele folosind modele cu coeficienți neliniari

## 5.4.1 Metoda Gauss–Newton

- considerăm sistemul de  $m$  ecuații cu  $n$  necunoscute

$$\begin{aligned} r_1(x_1, \dots, x_n) &= 0 \\ &\vdots \\ r_m(x_1, \dots, x_n) &= 0. \end{aligned} \tag{19}$$

- suma pătratelor erorilor este reprezentată de funcția

$$E(x_1, \dots, x_n) = \frac{1}{2}(r_1^2 + \dots + r_m^2) = \frac{1}{2}r^T r,$$

unde  $r = [r_1, \dots, r_m]^T$

- constanta  $1/2$  a fost inclusă în definiție pentru a simplifica formulele deduse ulterior
- pentru a minimiza  $E$ , facem gradientul  $F(x) = \nabla E(x)$  egal zero:

$$0 = F(x) = \nabla E(x) = \nabla \left( \frac{1}{2} r(x)^T r(x) \right) = r(x)^T Dr(x). \tag{20}$$

- observăm că am folosit regula produsului scalar pentru gradient
- reamintim metoda lui Newton pentru mai multe variabile, și o aplicăm funcției  $F(x)^T = (r^T Dr)^T = (Dr)^T r$  privită ca vector coloană



## 5.4.1 Metoda Gauss–Newton

- regula produsului matrice/vector poate fi aplicată pentru a da

$$DF(x)^T = D((Dr)^T r) = (Dr)^T \cdot Dr + \sum_{i=1}^m r_i Dc_i,$$

unde  $c_i$  este a  $i$ -a coloană a lui  $Dr$

- observăm că  $Dc_i = H_{r_i}$ , matricea derivatelor parțiale secunde, sau **hessiana** lui  $r_i$ :

$$H_{r_i} = \begin{bmatrix} \frac{\partial^2 r_i}{\partial x_1 \partial x_1} & \cdots & \frac{\partial^2 r_i}{\partial x_1 \partial x_n} \\ \vdots & & \vdots \\ \frac{\partial^2 r_i}{\partial x_n \partial x_1} & \cdots & \frac{\partial^2 r_i}{\partial x_n \partial x_n} \end{bmatrix}.$$

- aplicarea metodei lui Newton poate fi simplificată prin renunțarea la anumiți termeni
- renunțând la suma de  $m$  termeni de mai sus, obținem următorul algoritm:

## 5.4.1 Metoda Gauss–Newton

### Algoritmul 3 (Metoda Gauss–Newton)

Pentru a minimiza  $r_1(x)^2 + \dots + r_m(x)^2$ .

Luăm  $x^0$  = vectorul inițial.

**for**  $k = 0, 1, 2, \dots$

$$A = Dr(x^k) \quad (21)$$

$$A^T A v^k = -A^T r(x^k)$$

$$x^{k+1} = x^k + v^k \quad (22)$$

**end**

- observăm că fiecare pas al metodei Gauss–Newton este o reminiscență a ecuațiilor normale, în care matricea coeficienților a fost înlocuită cu  $Dr$
- metoda Gauss–Newton poate fi rezolvată pentru a găsi o rădăcină a gradientului erorii pătratice
- deși gradientul trebuie să fie zero într-un punct de minim, invers nu este adevărat, deci este posibil ca metoda să convergă către un punct de maxim sau către un punct șa
- trebuie să fim atenți când interpretăm rezultatul algoritmului

## 5.4.1 Metoda Gauss–Newton

- următoarele trei exemple ilustrează folosirea metodei Gauss-Newton, precum și metoda lui Newton pentru mai multe variabile din Capitolul 3
- două cercuri care se intersectează, se pot intersecta în unul sau două puncte, dacă nu cumva cercurile coincid
- trei cercuri din plan, însă, nu au puncte comune de intersecție
- într-un astfel de caz, căutăm punctul din plan care este cel mai aproape de fi punctul de intersecție în sensul celor mai mici pătrate
- pentru trei cercuri, aceasta presupune trei ecuații neliniare cu două necunoscute  $x, y$
- Exemplul 8 arată cum metoda Gauss-Newton rezolvă această problemă neliniară de tip cele mai mici pătrate
- Exemplul 9 definește cel mai bun punct într-un alt mod: punctul unic de intersecție al celor 3 cercuri se obține permițând ca razele lor să fie schimbate cu o valoare comună  $K$
- aceasta ne dă o problemă cu trei ecuații cu trei necunoscute  $x, y, K$ , nu o problemă de tip cele mai mici pătrate, care poate fi rezolvată folosind metoda lui Newton pentru mai multe variabile
- în fine, Exemplul 10 adaugă un al patrulea cerc

## 5.4.1 Metoda Gauss–Newton


- soluția celor patru ecuații cu trei necunoscute  $x, y, K$  este din nou o problemă de tip cele mai mici pătrate care poate fi rezolvată folosind metoda Gauss-Newton

### Exemplul 8

- considerăm trei cercuri în plan care au centrele  $(x_1, y_1) = (-1, 0)$ ,  $(x_2, y_2) = (1, 1/2)$ ,  $(x_3, y_3) = (1, -1/2)$  și, respectiv, razele  $R_1 = 1$ ,  $R_2 = 1/2$ ,  $R_3 = 1/2$
- folosiți metoda Gauss–Newton pentru a găsi punctul pentru care suma pătratelor distanțelor până la cele trei cercuri este minimizată
- cercurile sunt prezentate în Figura 6(a)



## 5.4.1 Metoda Gauss–Newton



**Figura 6: Puncte de intersecție a trei cercuri.** (a) Punctul de intersecție în sensul celor mai mici pătrate, găsit folosind metoda Gauss–Newton. (b) Mărind razele cu o valoare comună ne dă un tip diferit de punct de intersecție folosind metoda lui Newton pentru mai multe variabile. (c) Cele patru cercuri din Exemplul 10 cu punctul de tip cele mai mici pătrate găsit folosind metoda Gauss–Newton.



## 5.4.1 Metoda Gauss–Newton

- punctul  $(x, y)$  care trebuie găsit, minimizează suma pătratelor erorilor reziduale:

$$r_1(x, y) = \sqrt{(x - x_1)^2 + (y - y_1)^2} - R_1$$

$$r_2(x, y) = \sqrt{(x - x_2)^2 + (y - y_2)^2} - R_2$$

$$r_3(x, y) = \sqrt{(x - x_3)^2 + (y - y_3)^2} - R_3.$$

- aceasta rezultă din faptul că distanța de la un punct  $(x, y)$  la un cerc cu centrul  $(x_1, y_1)$  și raza  $R_1$  este  $|\sqrt{(x - x_1)^2 + (y - y_1)^2} - R_1|$
- jacobianul lui  $r(x, y)$  este

$$Dr(x, y) = \begin{bmatrix} \frac{x-x_1}{S_1} & \frac{y-y_1}{S_1} \\ \frac{x-x_2}{S_2} & \frac{y-y_2}{S_2} \\ \frac{x-x_3}{S_3} & \frac{y-y_3}{S_3} \end{bmatrix},$$

unde  $S_i = \sqrt{(x - x_i)^2 + (y - y_i)^2}$  pentru  $i = 1, 2, 3$

- iterația Gauss–Newton cu vectorul inițial  $(x^0, y^0) = (0, 0)$  converge la  $(\bar{x}, \bar{y}) = (0.412891, 0)$  cu șase zecimale exacte după șapte pași

## 5.4.1 Metoda Gauss–Newton

- o altă problemă pentru trei cercuri ne dă un tip diferit de răspuns
- în loc să căutăm puncte care seamănă cel mai mult cu puncte de intersecție, putem expanda (sau contracta) razele cercurilor cu o valoare comună până când cercurile au un punct de intersecție comun
- aceasta este echivalent cu rezolvarea sistemului

$$\begin{aligned}r_1(x, y, K) &= \sqrt{(x - x_1)^2 + (y - y_1)^2} - (R_1 + K) = 0 \\r_2(x, y, K) &= \sqrt{(x - x_2)^2 + (y - y_2)^2} - (R_2 + K) = 0 \\r_3(x, y, K) &= \sqrt{(x - x_3)^2 + (y - y_3)^2} - (R_3 + K) = 0.\end{aligned}\quad (23)$$

- punctul  $(x, y)$  identificat în acest mod este în general diferit de soluția de tip cele mai mici pătrate din Exemplul 8

## 5.4.1 Metoda Gauss–Newton

### Exemplul 9

- rezolvați sistemul (23) pentru a găsi  $(x, y, K)$ , folosind cercurile din Exemplul 8
- sistemul constă din trei ecuații neliniare cu trei necunoscute, ceea ce înseamnă că poate fi rezolvat folosind metoda lui Newton pentru mai multe variabile
- jacobianul este

$$Dr(x, y, K) = \begin{bmatrix} \frac{x-x_1}{S_1} & \frac{y-y_1}{S_1} & -1 \\ \frac{x-x_2}{S_2} & \frac{y-y_2}{S_2} & -1 \\ \frac{x-x_3}{S_3} & \frac{y-y_3}{S_3} & -1 \end{bmatrix}.$$

- metoda lui Newton ne dă soluția  $(x, y, K) = (1/3, 0, 1/3)$  în trei pași
- punctul de intersecție  $(1/3, 0)$  și cele trei cercuri cu razele expandate cu  $K = 1/3$  apar în Figura 6(b)
- Exemplele 8 și 9 prezintă două puncte de vedere diferite asupra sensului „punctului de intersecție” al unui grup de cercuri

## 5.4.1 Metoda Gauss–Newton

- Exemplul 10 combină cele două abordări diferite

### Exemplul 10

- considerăm patru cercuri cu centrele  $(-1, 0)$ ,  $(1, 1/2)$ ,  $(1, -1/2)$ ,  $(0, 1)$  și, respectiv, razele  $1$ ,  $1/2$ ,  $1/2$ ,  $1/2$
- găsiți punctul  $(x, y)$  și constanta  $K$  pentru care suma pătratelor distanțelor de la punct la cele patru cercuri cu razele mărite cu valoarea  $K$  (deci, cu razele respectiv  $1 + K$ ,  $1/2 + K$ ,  $1/2 + K$ ,  $1/2 + K$ ) este minimizată
- aceasta este o simplă combinație a celor două exemple anterioare
- sunt patru ecuații cu trei necunoscute  $x$ ,  $y$ ,  $K$

## 5.4.1 Metoda Gauss–Newton

- rezidualul în sensul celor mai mici pătrate este asemănător cu (23), dar cu patru termeni, iar jacobianul este

$$Dr(x, y, K) = \begin{bmatrix} \frac{x-x_1}{S_1} & \frac{y-y_1}{S_1} & -1 \\ \frac{x-x_2}{S_2} & \frac{y-y_2}{S_2} & -1 \\ \frac{x-x_3}{S_3} & \frac{y-y_3}{S_3} & -1 \\ \frac{x-x_4}{S_4} & \frac{y-y_4}{S_4} & -1 \end{bmatrix}.$$

- metoda Gauss–Newton ne dă soluția  $(\bar{x}, \bar{y}) = (0.311385, 0.112268)$  cu  $\bar{K} = 0.367164$ , prezentată în Figura 6(c)
- analogul Exemplului 10 pentru sfere în trei dimensiuni reprezintă fundamentul matematic al Global Positioning System (GPS)



## 5.4.2 Modele cu parametri neliniari

- o aplicație importantă a metodei Gauss–Newton este de a interpola modele cu coeficienți neliniari
- fie  $(t_1, y_1), \dots, (t_m, y_m)$  punctele de interpolare și  $y = f_c(x)$  funcția care urmează să fie interpolată, unde  $c = [c_1, \dots, c_p]^T$  este un set de parametri care va fi ales pentru a minimiza suma pătratelor rezidualelor

$$\begin{aligned} r_1(c) &= f_c(t_1) - y_1 \\ &\vdots \\ r_m(c) &= f_c(t_m) - y_m. \end{aligned}$$

- cazul particular (19) apare destul de des pentru a fi tratat separat aici
- dacă parametrii  $c_1, \dots, c_p$  apar în model liniar, atunci aceste ecuații liniare cu necunoscutele  $c_i$ , și ecuațiile normale sau soluția folosind factorizarea QR, ne dau alegerea optimă a parametrilor  $c$
- dacă parametrii  $c_i$  apar neliniar în model, același tratament rezultă într-un sistem de ecuații care este neliniar în necunoscutele  $c_i$

## 5.4.2 Modele cu parametri neliniari

- de exemplu, interpolând modelul  $y = c_1 t^{c_2}$  pentru punctele  $(t_i, y_i)$ , obținem ecuațiile neliniare

$$\begin{aligned}y_1 &= c_1 t_1^{c_2} \\y_2 &= c_1 t_2^{c_2} \\&\vdots \\y_m &= c_1 t_m^{c_2}.\end{aligned}$$

- deoarece  $c_2$  apare neliniar în acest model, sistemul de ecuații nu poate fi pus în formă matricială
- în Secțiunea 5.2, am tratat această dificultate schimbând problema: am „liniarizat modelul” luând logaritmul ambelor părți ale modelului și am minimizat eroarea în aceste coordonate transformate folosind cele mai mici pătrate
- în cazurile în care coordonatele transformate sunt într-adevăr coordonatele potrivite în care să minimizăm eroarea, acest lucru este adecvat
- pentru a rezolva problema de tip cele mai mici pătrate inițială, însă, apelăm la metoda Gauss–Newton

## 5.4.2 Modele cu parametri neliniari

- aceasta este folosită pentru a minimiza funcția de eroare  $E$  ca funcție de vectorul de parametri  $c$
- matricea  $Dr$  este matricea derivatelor parțiale ale erorilor  $r_i$  în funcție de parametrii  $c_j$ , care sunt

$$(Dr)_{ij} = \frac{\partial r_i}{\partial c_j} = f_{c_j}(t_i).$$

- cu această informație, metoda Gauss–Newton (21) poate fi implementată

### Exemplul 11

- folosiți metoda Gauss–Newton pentru a interpola datele privind numărul total de mașini existente în lume din Exemplul 1 folosind un model exponențial (neliniarizat)
- găsirea celei mai bune interpolări de tip cele mai mici pătrate pentru date folosind un model exponențial înseamnă găsirea acelor  $c_1, c_2$  care minimizează REMP-ul pentru erorile  $r_i = c_1 e^{c_2 t_i} - y_i, i = 1, \dots, m$
- folosind liniarizarea modelului din secțiunea anterioară, am minimizat REMP-ul pentru erorile modelului logaritm  $\ln y_i - (\ln c_1 + c_2 t_i)$

## 5.4.2 Modele cu parametri neliniari

- valorile parametrilor  $c_i$  care minimizează REMP-ul în cele două sensuri diferite sunt diferite în general
- pentru a calcula cel mai bun model în sensul celor mai mici pătrate folosind metoda Gauss–Newton, definim

$$r = \begin{bmatrix} c_1 e^{c_2 t_1} - y_1 \\ \vdots \\ c_1 e^{c_2 t_m} - y_m \end{bmatrix},$$

și luăm derivatele în funcție de parametrii  $c_1$  și  $c_2$  pentru a obține

$$Dr = \begin{bmatrix} e^{c_2 t_1} & c_1 t_1 e^{c_2 t_1} \\ \vdots & \vdots \\ e^{c_2 t_m} & c_1 t_m e^{c_2 t_m} \end{bmatrix}.$$

- acest model este interpolat pentru numărul total de mașini existente în lume, unde  $t$  este măsurat în ani scurși din 1970, și mașinile în milioane



## 5.4.2 Modele cu parametri neliniari

- cinci pași din metoda Gauss–Newton (21) pornind de la valoarea inițială  $(c_1, c_2) = (50, 0.1)$  ne dau  $(c_1, c_2) \approx (58.51, 0.05772)$  cu patru zecimale exacte
- cel mai bun model exponențial în sensul celor mai mici pătrate pentru aceste date este

$$y = 58.51e^{0.05772t}. \quad (24)$$

- valoarea REMP-ului este 7.68, ceea ce reprezintă eroarea medie de modelare, în sensul celor mai mici pătrate, de 7.68 milioane de mașini (a se vedea Figura 7)
- cel mai bun model (24) poate fi comparat cu cel mai bun model exponențial liniarizat


$$y = 54.03e^{0.06152t}$$

calculat în Exemplul 1

- acesta a fost obținut din ecuațiile normale aplicate modelului liniarizat  $\ln y = \ln c_1 + c_2 t$
- valoarea REMP-ului pentru erorile  $r_i$  ale modelului liniarizat este 9.56, mai mare decât REMP-ul din (24), după cum era de așteptat



## 5.4.2 Modele cu parametri neliniari



**Figura 7: Interpolarea exponențială a numărului total de mașini existente în lume, fără a folosi liniarizarea.** Cel mai bun model în sensul celor mai mici pătrate este  $y = 58.51e^{0.05772t}$ .

## 5.4.2 Modele cu parametri neliniari

- totuși, modelul liniarizat minimizează REMP-ul pentru erorile  $\ln y_i - (\ln c_1 + c_2 t_i)$ , dând o valoare de 0.0357, mai mică decât valoarea corespunzătoare 0.0568 pentru modelul (24), tot după cum era de așteptat
- fiecare dintre modele este interpolarea optimă în spațiul de date corespunzător
- morala este că există algoritmi computaționali pentru rezolvarea oricăreia dintre probleme
- minimizarea valorilor  $r_i$  este problema de tip cele mai mici pătrate standard, dar utilizatorul trebuie să decidă pe baza contextului datelor dacă este mai potrivit să minimizeze erori sau erori logaritmice

## 5.4.3 Metoda Levenberg–Marquardt

- metoda Levenberg–Marquardt poate fi considerată ca o combinație între metoda Gauss–Newton și metoda gradientului, care va fi introdusă pentru probleme generale de optimizare în Capitolul 11
- algoritmul este o simplă modificare a metodei Gauss–Newton

### Algoritmul 4 (Metoda Levenberg–Marquardt)

Pentru a minimiza  $r_1(x)^2 + \dots + r_m(x)^2$ .

Luăm  $x^0$  = vectorul inițial,  $\lambda$  = constantă.

**for**  $k = 0, 1, 2, \dots$

$$A = Dr(x^k)$$

$$(A^T A + \lambda \text{diag}(A^T A))v^k = -A^T r(x^k)$$

$$x^{k+1} = x^k + v^k$$

**end**

- cazul  $\lambda = 0$  este identic cu metoda Gauss–Newton
- creșterea parametrului  $\lambda$  accentuează efectul diagonalei matricii  $A^T A$ , și, în general, face ca metoda să convergă pornind de la o mulțime mai mare de vectori inițiali  $x^0$  decât metoda Gauss–Newton

## 5.4.3 Metoda Levenberg–Marquardt

### Exemplul 12


- folosiți metoda Levenberg–Marquardt pentru a interpola modelul  $y = c_1 e^{-c_2(t-c_3)^2}$  pentru punctele  $(t_i, y_i) = \{(1, 3), (2, 5), (2, 7), (3, 5), (4, 1)\}$
- trebuie să găsim acei  $c_1, c_2, c_3$  care minimizează REMP-ul vectorului de eroare

$$r = \begin{bmatrix} c_1 e^{-c_2(t_1-c_3)^2} - y_1 \\ \vdots \\ c_1 e^{-c_2(t_5-c_3)^2} - y_5 \end{bmatrix}.$$

- derivata lui  $r$  evaluată în cele cinci puncte este matricea  $5 \times 3$

$$Dr = \begin{bmatrix} e^{-c_2(t_1-c_3)^2} & -c_1(t_1-c_3)^2 e^{-c_2(t_1-c_3)^2} & 2c_1 c_2(t_1-c_3) e^{-c_2(t_1-c_3)^2} \\ \vdots & \vdots & \vdots \\ e^{-c_2(t_5-c_3)^2} & -c_1(t_5-c_3)^2 e^{-c_2(t_5-c_3)^2} & 2c_1 c_2(t_5-c_3) e^{-c_2(t_5-c_3)^2} \end{bmatrix}.$$

## 5.4.3 Metoda Levenberg–Marquardt



**Figura 8: Modelul de interpolare din Exemplul 12.** Metoda Levenberg–Marquardt este folosită pentru a găsi cel mai bun model în sensul celor mai mici pătrate  $y = 6.301e^{-0.5088(t-2.249)^2}$ , care este reprezentat grafic sub forma curbei continue.



## 5.4.3 Metoda Levenberg–Marquardt

- metoda Levenberg–Marquardt cu vectorul inițial  $(c_1, c_2, c_3) = (1, 1, 1)$  și  $\lambda$  fixat la valoarea 50 converge către cel mai bun model în sensul celor mai mici pătrate  $y = 6.301 e^{-0.5088(t-2.249)^2}$
- cel mai bun model este reprezentat grafic împreună cu punctele de interpolare în Figura 8
- metoda Gauss–Newton corespunzătoare diverge la infinit pornind de la acest vector inițial

Vă mulțumesc!