

Matematici Asistate de Calculator

Prof. Dr. Călin-Adrian POPA

Cursul 13

5 Mai 2026

9.4 TCD Modificată și compresia audio

- ne întoarcem la problema semnalelor uni-dimensionale și discutăm abordări de ultimă oră pentru compresia audio
- deși s-ar putea crede că o dimensiune este mai ușor de abordat decât două, provocarea este că sistemul auditiv uman este foarte sensibil în domeniul frecvență, și „artefactele” nedorite introduse prin compresie și decompresie sunt detectate mai ușor
- din acest motiv, este obișnuit ca metodele de compresie a sunetului să folosească trucuri sofisticate menite să ascundă faptul că a avut loc compresia
- prima dată, vom introduce TCD4, o nouă versiune a Transformatei Cosinus Discrete, și așa-numita Transformată Cosinus Discretă Modificată (TCDM)
- TCDM este reprezentată printr-o matrice care nu este pătratică și astfel, spre deosebire de TCD și TCD4, nu este inversabilă
- totuși, când este aplicată pentru ferestre de timp suprapuse, poate fi folosită pentru a reconstrui complet fluxul de date inițial
- poate fi combinată cu cuantizarea pentru a efectua compresia cu pierdere de informații cu o degradare minimală a calității sunetului
- TCDM stă la baza majorității formatelor curente de compresie audio, cum ar fi MP3, AAC, și WMA

9.4.1 Transformata Cosinus Discretă Modificată

- începem cu o formă ușor diferită a TCD introdusă mai devreme
- există patru versiuni diferite ale TCD care sunt folosite de obicei—noi am folosit versiunea TCD1 pentru compresia imaginilor în secțiunea precedentă
- versiunea TCD4 este cea mai populară pentru compresia audio

Definiția 1

Transformata Cosinus Discretă (versiunea 4) (TCD4) a lui $x = [x_0, \dots, x_{n-1}]^T$ este vectorul n -dimensional

$$y = Ex,$$

unde E este matricea $n \times n$

$$E_{ij} = \sqrt{\frac{2}{n}} \cos \frac{(i + \frac{1}{2})(j + \frac{1}{2})\pi}{n}. \quad (1)$$

- ca în cazul TCD1, matricea E din TCD4 este o matrice reală ortogonală: este pătratică și coloanele ei sunt vectori unitari ortogonali doi câte doi

9.4.1 Transformata Cosinus Discretă Modificată

- de fapt, coloanele lui E sunt vectorii proprii unitari ai matricii reale simetrice $n \times n$

$$\begin{bmatrix} 1 & -1 & & & \\ -1 & 2 & -1 & & \\ & -1 & 2 & -1 & \\ & & \ddots & \ddots & \ddots \\ & & & -1 & 2 & -1 \\ & & & & -1 & 3 \end{bmatrix}. \quad (2)$$

- în continuare, observăm două fapte importante despre coloanele matricii TCD4
- presupunem n ca fiind fixat, și considerăm nu doar cele n coloane din TCD4, ci vectorii coloană definiți de (1) pentru orice întreg pozitiv sau negativ j

Lema 1

Notăm prin c_j coloana j a matricii TCD4 (extinse) (1). Atunci (a) $c_j = c_{-1-j}$ pentru orice întreg j (coloanele sunt simetrice în jurul lui $j = -\frac{1}{2}$), și (b) $c_j = -c_{2n-1-j}$ pentru orice întreg j (coloanele sunt antisimetrice în jurul lui $j = n - \frac{1}{2}$).

9.4.1 Transformata Cosinus Discretă Modificată

- pentru a demonstra partea (a) a lemei, scriem $j = -\frac{1}{2} + (j + \frac{1}{2})$ și $-1 - j = -j + \frac{1}{2} - (j + \frac{1}{2})$
- folosind ecuația (1), obținem

$$\begin{aligned}c_j &= c_{-\frac{1}{2}+(j+\frac{1}{2})} = \sqrt{\frac{2}{n}} \cos \frac{(i+\frac{1}{2})(j+\frac{1}{2})\pi}{n} = \sqrt{\frac{2}{n}} \cos \frac{(i+\frac{1}{2})(-j-\frac{1}{2})\pi}{n} \\ &= c_{-\frac{1}{2}-(j+\frac{1}{2})} = c_{-1-j}\end{aligned}$$

pentru $i = 0, \dots, n-1$

- pentru a demonstra (b), luăm $r = n - \frac{1}{2} - j$; atunci $j = n - \frac{1}{2} - r$ și $2n - 1 - j = n - \frac{1}{2} + r$, și trebuie să arătăm că $c_{n-\frac{1}{2}-r} + c_{n-\frac{1}{2}+r} = 0$
- din formula pentru adunarea unghiurilor la cosinus, avem

$$\begin{aligned}c_{n-\frac{1}{2}-r} &= \sqrt{\frac{2}{n}} \cos \frac{(2i+1)(n-r)\pi}{2n} \\ &= \sqrt{\frac{2}{n}} \cos \frac{2i+1}{2}\pi \cos \frac{(2i+1)r\pi}{2n} + \sqrt{\frac{2}{n}} \sin \frac{2i+1}{2}\pi \sin \frac{(2i+1)r\pi}{2n} \\ c_{n-\frac{1}{2}+r} &= \sqrt{\frac{2}{n}} \cos \frac{(2i+1)(n+r)\pi}{2n} \\ &= \sqrt{\frac{2}{n}} \cos \frac{2i+1}{2}\pi \cos \frac{(2i+1)r\pi}{2n} - \sqrt{\frac{2}{n}} \sin \frac{2i+1}{2}\pi \sin \frac{(2i+1)r\pi}{2n}\end{aligned}$$

9.4.1 Transformata Cosinus Discretă Modificată

pentru $i = 0, \dots, n-1$

- deoarece $\cos \frac{1}{2}(2i+1)\pi = 0$ pentru orice întreg i , suma $c_{n-\frac{1}{2}-r} + c_{n-\frac{1}{2}+r} = 0$, ceea ce trebuia să arătăm



Figura 1: Ilustrarea Lemei 1. Coloanele $c_0, \dots, c_{n-1}$ formează matricea $n \times n$ TCD4. Pentru întregii j din afara acestui interval, coloana definită de către c_j din ecuația (1) corespunde uneia dintre cele n coloane ale lui TCD4, prezentată direct sub ea în figură. Aceasta ilustrează Lema 1.

- vom folosi matricea TCD4 E pentru a construi Transformata Cosinus Discretă Modificată
- presupunem că n este par
- vom crea o nouă matrice, folosind coloanele $c_{\frac{n}{2}}, \dots, c_{\frac{5}{2}n-1}$

9.4.1 Transformata Cosinus Discretă Modificată

- Lema 1 arată că pentru orice întreg j , coloana c_j poate fi exprimată ca una dintre coloanele lui TCD4—și anume, una dintre coloanele c_j pentru $0 \leq i \leq n-1$, după cum se arată în Figura 1, până la o posibilă schimbare de semn

Definiția 2

Fie n un întreg pozitiv par. **Transformata Cosinus Discretă Modificată** (TCDM) a lui $x = [x_0, \dots, x_{2n-1}]^T$ este vectorul n -dimensional

$$y = Mx, \quad (3)$$

unde M este matricea $n \times 2n$

$$M_{ij} = \sqrt{\frac{2}{n}} \cos \frac{(i + \frac{1}{2})(j + \frac{n}{2} + \frac{1}{2})\pi}{n}, \quad (4)$$

pentru $0 \leq i \leq n-1$ și $0 \leq j \leq 2n-1$.

- observăm diferența majoră față de formele anterioare ale TCD: TCDM a unui vector de dimensiune $2n$ este un vector de dimensiune n

9.4.1 Transformata Cosinus Discretă Modificată

- din acest motiv, TCDM nu este direct inversabilă, dar vom vedea mai târziu că același efect va fi obținut prin suprapunerea vectorilor de dimensiune $2n$
- compararea cu Definiția 1 ne permite să scriem matricea TCDM M în termeni de coloane TCD4 și apoi să simplificăm, folosind Lema 1:

$$\begin{aligned} M &= \left[c_{\frac{n}{2}} \cdots c_{\frac{5n}{2}-1} \right] \\ &= \left[c_{\frac{n}{2}} \cdots c_{n-1} \mid c_n \cdots c_{\frac{3n}{2}-1} \mid c_{\frac{3n}{2}} \cdots c_{2n-1} \mid c_{2n} \cdots c_{\frac{5n}{2}-1} \right] \\ &= \left[c_{\frac{n}{2}} \cdots c_{n-1} \mid -c_{n-1} \cdots -c_{\frac{n}{2}} \mid -c_{\frac{n}{2}-1} \cdots -c_0 \mid -c_0 \cdots -c_{\frac{n}{2}-1} \right]. \quad (5) \end{aligned}$$

- de exemplu, matricea TCDM $n = 4$ este

$$M = [c_2 c_3 \mid c_4 c_5 \mid c_6 c_7 \mid c_8 c_9] = [c_2 c_3 \mid -c_3 -c_2 \mid -c_1 -c_0 \mid -c_0 -c_1].$$

- pentru a simplifica notația, fie A și B jumătatea stângă, și, respectiv, dreaptă a matricii TCD4, astfel încât $E = [A \mid B]$

9.4.1 Transformata Cosinus Discretă Modificată

- definim matricea de permutare formată prin inversarea coloanelor matricii identitate, de la stânga la dreapta:

$$R = \begin{bmatrix} & & 1 \\ & \ddots & \\ 1 & & \end{bmatrix}.$$

- matricea de permutare R inversează coloanele de la dreapta la stânga atunci când este înmulțită cu o matrice la dreapta
- când este înmulțită la stânga, inversează rândurile de sus în jos
- observăm că R este o matrice simetrică ortogonală, deoarece $R^{-1} = R^T = R$
- acum (5) poate fi scrisă mai simplu sub forma

$$M = [B | -BR | -AR | -A], \quad (6)$$

unde AR și BR sunt versiunile lui A și B în care ordinea coloanelor a fost inversată, de la stânga la dreapta

- acțiunea TCDM poate fi exprimată în termeni de TCD4

9.4.1 Transformata Cosinus Discretă Modificată

- fie

$$x = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix}$$

un vector $2n$ -dimensional, unde fiecare x_i este un vector de dimensiune $n/2$ (ne amintim că n este par)

- atunci, din caracterizarea lui M din (6), avem

$$\begin{aligned} Mx &= Bx_1 - BRx_2 - ARx_3 - Ax_4 \\ &= [A|B] \begin{bmatrix} -Rx_3 - x_4 \\ x_1 - Rx_2 \end{bmatrix} = E \begin{bmatrix} -Rx_3 - x_4 \\ x_1 - Rx_2 \end{bmatrix}, \end{aligned} \quad (7)$$

unde E este matricea TCD4 $n \times n$ și Rx_2 și Rx_3 reprezintă x_2 și x_3 cu intrările inversate de sus în jos

- acest fapt este foarte util—putem exprima ieșirea lui M în funcție de matricea ortogonală E
- deoarece matricea $n \times 2n$ M a TCDM nu este o matrice pătratică, nu este inversabilă

9.4.1 Transformata Cosinus Discretă Modificată

- totuși, două TCDM adiacente pot avea rangul $2n$ în total, și împreună, pot reconstrui perfect valorile de intrare x , după cum vom arăta
- TCDM „inversă” este reprezentată de matricea $2n \times n$ $N = M^T$, care are intrările transpuse

$$N_{ij} = \sqrt{\frac{2}{n}} \cos \frac{(j + \frac{1}{2}) (i + \frac{n}{2} + \frac{1}{2}) \pi}{n}, \quad (8)$$

- nu este o inversă propriu-zisă, deși este cât se poate de aproape de aceasta, pentru o matrice care nu este pătratică
- luând transpusa lui (6), avem

$$N = \begin{bmatrix} B^T \\ -RB^T \\ -RA^T \\ -A^T \end{bmatrix}, \quad (9)$$

unde am folosit notația anterioară $E = [A|B]$ pentru Transformata Cosinus Discretă TCD4

9.4.1 Transformata Cosinus Discretă Modificată

- știm că, deoarece E este o matrice ortogonală,

$$\begin{aligned}A^T A &= I \\ B^T B &= I \\ A^T B &= B^T A = 0,\end{aligned}$$

unde I reprezintă matricea identitate $n \times n$

- acum suntem pregătiți să calculăm NM , pentru a vedea în ce sens N inversează matricea TCDM M
- presupunem că x este partiționat în patru părți, ca mai înainte
- potrivit (7) și (9), ortogonalității lui A și B , și faptului că $R^2 = I$, avem

$$\begin{aligned}NM \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} &= \begin{bmatrix} B^T \\ -RB^T \\ -RA^T \\ -A^T \end{bmatrix} [A(-Rx_3 - x_4) + B(x_1 - Rx_2)] \\ &= \begin{bmatrix} x_1 - Rx_2 \\ -Rx_1 + x_2 \\ x_3 + Rx_4 \\ Rx_3 + x_4 \end{bmatrix}. \end{aligned} \tag{10}$$

9.4.1 Transformata Cosinus Discretă Modificată

- în algoritmi de compresie audio, TCDM este aplicată unor vectori de date care se suprapun
- motivul este că orice „artefacte” datorate capetelor vectorilor vor apărea cu o frecvență fixată, datorită dimensiunii constante a vectorilor
- sistemul auditiv este și mai sensibil la erori periodice decât sistemul vizual; la urma urmei, o eroare cu frecvență fixă este un ton al acelei frecvențe, pe care urechea îl va sesiza
- presupunem că datele vor fi prezentate într-o manieră suprapusă
- fie

$$Z_1 = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} \text{ și } Z_2 = \begin{bmatrix} x_3 \\ x_4 \\ x_5 \\ x_6 \end{bmatrix}$$

doi vectori $2n$ -dimensionali pentru un întreg par n , unde fiecare x_i este un vector de dimensiune $n/2$

- vectorii Z_1 și Z_2 se suprapun pe jumătate din lungimea lor

9.4.1 Transformata Cosinus Discretă Modificată

- deoarece (10) ne arată că

$$NMZ_1 = \begin{bmatrix} x_1 - Rx_2 \\ -Rx_1 + x_2 \\ x_3 + Rx_4 \\ Rx_3 + x_4 \end{bmatrix} \text{ și } NMZ_2 = \begin{bmatrix} x_3 - Rx_4 \\ -Rx_3 + x_4 \\ x_5 + Rx_6 \\ Rx_5 + x_6 \end{bmatrix}, \quad (11)$$

putem reconstrui vectorul n -dimensional $[x_3, x_4]^T$ exact prin medierea jumătății inferioare a lui NMZ_1 și a jumătății superioare a lui NMZ_2 :

$$\begin{bmatrix} x_3 \\ x_4 \end{bmatrix} = \frac{1}{2}(NMZ_1)_{n,\dots,2n-1} + \frac{1}{2}(NMZ_2)_{0,\dots,n-1}. \quad (12)$$

- această egalitate prezintă modul în care matricea N este folosită pentru a decoda semnalul după ce a fost codat prin M
- acest rezultat este rezumat în Teorema 1

9.4.1 Transformata Cosinus Discretă Modificată

Teorema 1 (Inversarea TCDM prin suprapunere)

Fie M matricea TCDM $n \times 2n$, și $N = M^T$. Fie u_1, u_2, u_3 n -vectori, și luăm

$$v_1 = M \begin{bmatrix} u_1 \\ u_2 \end{bmatrix} \text{ și } v_2 = M \begin{bmatrix} u_2 \\ u_3 \end{bmatrix}.$$

Atunci n -vectorii w_1, w_2, w_3, w_4 definiți prin

$$\begin{bmatrix} w_1 \\ w_2 \end{bmatrix} = Nv_1 \text{ și } \begin{bmatrix} w_3 \\ w_4 \end{bmatrix} = Nv_2,$$

satisfac $u_2 = \frac{1}{2}(w_2 + w_3)$.

- aceasta este o reconstrucție exactă
- Teorema 1 este folosită de obicei pentru un semnal lung $[u_1, u_2, \dots, u_m]^T$ format din n -vectori concatenați
- TCDM este aplicată pentru perechi adiacente pentru a obține semnalul transformat $[v_1, v_2, \dots, v_{m-1}]^T$
- acum intervine compresia cu pierdere de informații

9.4.1 Transformata Cosinus Discretă Modificată

- vectorii v_i sunt componente de frecvență, astfel că putem alege să păstrăm anumite frecvențe și să estompăm alte frecvențe
- vom urma această direcție în secțiunea următoare
- după compresarea conținutului vectorilor v_i prin cuantizare sau alte mijloace, $[u_2, \dots, u_{m-1}]^T$ poate fi decompresat folosind Teorema 1
- observăm că nu putem recupera u_1 și u_m ; ei trebuie să fie sau părți neimportante ale semnalului sau o bordare care este adăugată înainte

Exemplul 1

- folosiți TCDM suprapusă pentru a transforma semnalul $x = [1, 2, 3, 4, 5, 6]^T$
- apoi inversați transformarea pentru a reconstrui secțiunea din mijloc $[3, 4]^T$
- vom suprapune vectorii $[1, 2, 3, 4]^T$ și $[3, 4, 5, 6]^T$
- fie $n = 2$ și luăm

$$E_2 = \begin{bmatrix} \cos \frac{\pi}{8} & \cos \frac{3\pi}{8} \\ \cos \frac{3\pi}{8} & \cos \frac{9\pi}{8} \end{bmatrix} = \begin{bmatrix} b & c \\ c & -b \end{bmatrix}.$$

9.4.1 Transformata Cosinus Discretă Modificată

- aplicând TCDM 2×4 , obținem

$$v_1 = M \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \end{bmatrix} = E_2 \begin{bmatrix} -R(3) - 4 \\ 1 - R(2) \end{bmatrix} = E_2 \begin{bmatrix} -7 \\ -1 \end{bmatrix} = \begin{bmatrix} -7b - c \\ b - 7c \end{bmatrix} = \begin{bmatrix} -6.8498 \\ -1.7549 \end{bmatrix},$$

$$v_2 = M \begin{bmatrix} 3 \\ 4 \\ 5 \\ 6 \end{bmatrix} = E_2 \begin{bmatrix} -R(5) - 6 \\ 3 - R(4) \end{bmatrix} = E_2 \begin{bmatrix} -11 \\ -1 \end{bmatrix} = \begin{bmatrix} -11b - c \\ b - 11c \end{bmatrix} = \begin{bmatrix} -10.5454 \\ -3.2856 \end{bmatrix}.$$

- semnalul transformat este reprezentat prin

$$[v_1 | v_2] = \begin{bmatrix} -6.8498 & -10.5454 \\ -1.7549 & -3.2856 \end{bmatrix}.$$

- pentru a inversa TCDM, definim A și B prin

$$E_2 = [A|B] = \begin{bmatrix} b & c \\ c & -b \end{bmatrix},$$

9.4.1 Transformata Cosinus Discretă Modificată

- și calculăm

$$\begin{bmatrix} w_1 \\ w_2 \end{bmatrix} = Nv_1 = \begin{bmatrix} B^T v_1 \\ -RB^T v_1 \\ -RA^T v_1 \\ -A^T v_1 \end{bmatrix} = \begin{bmatrix} c & -b \\ -c & b \\ -b & -c \\ -b & -c \end{bmatrix} \begin{bmatrix} -7b - c \\ b - 7c \end{bmatrix} = \begin{bmatrix} -1 \\ 1 \\ 7 \\ 7 \end{bmatrix},$$
$$\begin{bmatrix} w_3 \\ w_4 \end{bmatrix} = Nv_2 = \begin{bmatrix} B^T v_2 \\ -RB^T v_2 \\ -RA^T v_2 \\ -A^T v_2 \end{bmatrix} = \begin{bmatrix} c & -b \\ -c & b \\ -b & -c \\ -b & -c \end{bmatrix} \begin{bmatrix} -11b - c \\ b - 11c \end{bmatrix} = \begin{bmatrix} -1 \\ 1 \\ 11 \\ 11 \end{bmatrix},$$

unde am folosit faptul că $b^2 + c^2 = 1$

- rezultatul Teoremei 1 ne spune că putem recupera suprapunerea $[3, 4]^T$ folosind expresia

$$u_2 = \frac{1}{2}(w_2 + w_3) = \frac{1}{2} \left(\begin{bmatrix} 7 \\ 7 \end{bmatrix} + \begin{bmatrix} -1 \\ 1 \end{bmatrix} \right) = \begin{bmatrix} 3 \\ 4 \end{bmatrix}.$$

9.4.1 Transformata Cosinus Discretă Modificată

- definiția și utilizarea TCDM sunt mai puțin directe decât folosirea TCD, discutată anterior în acest capitol
- avantajul ei este că permite suprapunerea vectorilor adiacenți în mod eficient
- efectul este de a media contribuțiile a doi vectori, reducând „artefactele” rezultate din tranzițiile abrupte care pot fi observate la capete
- ca în cazul TCD, putem filtra sau cuantiza coeficienții transformatei înainte de reconstruirea semnalului pentru a îmbunătăți sau a comprima semnalul
- în cele ce urmează, vom arăta cum poate fi folosită TCDM pentru compresie prin adăugarea unui pas de cuantizare

9.4.2 Cuantizarea biților

- compresia cu pierdere de informații a semnalelor audio se obține prin cuantizarea ieșirii TCDM a semnalului
- în această subsecțiune, vom extinde cuantizarea folosită pentru compresia imaginilor, pentru a permite un control sporit asupra numărului de biți folosiți pentru a reprezenta versiunea compresată a semnalului
- pornim de la intervalul deschis de numere reale $(-L, L)$
- presupunem că scopul este de a reprezenta un număr din $(-L, L)$ prin b biți, și că suntem dispuși să acceptăm o mică eroare
- vom folosi un bit pentru semn și vom cuantiza la un întreg binar pe $b - 1$ biți
- formula de cuantizare este:

Algoritmul 1 (Cuantizarea cu b biți a intervalului $(-L, L)$)

Cuantizarea:

$$z = \text{rotunjire} \left(\frac{y}{q} \right), \text{ unde } q = \frac{2L}{2^b - 1}$$

Decuantizarea:

$$\bar{y} = qz \quad (13)$$

9.4.2 Cuantizarea biților

- ca exemplu, vom arăta cum se pot reprezenta numerele din intervalul $(-1, 1)$ cu 4 biți
- luăm $q = 2(1)/(2^4 - 1) = 2/15$, și cuantizăm prin q
- numărul $y = -0.3$ este reprezentat prin

$$\frac{-0.3}{2/15} = -\frac{9}{4} \rightarrow -2 \rightarrow -010,$$

și numărul $y = 0.9$ este reprezentat prin

$$\frac{0.9}{2/15} = \frac{27}{4} = 6.75 \rightarrow 7 \rightarrow +111.$$

- decuantizarea inversează acest proces
- versiunea cuantizată a lui -0.3 este decuantizată ca

$$(-2)q = (-2)(2/15) = -4/15 \approx -0.2667,$$

și versiunea cuantizată a lui 0.9 ca

$$(7)q = (7)(2/15) = 14/15 \approx 0.9333.$$

- în ambele cazuri, eroarea de cuantizare este $1/30$

9.4.2 Cuantizarea biților

Exemplul 2

- cuantizați ieșirea TCDM din Exemplul 1 cu întregi pe 4 biți
- apoi decuantizați, inversați TCDM, și găsiți eroarea de cuantizare
- toate intrările transformate se află în intervalul $(-12, 12)$
- folosind $L = 12$, cuantizarea cu 4 biți necesită ca
 $q = 2(12)/(2^4 - 1) = 1.6$
- atunci

$$v_1 = \begin{bmatrix} -6.8498 \\ -1.7549 \end{bmatrix} \rightarrow \begin{bmatrix} \text{rotunjire} \left(\frac{-6.8498}{1.6} \right) \\ \text{rotunjire} \left(\frac{-1.7549}{1.6} \right) \end{bmatrix} \rightarrow \begin{bmatrix} -4 \\ -1 \end{bmatrix} \rightarrow \begin{bmatrix} -100 \\ -001 \end{bmatrix}$$

și

$$v_2 = \begin{bmatrix} -10.5454 \\ -3.2856 \end{bmatrix} \rightarrow \begin{bmatrix} \text{rotunjire} \left(\frac{-10.5454}{1.6} \right) \\ \text{rotunjire} \left(\frac{-3.2856}{1.6} \right) \end{bmatrix} \rightarrow \begin{bmatrix} -7 \\ -2 \end{bmatrix} \rightarrow \begin{bmatrix} -111 \\ -010 \end{bmatrix}.$$

- variabilele transformate v_1 , v_2 pot fi stocate ca întregi pe 4 biți, dând un total de 16 biți

9.4.2 Cuantizarea biților

- decuantizarea cu $q = 1.6$ este

$$\begin{bmatrix} -4 \\ -1 \end{bmatrix} \rightarrow \begin{bmatrix} -6.4 \\ -1.6 \end{bmatrix} = \overline{v_1}$$

și

$$\begin{bmatrix} -7 \\ -2 \end{bmatrix} \rightarrow \begin{bmatrix} -11.2 \\ -3.2 \end{bmatrix} = \overline{v_2}.$$

- aplicând TCDM inversă, obținem

$$\begin{bmatrix} w_1 \\ w_2 \end{bmatrix} = N\overline{v_1} = \begin{bmatrix} -0.9710 \\ 0.9710 \\ 6.5251 \\ 6.5251 \end{bmatrix}$$
$$\begin{bmatrix} w_3 \\ w_4 \end{bmatrix} = N\overline{v_2} = \begin{bmatrix} -1.3296 \\ 1.3296 \\ 11.5720 \\ 11.5720 \end{bmatrix},$$

9.4.2 Cuantizarea biților

- și semnalul reconstruit este

$$u_2 = \frac{1}{2}(w_2 + w_3) = \frac{1}{2} \left(\begin{bmatrix} 6.5251 \\ 6.5251 \end{bmatrix} + \begin{bmatrix} -1.3296 \\ 1.3296 \end{bmatrix} \right) = \begin{bmatrix} 2.5977 \\ 3.9274 \end{bmatrix}.$$

- eroarea de cuantizare este diferența dintre semnalul inițial și semnalul reconstruit:

$$\left| \begin{bmatrix} 2.5977 \\ 3.9274 \end{bmatrix} - \begin{bmatrix} 3 \\ 4 \end{bmatrix} \right| = \begin{bmatrix} 0.4023 \\ 0.0726 \end{bmatrix}.$$

10 Valori proprii și valori singulare

- metodele computaționale pentru localizarea valorilor proprii sunt bazate pe ideea fundamentală a iterației de putere, un tip de iterație de punct fix pentru spații proprii
- o versiune sofisticată a acestei idei, numită algoritmul QR, este algoritmul standard pentru determinarea tuturor valorilor proprii ale matricilor tipice
- descompunerea valorilor singulare dezvăluie structura de bază a unei matrici și este foarte folosită în aplicațiile statistice pentru a găsi relații între date
- în acest capitol, trecem în revistă metode pentru calcularea valorilor proprii și vectorilor proprii pentru o matrice pătratică, și a valorilor singulare și a vectorilor singolari pentru o matrice generală

10.1 Metode de tip iterație de putere

- nu există nicio metodă directă pentru calcularea valorilor proprii
- situația este analoagă găsirii rădăcinilor, în aceea că toate metodele fezabile depind de un anumit tip de iterație
- în debutul acestei secțiuni, vom verifica dacă problema poate fi redusă la găsirea rădăcinilor
- o abordare pentru calcularea valorilor proprii și a vectorilor proprii pentru o matrice $m \times m$, bazată pe găsirea rădăcinilor polinomului caracteristic de gradul m , funcționează bine pentru matrici 2×2
- pentru matrici mai mari, procedura necesită un algoritm de găsire a rădăcinilor de tipul celor studiate în Capitolul 2

10.1 Metode de tip iterație de putere

- sunt cazuri în care modificări mici ale coeficienților unui polinom se pot traduce în modificări dramatice ale rădăcinilor polinomului
- deoarece calculul coeficienților polinomului caracteristic va fi supus unor erori de ordinul celei de rotunjire efectuate în calculator sau mai mari, calcularea valorilor proprii folosind această abordare este susceptibilă unor erori mari
- această dificultate este suficient de serioasă pentru a necesita eliminarea metodei de găsire a rădăcinilor polinomului caracteristic din procesul de calculare precisă a valorilor proprii
- această secțiune introduce metode bazate pe înmulțirea unor puteri mari ale matricii cu un vector, care, de obicei, se va transforma într-un vector propriu pe măsură ce puterea este mărită
- vom rafina această idee mai târziu, dar ea reprezintă baza pentru metode mai sofisticate

10.1.1 Iterația de putere

- motivația pentru iterația de putere este aceea că înmulțirea cu o matrice tinde să miște vectorii înspre direcția vectorului propriu dominant

Definiția 3

Fie A o matrice $m \times m$. O **valoare proprie dominantă** a lui A este valoarea proprie λ a cărei normă este mai mare decât toate celelalte valori proprii ale lui A . Dacă există, un vector propriu asociat lui λ se numește **vector propriu dominant**.

- matricea

$$A = \begin{bmatrix} 1 & 3 \\ 2 & 2 \end{bmatrix}$$

are o valoare proprie dominantă 4 cu vectorul propriu $[1, 1]^T$, și o valoare proprie care are norma mai mică, -1 , cu vectorul propriu asociat $[-3, 2]^T$

10.1.1 Iterația de putere

- să observăm care este rezultatul înmulțirii matricii A cu un vector „aleator”, de exemplu $[-5, 5]^T$:

$$x_1 = Ax_0 = \begin{bmatrix} 1 & 3 \\ 2 & 2 \end{bmatrix} \begin{bmatrix} -5 \\ 5 \end{bmatrix} = \begin{bmatrix} 10 \\ 0 \end{bmatrix}$$

$$x_2 = A^2x_0 = \begin{bmatrix} 1 & 3 \\ 2 & 2 \end{bmatrix} \begin{bmatrix} 10 \\ 0 \end{bmatrix} = \begin{bmatrix} 10 \\ 20 \end{bmatrix}$$

$$x_3 = A^3x_0 = \begin{bmatrix} 1 & 3 \\ 2 & 2 \end{bmatrix} \begin{bmatrix} 10 \\ 20 \end{bmatrix} = \begin{bmatrix} 70 \\ 60 \end{bmatrix}$$

$$x_4 = A^4x_0 = \begin{bmatrix} 1 & 3 \\ 2 & 2 \end{bmatrix} \begin{bmatrix} 70 \\ 60 \end{bmatrix} = \begin{bmatrix} 250 \\ 260 \end{bmatrix} = 260 \begin{bmatrix} \frac{25}{26} \\ 1 \end{bmatrix}.$$

- înmulțirea repetată cu matricea A a unui vector inițial aleator a avut ca efect mișcarea vectorului foarte aproape de vectorul propriu dominant al lui A
- aceasta nu este o coincidență, după cum se poate vedea din exprimarea lui x_0 ca o combinație liniară a vectorilor proprii

$$x_0 = 1 \begin{bmatrix} 1 \\ 1 \end{bmatrix} + 2 \begin{bmatrix} -3 \\ 2 \end{bmatrix},$$

10.1.1 Iterația de putere

- și refacerea calculului în lumina acestei scrieri:

$$x_1 = Ax_0 = 4 \begin{bmatrix} 1 \\ 1 \end{bmatrix} - 2 \begin{bmatrix} -3 \\ 2 \end{bmatrix}$$

$$x_2 = A^2 x_0 = 4^2 \begin{bmatrix} 1 \\ 1 \end{bmatrix} + 2 \begin{bmatrix} -3 \\ 2 \end{bmatrix}$$

$$x_3 = A^3 x_0 = 4^3 \begin{bmatrix} 1 \\ 1 \end{bmatrix} - 2 \begin{bmatrix} -3 \\ 2 \end{bmatrix}$$

$$\begin{aligned} x_4 = A^4 x_0 &= 4^4 \begin{bmatrix} 1 \\ 1 \end{bmatrix} + 2 \begin{bmatrix} -3 \\ 2 \end{bmatrix} \\ &= 256 \begin{bmatrix} 1 \\ 1 \end{bmatrix} + 2 \begin{bmatrix} -3 \\ 2 \end{bmatrix}. \end{aligned}$$

- ideea este că vectorul propriu corespunzător valorii proprii care este cea mai mare în modul va domina calculul după câțiva pași
- în acest caz, valoarea proprie 4 este cea mai mare, și calculul se apropie din ce în ce mai mult de vectorul propriu corespunzător $[1, 1]^T$
- pentru a nu lăsa numerele să crească necontrolat, este necesar să normalizăm vectorul la fiecare pas

10.1.1 Iterația de putere

- o modalitate de a face acest lucru este de a împărți vectorul curent prin norma lui înainte de fiecare pas
- aceste două operații, normalizarea și înmulțirea cu A constituie metoda iterației de putere
- pe măsură ce pașii oferă aproximări îmbunătățite ale vectorilor proprii, cum găsim aproximările valorilor proprii?
- pentru a pune întrebarea mai general, presupunem că o matrice A și o aproximare a unui vector propriu sunt cunoscute
- care este cea mai bună aproximare pentru valoarea proprie asociată?
- vom apela la cele mai mici pătrate
- considerăm ecuația valorii proprii $x\lambda = Ax$, unde x este o aproximare a unui vector propriu și λ este necunoscut
- privită în acest fel, matricea coeficienților este matricea $n \times 1$ x
- ecuațiile normale ne spun că răspunsul în sensul celor mai mici pătrate este soluția lui $x^T x \lambda = x^T Ax$, sau

$$\lambda = \frac{x^T Ax}{x^T x}, \quad (14)$$

cunoscut sub numele de **cât Rayleigh**

10.1.1 Iterația de putere

- fiind dată o aproximare a unui vector propriu, câtul Rayleigh este cea mai bună aproximare a valorii proprii corespunzătoare
- aplicând câtul Rayleigh la vectorul propriu normalizat adaugă o aproximare a valorii proprii la iterația de putere

Algoritmul 2 (Iterația de putere)

Dându-se vectorul inițial x_0

for $j = 1, 2, 3, \dots$

$$u_{j-1} = x_{j-1} / \|x_{j-1}\|_2$$

$$x_j = Au_{j-1}$$

$$\lambda_j = u_{j-1}^T Au_{j-1}$$

end

$$u_j = x_j / \|x_j\|_2$$

- pentru a găsi vectorul propriu dominant al matricii A , începem cu un vector inițial
- fiecare iterație constă din normalizarea vectorului curent și înmulțirea cu A
- câtul Rayleigh este folosit pentru a aproxima valoarea proprie

10.1.2 Convergența iterației de putere

- vom demonstra convergența iterației de putere în anumite condiții impuse valorilor proprii
- deși aceste condiții nu sunt absolut generale, ele servesc pentru a arăta de ce metoda înregistrează o reușită în cel mai clar caz posibil
- mai târziu, vom asambla metode de găsim a valorilor proprii din ce în ce mai sofisticate, construite pe baza conceptului de iterație de putere, care pot fi folosite pentru matrici mai generale

Teorema 2

Fie A o matrice $m \times m$ cu valorile proprii reale $\lambda_1, \dots, \lambda_m$, care satisfac $|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \dots \geq |\lambda_m|$. Presupunem că vectorii proprii ai lui A generează $\mathbb{R}^m$. Pentru aproape orice vector inițial, iterația de putere converge liniar către un vector asociat lui λ_1 , cu rata constantă de convergență $S = |\lambda_2/\lambda_1|$.

- fie $v_1, \dots, v_n$ vectorii proprii care formează o bază a lui $\mathbb{R}^n$, cu valorile proprii corespunzătoare, respectiv, $\lambda_1, \dots, \lambda_n$
- exprimăm vectorul inițial în această bază sub forma $x_0 = c_1 v_1 + \dots + c_n v_n$, pentru anumiți coeficienți c_i

10.1.2 Convergența iterației de putere

- afirmația „pentru aproape orice vector inițial” înseamnă că putem presupune că $c_1, c_2 \neq 0$
- aplicând iterația de putere, obținem

$$\begin{aligned}Ax_0 &= c_1 \lambda_1 v_1 + c_2 \lambda_2 v_2 + \cdots + c_n \lambda_n v_n \\A^2 x_0 &= c_1 \lambda_1^2 v_1 + c_2 \lambda_2^2 v_2 + \cdots + c_n \lambda_n^2 v_n \\A^3 x_0 &= c_1 \lambda_1^3 v_1 + c_2 \lambda_2^3 v_2 + \cdots + c_n \lambda_n^3 v_n \\&\vdots\end{aligned}$$

cu normalizare la fiecare pas

- pe măsură ce numărul de pași $k \rightarrow \infty$, primul termen din partea dreaptă va domina, indiferent de cum este realizată normalizarea, deoarece

$$\frac{A^k x_0}{\lambda_1^k} = c_1 v_1 + c_2 \left(\frac{\lambda_2}{\lambda_1} \right)^k v_2 + \cdots + c_n \left(\frac{\lambda_n}{\lambda_1} \right)^k v_n.$$

10.1.2 Convergența iterației de putere

- presupunerea că $|\lambda_1| > |\lambda_i|$ pentru $i > 1$ implică faptul că toți termenii mai puțin primul vor converge la zero cu rata de convergență $S \leq |\lambda_2/\lambda_1|$, și anume cu exact această rată, deoarece $c_2 \neq 0$
- prin urmare, metoda converge la un multiplu al vectorului propriu dominant v_1 , cu valoarea proprie λ_1
- termenul „aproape orice” din concluzia teoremei înseamnă că mulțimea de vectori inițiali x_0 pentru care iterația eșuează este o mulțime de dimensiune mai mică din $\mathbb{R}^m$
- mai exact, iterația va converge cu rata specificată dacă x_0 nu se află în reuniunea planelor de dimensiune $m - 1$ generate de $\{v_1, v_3, \dots, v_m\}$ și $\{v_2, v_3, \dots, v_m\}$

10.1.3 Iterația de putere inversă

- iterația de putere este limitată la localizarea valorii proprii cu norma cea mai mare
- dacă iterația de putere este aplicată inversei matricii, cea mai mică valoare proprie poate fi găsită

Lema 2

Fie $\lambda_1, \lambda_2, \dots, \lambda_m$ valorile proprii ale matricii $m \times m$ A . (a) Valorile proprii ale matricii inverse A^{-1} sunt $\lambda_1^{-1}, \lambda_2^{-1}, \dots, \lambda_m^{-1}$, presupunând că această inversă există. Vectorii proprii sunt aceiași cu cei ai lui A . (b) Valorile proprii ale matricii $A - sI$ sunt $\lambda_1 - s, \lambda_2 - s, \dots, \lambda_m - s$ și vectorii proprii sunt aceiași cu cei ai lui A .

- (a) $Av = \lambda v$ implică $v = \lambda A^{-1}v$, și, prin urmare, $A^{-1}v = (1/\lambda)v$
- observăm că vectorul propriu este neschimbat
- (b) scădem sI din ambele părți ale lui $Av = \lambda v$
- atunci $(A - sI)v = (\lambda - s)v$ este definiția valorii proprii pentru $(A - sI)$, și din nou același vector propriu poate fi folosit

10.1.3 Iterația de putere inversă

- potrivit Lemei 2, valoarea proprie cu norma cea mai mare a matricii A^{-1} este inversa valorii proprii cu norma cea mai mică a matricii A
- aplicarea iterației de putere pentru matricea inversă, urmată de inversarea valorii proprii a lui A^{-1} , ne dă valoarea proprie cu norma cea mai mică a matricii A
- pentru a evita calculul explicit al inversei lui A , rescriem aplicarea iterației de putere pentru A^{-1} , și anume,

$$x_{k+1} = A^{-1} x_k, \quad (15)$$

în forma echivalentă

$$Ax_{k+1} = x_k, \quad (16)$$

care este apoi rezolvată pentru a găsi x_{k+1} prin eliminare gaussiană

- acum știm cum să găsim cea mai mare și cea mai mică valoare proprie a unei matrici
- cu alte cuvinte, pentru o matrice 100×100 , suntem 2% gata
- cum găsim celelalte 98 de procente?
- o abordare este sugerată de Lema 2(b)
- putem să facem oricare dintre celelalte valori proprii să fie cea mai mică prin deplasarea lui A cu o valoare apropiată valorii proprii

10.1.3 Iterația de putere inversă

- dacă se întâmplă să știm că există o valoare proprie în apropierea lui 10 (de exemplu, 10.05), atunci $A - 10I$ are o valoare proprie $\lambda = 0.05$
- dacă este valoarea proprie cu norma cea mai mică a lui $A - 10I$, atunci iterația de putere inversă $x_{k+1} = (A - 10I)^{-1}x_k$ o va localiza
- și anume, iterația de putere inversă va converge la inversul $1/(0.05) = 20$, după care inversăm înapoi la 0.05 și adunăm înapoi deplasarea, obținând 10.05
- acest truc va localiza valoarea proprie care este cea mai mică după deplasare—adică valoarea proprie care se află cel mai aproape de această deplasare; pentru a rezuma, avem

Algoritmul 3 (Iterația de putere inversă)

Dându-se vectorul inițial x_0 și deplasarea s

for $j = 1, 2, 3, \dots$

$$u_{j-1} = x_{j-1} / \|x_{j-1}\|_2$$

$$\text{Rezolvăm } (A - sI)x_j = u_{j-1}$$

$$\lambda_j = u_{j-1}^T x_j$$

end

$$u_j = x_j / \|x_j\|_2$$

10.1.3 Iterația de putere inversă

- pentru a găsi valoarea proprie a lui A care se află cel mai aproape de numărul real s , aplicăm iterația de putere pentru $(A - sI)^{-1}$ pentru a obține valoarea proprie cu norma cea mai mare b a lui $(A - sI)^{-1}$
- iterațiile de putere ar trebui făcute prin eliminare gaussiană pentru $(A - sI)y_{k+1} = x_k$
- atunci $\lambda = b^{-1} + s$ este valoarea proprie a lui A aflată cel mai aproape de s
- vectorul propriu asociat lui λ este dat direct de calcul

Exemplul 3

- presupunem că A este o matrice 5×5 cu valorile proprii $-5, -2, 1/2, 3/2, 4$
- aflați valoarea proprie și rata de convergență așteptată când aplicăm
(a) iterația de putere (b) iterația de putere inversă cu deplasarea $s = 0$
(c) iterația de putere inversă cu deplasarea $s = 2$
- (a) iterația de putere cu un vector inițial aleator va converge către valoarea proprie cu norma cea mai mare -5 , cu rata de convergență $S = |\lambda_2|/|\lambda_1| = 4/5$

10.1.3 Iterația de putere inversă

- (b) iterația de putere inversă (fără deplasare) va converge către valoarea proprie cea mai mică, $1/2$, pentru că inversa sa 2 este mai mare decât celelalte inverse $-1/5, -1/2, 2/3$, și $1/4$
- rata de convergență va fi raportul dintre cele mai mari două valori proprii ale matricii inverse, $S = (2/3)/2 = 1/3$
- (c) iterația de putere inversă cu deplasarea $s = 2$ va localiza valoarea proprie cea mai apropiată de 2, care este $3/2$
- motivul este că, după deplasarea valorilor proprii la $-7, -4, -3/2, -1/2$, și 2, cea mai mare dintre inverse este -2
- după inversare obținem $-1/2$ și adunând înapoi deplasarea $s = 2$, obținem $3/2$
- rata de convergență este din nou raportul $(2/3)/2 = 1/3$

10.1.4 Iterația câtlui Rayleigh

- câtlul Rayleigh poate fi folosit împreună cu iterația de putere inversă
- știm că aceasta converge la vectorul propriu asociat valorii proprii cu cea mai mică distanță până la deplasarea s , și convergența este rapidă dacă distanța este mică
- dacă la un anumit pas am ști aproximarea unei valori proprii, aceasta ar putea fi folosită drept deplasarea s , pentru a accelera convergența
- folosind câtlul Rayleigh ca actualizare a deplasării în iterația de putere inversă ne conduce la iterația câtlui Rayleigh (ICR)

Algoritmul 4 (Iterația câtlui Rayleigh)

Dându-se vectorul inițial x_0

for $j = 1, 2, 3, \dots$

$$u_{j-1} = x_{j-1} / \|x_{j-1}\|_2$$

$$\lambda_{j-1} = u_{j-1}^T A u_{j-1}$$

$$\text{Rezolvăm } (A - \lambda_{j-1} I)x_j = u_{j-1}$$

end

$$u_j = x_j / \|x_j\|_2$$

10.1.4 Iterația câtlui Rayleigh

- câtă vreme iterația de putere inversă converge liniar, iterația câtlui Rayleigh este pătratic convergentă pentru valori proprii simple (care nu se repetă) și va converge cubic dacă matricea este simetrică
- aceasta înseamnă că puțini pași sunt necesari pentru a converge la eroarea de rotunjire efectuată în calculator pentru această metodă
- după convergență, matricea $A - \lambda_{j-1} I$ este singulară și nu mai pot fi făcuți alți pași ai metodei
- prin urmare, încercarea și eroarea trebuie folosite pentru a opri iterația chiar înainte ca acest lucru să se întâmple
- observăm că s-a produs o creștere în complexitate pentru ICR
- iterația de putere inversă necesită doar o factorizare LU; dar pentru ICR, fiecare pas necesită o nouă factorizare, deoarece deplasarea s-a modificat
- chiar și așa, iterația câtlui Rayleigh este metoda cu convergența cea mai rapidă dintre cele pe care le-am prezentat în această secțiune pentru a găsi câte o valoare proprie
- în secțiunea următoare, vom discuta modalități de a găsi toate valorile proprii ale unei matrici în același calcul
- ideea de bază va rămâne iterația de putere—doar detaliile organizationale vor deveni mai sofisticate

10.2 Algoritmul QR

- scopul acestei secțiuni este de a dezvolta metode pentru găsirea tuturor valorilor proprii deodată
- începem cu o metodă care funcționează pentru matrici simetrice, iar mai apoi o vom suplimenta pentru a funcționa în general
- matricile simetrice sunt cel mai ușor de tratat pentru că valorile lor proprii sunt reale și vectorii lor proprii unitari formează o bază ortonormată a lui $\mathbb{R}^m$
- aceasta motivează aplicarea iterației de putere cu m vectori în paralel, în care ne vom asigura că vectorii sunt ortogonali doi câte doi

10.2.1 Iterația simultană

- presupunem că începem cu m vectori inițiali ortogonali doi câte doi $v_1, \dots, v_m$
- după un pas din iterația de putere aplicată fiecărui vector, nu avem garanția că $Av_1, \dots, Av_m$ sunt ortogonali doi câte doi
- de fapt, după înmulțiri repetate cu A , toți vor converge către vectorul propriu dominant, potrivit Teoremei 2
- pentru a evita această situație, vom re-ortogonaliza mulțimea de m vectori la fiecare pas
- înmulțirea simultană cu A a celor m vectori se poate scrie eficient sub forma produsului matricial

$$A[v_1 | \dots | v_m].$$

- după cum am văzut în Capitolul 5, pasul de ortogonalizare poate fi privit ca factorizarea produsului rezultat sub forma QR

10.2.1 Iterația simultană

- dacă vectorii bazei elementare sunt folosiți ca vectori inițiali, atunci primul pas al iterației de putere urmată de re-ortogonalizare este

$$AI = \overline{Q}_1 R_1, \text{ sau}$$

$$\left[A \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix} \mid A \begin{bmatrix} 0 \\ 1 \\ \vdots \\ 0 \end{bmatrix} \mid \cdots \mid A \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 1 \end{bmatrix} \right] = \left[\overline{q}_1^1 \mid \cdots \mid \overline{q}_m^1 \right] \begin{bmatrix} r_{11}^1 & r_{12}^1 & \cdots & r_{1m}^1 \\ & r_{22}^1 & & \vdots \\ & & \ddots & \vdots \\ & & & r_{mm}^1 \end{bmatrix}. \quad (17)$$

- vectorii $\overline{q}_i^1$ pentru $i = 1, \dots, m$ reprezintă noua mulțime ortogonală de vectori unitari din cadrul iterației de putere
- în continuare, repetăm acest pas:

$$\begin{aligned} A\overline{Q}_1 &= \left[A\overline{q}_1^1 \mid A\overline{q}_2^1 \mid \cdots \mid A\overline{q}_m^1 \right] \\ &= \left[\overline{q}_1^2 \mid \overline{q}_2^2 \mid \cdots \mid \overline{q}_m^2 \right] \begin{bmatrix} r_{11}^2 & r_{12}^2 & \cdots & r_{1m}^2 \\ & r_{22}^2 & & \vdots \\ & & \ddots & \vdots \\ & & & r_{mm}^2 \end{bmatrix} \\ &= \overline{Q}_2 R_2. \end{aligned} \quad (18)$$

10.2.1 Iterația simultană

- cu alte cuvinte, am dezvoltat o formă matricială a iterației de putere care caută să găsească toți cei m vectori proprii ai unei matrici simetrice simultan

Algoritmul 5 (Iterația simultană normalizată)

```
Luăm  $\overline{Q}_0 = I$   
for  $j = 1, 2, 3, \dots$   
     $A\overline{Q}_j = \overline{Q}_{j+1}R_{j+1}$   
end
```

- la pasul j , coloanele lui Q_j sunt aproximări ale vectorilor proprii ai lui A , și intrările diagonale $r_{11}^j, \dots, r_{mm}^j$ sunt aproximări ale valorilor proprii
- vom numi acest algoritm iterația simultană normalizată (ISN)
- există o modalitate și mai compactă de a implementa iterația simultană normalizată
- luăm $\overline{Q}_0 = I$

10.2.1 Iterația simultană

- atunci ISN are loc după cum urmează:

$$\begin{aligned} A\overline{Q_0} &= \overline{Q_1}R_1 \\ A\overline{Q_1} &= \overline{Q_2}R_2 \\ A\overline{Q_2} &= \overline{Q_3}R_3 \\ &\vdots \end{aligned} \tag{19}$$

- considerăm iterația similară $Q_0 = I$, și

$$\begin{aligned} A_0 &\equiv AQ_0 = Q_1R'_1 \\ A_1 &\equiv R_1Q_1 = Q_2R'_2 \\ A_2 &\equiv R_2Q_2 = Q_3R'_3 \\ &\vdots \end{aligned} \tag{20}$$

pe care îl vom numi **algoritmul QR nedeplasat**

- singura diferență este că matricea A nu mai este necesară după primul pas; ea este înlocuită de matricea curentă R_k
- comparând (19) și (20) ne arată că putem alege $Q_1 = \overline{Q_1}$ și $R_1 = R'_1$ în (19)

10.2.1 Iterația simultană

- mai mult, deoarece

$$\overline{Q_2} R_2 = A \overline{Q_1} = Q_1 R'_1 \overline{Q_1} = Q_1 R'_1 Q_1 = Q_1 Q_2 R'_2, \quad (21)$$

putem alege $\overline{Q_2} = Q_1 Q_2$ și $R_2 = R'_2$ în (19)

- de fapt, dacă am ales $\overline{Q_{j-1}} = Q_1 \cdots Q_{j-1}$ și $R_{j-1} = R'_{j-1}$, atunci

$$\begin{aligned} \overline{Q_j} R_j &= A \overline{Q_{j-1}} = A Q_1 \cdots Q_{j-1} \\ &= \overline{Q_2} R_2 Q_2 \cdots Q_{j-1} \\ &= \overline{Q_2} Q_3 R_3 Q_3 \cdots Q_{j-1} \\ &= Q_1 Q_2 Q_3 Q_4 R_4 Q_4 \cdots Q_{j-1} \\ &= \cdots = Q_1 \cdots Q_j R_j, \end{aligned} \quad (22)$$

și putem defini $\overline{Q_j} = Q_1 \cdots Q_j$ și $R_j = R'_j$ în (19)

- prin urmare, algoritmul QR nedepasat efectuează aceleași calcule ca iterația simultană normalizată, cu o notație ușor diferită
- observăm de asemenea că

$$A_{j-1} = Q_j R_j = Q_j R_j Q_j Q_j^T = Q_j A_j Q_j^T, \quad (23)$$

astfel că toate matricile A_j sunt asemenea și au aceeași mulțime de valori proprii

10.2.1 Iterația simultană

Teorema 3

Presupunem că A este o matrice simetrică $m \times m$ cu valorile proprii λ_i care satisfac $|\lambda_1| > |\lambda_2| > \dots > |\lambda_m|$. Algoritmul QR nedepasat converge liniar către vectorii proprii și valorile proprii ale lui A . Pe măsură ce $j \rightarrow \infty$, A_j converge către o matrice diagonală care conține valorile proprii pe diagonala principală și $\overline{Q}_j = Q_1 \cdots Q_j$ converge la o matrice ortogonală ale cărei coloane sunt vectorii proprii.

- iterația simultană normalizată, practic același algoritm, converge în aceleași condiții
- observăm că algoritmul QR nedepasat ar putea să eșueze chiar și pentru matrici simetrice dacă ipotezele teoremei nu sunt satisfăcute
- deși algoritmul QR nedepasat este o versiune îmbunătățită a iterației de putere, condițiile cerute de Teorema 3 sunt stricte, și câteva îmbunătățiri sunt necesare pentru a face acest algoritm de găsire a valorilor proprii să funcționeze într-un context mai general—de exemplu, în cazul matricilor nesimetrice

10.2.1 Iterația simultană

- nimic din definiția algoritmului QR nedepășat nu ne permite să calculăm valori proprii complexe
- mai mult, algoritmul QR nedepășat nu folosește trucul iterației de putere inverse
- am arătat că iterația de putere poate fi accelerată semnificativ folosind acest truc, și dorim să găsim o modalitate de a aplica această idee noii noastre implementări
- aceste rafinări sunt aplicate în cele ce urmează, după introducerea scopului algoritmului QR, care este acela de a reduce matricea A la forma ei Schur reală

10.2.2 Forma Schur reală și algoritmul QR

- repetăm acest pas, generând un șir A_k de matrici, toate asemenea cu $A = A_0$
- care sunt alegerile bune pentru deplasarea s ?
- această întrebare ne conduce la conceptul de **deflație** pentru calculul valorilor proprii
- vom alege deplasarea ca fiind intrarea din dreapta jos a matricii A_k
- aceasta va face ca iterația, pe măsură ce converge la forma Schur reală, să schimbe rândul de jos într-un rând de zerouri, cu excepția intrării din dreapta jos
- după ce această intrare a devenit convergentă la o valoare proprie, vom efectua o deflație a matricii prin eliminarea ultimului rând și a ultimei coloane
- apoi continuăm cu găsirea celorlalte valori proprii

10.3 Descompunerea valorilor singulare

- imaginea sferei unitate din $\mathbb{R}^m$ printr-o matrice $m \times m$ este un elipsoid
- acest fapt interesant evidențiază descompunerea valorilor singulare, care are multe aplicații în analiza matricială în general și în special pentru compresie




Figura 2: Imaginea cercului unitate printr-o matrice 2×2 . Cercul unitate din $\mathbb{R}^2$ este transformat în elipsa cu axe semimajore $(3, 0)$ și $(0, 1/2)$ prin matricea A din (25).

10.3.1 Găsirea DVS în general

- am arătat două exemple simple de DVS
- pentru a arăta că DVS există pentru o matrice generală A , avem nevoie de următoarea lemă:

Lema 3

Fie A o matrice $m \times n$. Valorile proprii ale lui $A^T A$ sunt nenegative.

- fie v un vector propriu unitar al lui $A^T A$, și $A^T A v = \lambda v$
- atunci

$$0 \leq \|Av\|^2 = v^T A^T A v = \lambda v^T v = \lambda.$$

- pentru o matrice $m \times n$ A , matricea $n \times n$ $A^T A$ este simetrică, astfel că vectorii ei proprii sunt ortogonali și valorile ei proprii sunt reale
- Lema 3 ne arată că valorile proprii sunt numere reale nenegative astfel că pot fi exprimate sub forma $s_1^2 \geq \dots \geq s_n^2$, unde mulțimea ortonormală corespunzătoare de vectori proprii este $\{v_1, \dots, v_n\}$
- aceasta ne dă deja două treimi din DVS

10.3.1 Găsirea DVS în general

- în ecuația de definiție $Av_1 = s_1 u_1$, de exemplu, înlocuind pe v_1 cu $-v_1$ și pe u_1 cu $-u_1$ nu schimbă egalitatea, dar schimbă matricile U și V
- concluzionăm din această teoremă că imaginea sferei unitate de vectori este un elipsoid de vectori, centrat în origine, cu axele semimajore $s_i u_i$
- Figura 3 arată că cercul unitate de vectori este transformat într-o elipsă cu axele $\{s_1 u_1, s_2 u_2\}$
- pentru a găsi unde merge Ax pentru un vector x , putem scrie $x = a_1 v_1 + a_2 v_2$ (unde $a_1 v_1$ ($a_2 v_2$) este proiecția lui x pe direcția v_1 (v_2)), și apoi $Ax = a_1 s_1 u_1 + a_2 s_2 u_2$
- reprezentarea matricială (29) rezultă direct din Teorema 5
- definim S ca fiind matricea diagonală $m \times n$ ale cărei intrări sunt $s_1 \geq \dots \geq s_{\min\{m,n\}} \geq 0$
- definim U ca fiind matricea ale cărei coloane sunt $u_1, \dots, u_m$, și V ca fiind matricea ale cărei coloane sunt $v_1, \dots, v_n$
- observăm că $USV^T v_i = s_i u_i$ pentru $i = 1, \dots, m$
- deoarece matricile A și USV^T sunt egale de-a lungul vectorilor bazei $v_1, \dots, v_n$, ele sunt matrici $m \times n$ identice

10.3.1 Găsirea DVS în general

Exemplul 6

- găsiți valorile singulare și vectorii singulari ai matricii 2×2

$$A = \begin{bmatrix} 0 & 1 \\ 0 & -1 \end{bmatrix}. \quad (31)$$

- valorile proprii ale lui

$$A^T A = \begin{bmatrix} 0 & 0 \\ 0 & 2 \end{bmatrix},$$

aranjate în ordine descrescătoare, sunt $v_1 = [0, 1]^T$, $s_1^2 = 2$; și $v_2 = [1, 0]^T$, $s_2^2 = 0$

- valorile singulare sunt $\sqrt{2}$ și 0
- potrivit procedurii anterioare, u_1 este definit prin

$$\begin{aligned} \sqrt{2}u_1 &= Av_1 = \begin{bmatrix} 1 \\ -1 \end{bmatrix} \\ u_1 &= \begin{bmatrix} 1/\sqrt{2} \\ -1/\sqrt{2} \end{bmatrix}, \end{aligned}$$

10.3.1 Găsirea DVS în general

- și $u_2 = [1/\sqrt{2}, 1/\sqrt{2}]^T$ este ales pentru a fi ortogonal pe u_1
- DVS este

$$\begin{bmatrix} 0 & 1 \\ 0 & -1 \end{bmatrix} = \begin{bmatrix} \sqrt{2}/2 & \sqrt{2}/2 \\ -\sqrt{2}/2 & \sqrt{2}/2 \end{bmatrix} \begin{bmatrix} \sqrt{2} & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}. \quad (32)$$

- conform comentariului despre neunicitatea DVS care a urmat Teoremei 5, o altă DVS perfect valabilă pentru această matrice este

$$\begin{bmatrix} 0 & 1 \\ 0 & -1 \end{bmatrix} = \begin{bmatrix} -\sqrt{2}/2 & \sqrt{2}/2 \\ \sqrt{2}/2 & \sqrt{2}/2 \end{bmatrix} \begin{bmatrix} \sqrt{2} & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}. \quad (33)$$

- imaginea cercului unitate prin A este segmentul de dreaptă $y[1, -1]^T$, unde y se află între -1 și 1
- deci acțiunea lui A este de a aplatiza cercul unitate într-o elipsă uni-dimensională cu axe semimajore $\sqrt{2}[\sqrt{2}/2, -\sqrt{2}/2]$ și 0

10.3.2 Cazul special al matricilor simetrice

- găsirea DVS a unei matrici $m \times m$ simetrice se reduce la găsirea vectorilor proprii și a valorilor proprii
- știm că există o mulțime ortonormală de vectori proprii
- deoarece vectorii proprii sunt transformați în ei înșiși (cu o scalare λ , care este valoare proprie), satisfacerea ecuației (26) este ușoară: doar ordonăm valorile proprii descrescător în funcție de norme

$$|\lambda_1| \geq |\lambda_2| \geq |\lambda_3| \geq \cdots \geq |\lambda_m|, \quad (34)$$

și le folosim pe post de valori singulare $s_1 \geq s_2 \geq \cdots$

- pentru v_i , folosim vectorii proprii unitari în ordinea corespunzătoare valorilor proprii din (34), și folosim

$$u_i = \begin{cases} +v_i & \text{dacă } \lambda_i \geq 0 \\ -v_i & \text{dacă } \lambda_i < 0 \end{cases}. \quad (35)$$

- schimbarea de semn din (35) compensează orice semn minus pierdut prin luarea valorilor absolute în (34)

10.3.2 Cazul special al matricilor simetrice

Exemplul 7

- găsiți valorile singulare și vectorii singulari ai matricii

$$A = \begin{bmatrix} 0 & 1 \\ 1 & \frac{3}{2} \end{bmatrix}. \quad (36)$$

- perechile valoare proprie/vector propriu sunt $2, [1, 2]^T$ și $-\frac{1}{2}, [-2, 1]^T$
- definim v_i din vectorii proprii unitari și u_i din (35):

$$\begin{aligned} Av_1 &= A \begin{bmatrix} \frac{1}{\sqrt{5}} \\ \frac{2}{\sqrt{5}} \end{bmatrix} = 2 \begin{bmatrix} \frac{1}{\sqrt{5}} \\ \frac{2}{\sqrt{5}} \end{bmatrix} = s_1 u_1 \\ Av_2 &= A \begin{bmatrix} \frac{2}{\sqrt{5}} \\ -\frac{1}{\sqrt{5}} \end{bmatrix} = \frac{1}{2} \begin{bmatrix} -\frac{2}{\sqrt{5}} \\ \frac{1}{\sqrt{5}} \end{bmatrix} = s_2 u_2. \end{aligned} \quad (37)$$

10.3.2 Cazul special al matricilor simetrice

- DVS este

$$\begin{bmatrix} 0 & 1 \\ 1 & \frac{3}{2} \end{bmatrix} = \begin{bmatrix} \frac{1}{\sqrt{5}} & -\frac{2}{\sqrt{5}} \\ \frac{2}{\sqrt{5}} & \frac{1}{\sqrt{5}} \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 0 & \frac{1}{2} \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{5}} & \frac{2}{\sqrt{5}} \\ \frac{2}{\sqrt{5}} & -\frac{1}{\sqrt{5}} \end{bmatrix}. \quad (38)$$

- observăm că a trebuit să schimbăm semnul pentru a defini u_2 , după cum cere (35)

Vă mulțumesc!