

10 Seria de distribuție a statisticilor de eșantioane

Pentru a face inferență (predicție) asupra parametrilor populației, este necesar să analizăm statisticile de eșantioane. Media $\bar{x}$ în cazul unui eșantion nu este neapărat egală cu media μ a populației. Suntem însă mulțumiți dacă media $\bar{x}$ este apropiată de μ . Dacă se consideră media $\bar{x}'$ în cazul unui al doilea eșantion aceasta poate să fie diferită de $\bar{x}$ și de μ . Ceea ce putem spera este ca aceasta să fie apropiată de valoarea μ și de $\bar{x}$. Valabilitatea acestui tip de comportament interesează pentru orice populație și orice statistică.

Întrebarea care se naște în mod natural este ce înseamnă aproape? Cum se măsoară și se determină această apropiere? Care este seria de distribuție a statisticilor de eșantioane?

Definiția 10.1. Seria de distribuție a statisticilor de eșantioane este seria de distribuție a statisticilor de un anumit tip obținute pentru eșantioane de aceeași mărime. Tipul de statistică poate fi oricare din statisticile prezentate în secțiunile 6 și 7.

Exemplul 10.1. Se consideră o populație de N elemente de la care se pot obține următoarele date statistice distincte: $\{0, 2, 4, 6, 8\}$. În cazul acestei populații formăm eșantioane de mărime 2 de la care putem avea următoarele date statistice:

(0, 0)	(2, 0)	(4, 0)	(6, 0)	(8, 0)
(0, 2)	(2, 2)	(4, 2)	(6, 2)	(8, 2)
(0, 4)	(2, 4)	(4, 4)	(6, 4)	(8, 4)
(0, 6)	(2, 6)	(4, 6)	(6, 6)	(8, 6)
(0, 8)	(2, 8)	(4, 8)	(6, 8)	(8, 8)


Pentru aceste eșantioane mediile $\bar{x}$ sunt:

0	1	2	3	4
1	2	3	4	5
2	3	4	5	6
3	4	5	6	7
4	5	6	7	8

Eșantioanele fiind aleatoare fiecare eșantion, are probabilitatea $1/25$ să fie ales și seria de distribuție a mediilor acestor eșantioane este:

$\bar{x}$	$f'(\bar{x})$
0	0.04
1	0.08
2	0.12
3	0.16
4	0.20
5	0.16
6	0.12
7	0.08
8	0.04

unde $f'(\bar{x})$ este frecvența relativă a mediei $\bar{x}$. Diagrama coloană a mediilor eșantioanelor este:



Pentru același set de 25 de eșantioane putem determina seria de distribuție a plajelor R a acestor eșantioane.


Plajele R ale eșantioanelor sunt date în tabelul următor:

0	2	4	6	8
2	0	2	4	6
4	2	0	2	4
6	4	2	0	2
8	6	4	2	0

Seria de distribuție a plajelor acestor eșantioane este:

R	$f'(R)$
0	0.20
2	0.32
4	0.24
6	0.16
8	0.08

iar diagrama coloană a plajei eșantioanelor este:




Exemplul 10.2. În cazul aruncării zarului de un număr de N ori, setul de date statistice care se referă la numărul de pe față care apare este 1, 2, 3, 4, 5, 6.

Formăm eșantioane care constau din 5 aruncări. Fiecare din aceste eșantioane are media $\bar{x}$. Considerăm 30 de eșantioane de acest fel (înseamnă $30 \times 5 = 150$ aruncări) și într-un tabel reprezentăm rezultatele precum și mediile corespunzătoare:

Încercare	Eșantion	$\bar{x}$	Încercare	Eșantion	$\bar{x}$
1	1 2 3 2 2	2.0	16	5 2 1 3 5	3.2
2	4 5 5 4 5	4.6	17	6 1 3 3 5	3.6
3	3 1 5 2 4	3.0	18	6 5 5 2 6	4.8
4	5 6 6 4 2	4.6	19	1 3 5 5 6	4.0
5	5 4 1 6 4	4.0	20	3 1 5 3 1	2.6
6	3 5 6 1 5	4.0	21	5 1 1 4 3	2.8
7	2 3 6 3 2	3.2	22	4 6 3 1 2	3.2
8	5 3 4 6 2	4.0	23	1 5 3 4 5	3.6
9	1 5 5 3 4	3.6	24	3 4 1 3 3	2.8
10	4 1 5 2 6	3.6	25	1 2 4 1 4	2.4
11	5 1 3 3 2	2.8	26	5 2 1 6 3	3.4
12	1 5 2 3 1	2.4	27	4 2 5 6 3	4.0
13	2 1 1 5 3	2.4	28	4 3 1 3 4	3.0
14	5 1 4 4 6	4.0	29	2 6 5 3 3	3.8
15	5 5 6 3 3	4.4	30	6 3 5 1 1	3.2

Histograma seriei de distribuție a mediilor celor 30 de eșantioane este reprezentată în figura următoare:



Această lege de repartiție pare să aibe caracteristicile unei legi de repartiție normală; este maxim și este simetric față de media proprie 3.5.

11 Teorema limită centrală

În secțiunea precedentă am prezentat seria de distribuție a mediei și plajei unui set de eșantioane. Media este statistica folosită cel mai frecvent în cazul eșantioanelor și de aceea este foarte importantă. Teorema limită centrală se referă la seria de distribuție a mediei tuturor eșantioanelor aleatoare de aceeași mărime n .

Să formulăm ce anume interesează în cazul acestei serii de distribuție:

- 1) Unde este centrul datelor?
- 2) Cât de mare este dispersia datelor?
- 3) Care este caracterul seriei de distribuție?

Teorema limită centrală oferă răspuns la aceste trei întrebări.

Teorema 11.1. Teorema limită centrală

Fie μ media și σ deviația standard a unei variabile în cazul unei populații. Dacă se consideră toate eșantioanele aleatoare de mărime n din această populație, atunci seria de distribuție a mediilor acestor eșantioane are următoarele proprietăți:

- a) media $\mu_{\bar{x}}$ a acestei serii de distribuție este egală cu μ ;
- b) deviația standard $\sigma_{\bar{x}}$ a acestei serii de distribuție este $\frac{\sigma}{\sqrt{n}}$.
- c) dacă seria de distribuție a variabilei în cazul populației este normală, atunci seria de distribuție a mediilor eșantioanelor este normală; dacă seria de distribuție a variabilei în cazul populației nu este normală, atunci seria de distribuție a mediilor eșantioanelor este aproximativ normală pentru eșantioane de mărime mai mare ca 30. Tendința către o serie de distribuție normală crește dacă mărimea eșantionului crește.

Pe scurt, teorema limită centrală stabilește următoarele:

- 1) $\mu_{\bar{x}} = \mu$, unde $\bar{x}$ este media eșantionului x ;
- 2) $\sigma_{\bar{x}} = \sigma/\sqrt{n}$, deviația standard a mediei este egală cu deviația standard a populației împărțită cu rădăcina pătrată a mărării eșantionului.
- 3) seria de distribuție a mediei eșantioanelor este aproximativ normală indiferent de seria de distribuție a variabilei în cazul populației.

Remarca 11.1. Deviația standard $\sigma_{\bar{x}}$ a seriei de distribuție a mediilor eșantioanelor este deviația standard a mediilor eșantioanelor față de media seriei de distribuție a eșantioanelor.

Nu vom face demonstrație teoremei limită centrală. Vom ilustra însă validitatea ei examinând un caz ilustrativ.

Considerăm o populație pentru care seria de distribuție de date statistice cu frecvențe relative în cazul variabilei X este:

$$X : \begin{pmatrix} 2 & 4 & 6 \\ 1/3 & 1/3 & 1/3 \end{pmatrix}$$

Media μ și deviația standard σ pentru această variabilă sunt:

$$\mu = \sum_{j=1}^3 x_j \cdot f'_{x_j} \quad \sigma = \sqrt{\sum_{j=1}^3 x_j^2 \cdot f'_{x_j} - \left(\sum_{j=1}^3 x_j \cdot f'_{x_j} \right)^2}$$

$$\mu = \frac{12}{3} = 4 \quad \sigma = 1,63$$

În cazul acestei populații oricare eșantion de mărime doi are următoarele date posibile:

$$\begin{pmatrix} (2,2) & (2,4) & (2,6) \\ (4,2) & (4,4) & (4,6) \\ (6,2) & (6,4) & (6,6) \end{pmatrix}$$

Eșantioanele au următoarele medii:

$$\begin{pmatrix} 2 & 3 & 4 \\ 3 & 4 & 5 \\ 4 & 5 & 6 \end{pmatrix}$$

Eșantion	Media
(2,2)	2
(2,4)	3
(2,6)	4
(4,2)	3
(4,4)	4
(4,6)	5
(6,2)	4
(6,4)	5
(6,6)	6

Eșantioanele fiind aleatoare fiecare eșantion are probabilitatea $\frac{1}{9}$ să fie ales și seria de distribuție a mediilor eșantioanelor este:


$$\overline{X} \begin{pmatrix} 2 & 3 & 4 & 5 & 6 \\ 1/9 & 2/9 & 3/9 & 2/9 & 1/9 \end{pmatrix}$$

Media seriei de distribuție a mediilor eșantioanelor $\mu_{\overline{x}}$ este $\mu_{\overline{x}} = 36/9 = 4,0$. Prin urmare $\mu = \mu_{\overline{x}}$, iar deviația standard a repartițiilor mediilor eșantioanelor este:

$$\sigma_{\overline{x}} = \sqrt{\sum_{j=1}^5 x_j^2 \cdot f'_{x_j} - \left(\sum_{j=1}^5 x_j \cdot f'_{x_j} \right)^2} = \sqrt{\frac{156}{9} - \left(\frac{36}{9} \right)^2} = 1,15$$

$$\frac{\sigma}{\sqrt{n}} = \frac{1,63}{\sqrt{2}} = \frac{1,63}{1,41} = 1,15 = \sigma_{\overline{x}}$$

Reprezentând seria de distribuție a mediilor eșantioanelor obținem:



Această diagramă arată că seria de distribuție a mediilor eşantioanelor este normală.

12 O aplicație a teoremei limită centrală

Teorema limită centrală oferă informații asupra seriei de distribuție a mediilor eșantioanelor descriind forma repartiției mediilor tuturor eșantioanelor (aproape normală). Ea stabilește relația dintre media μ a populației și media $\mu_{\bar{x}}$ a seriei de distribuție a mediilor tuturor eșantioanelor și relația dintre deviația standard σ a populației și deviația standard $\sigma_{\bar{x}}$ a seriei de distribuție a mediilor eșantioanelor. Deoarece seria de distribuție a mediilor eșantioanelor este aproape normală putem stabili legături probabiliste dintre media populației și media unui eșantion.

Exemplul 12.1. Considerăm o populație normală cu $\mu = 100$ și $\sigma = 20$. Dacă se alege un eșantion aleator de mărime $n = 16$ care este probabilitatea ca valoarea medie a acestui eșantion să fie între 90 și 110? Altfel spus, cât este $P(90 < \bar{x} < 110)$?

Soluție: Conform teoremei limită centrală repartiția valorilor medii ale eșantioanelor este normală. Prin urmare va trebui să transformăm condiția $P(90 < \bar{x} < 110)$ într-o condiție care să permită folosirea tabelului de distribuție normală standard. Aceasta se face scriind:

$$\begin{aligned} P(90 < \bar{x} < 110) &= \Phi\left(\frac{110 - \mu_{\bar{x}}}{\sigma_{\bar{x}}}\right) - \Phi\left(\frac{90 - \mu_{\bar{x}}}{\sigma_{\bar{x}}}\right) = \\ &= \Phi\left(\frac{110 - 100}{\sigma_{\bar{x}}}\right) - \Phi\left(\frac{-10}{\sigma_{\bar{x}}}\right) = 2 \cdot \Phi\left(\frac{10}{\sigma_{\bar{x}}}\right) - 1 = F\left(\frac{10}{\sigma_{\bar{x}}}\right) \end{aligned}$$

unde $\Phi(X) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^X e^{-\frac{1}{2}t^2} dt$ și $F(X) = \Phi(X) - \frac{1}{2}$.

Deoarece $\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$, avem $\sigma_{\bar{x}} = \frac{20}{\sqrt{16}} = 5$ și astfel obținem:

$$P(90 < \bar{x} < 110) = 2 \cdot \Phi(2) - 1 = 2F(2) = 0.9544$$

Efectul creșterii dimensiunii n a eșantionului nu afectează $\mu_{\bar{x}} = \mu$ și micșorează $\sigma_{\bar{x}}$. Prin urmare $P(90 < \bar{x} < 110)$ crește, dacă n crește.

Exemplul 12.2. Înălțimea copiilor la o grădiniță are o distribuție normală având o medie $\mu = 100$ cm cu o deviație standard de 12,5 cm. Pentru un eșantion aleator de 25 de copii se determină media $\bar{x}$. Care este probabilitatea ca această medie să fie între 90 cm și 110 cm?

Soluție:

$$P(90 < \bar{x} < 110) = 2 \cdot \Phi\left(\frac{10}{\sigma_{\bar{x}}}\right) - 1 = 2 \cdot \Phi(4) - 1 = 2 \cdot F(4) = 2 \cdot 0.499968$$

13 Estimarea punctuală a unui parametru; intervalul de încredere

Considerăm o populație a cărei medie μ nu o cunoaștem și ne punem problema s-o găsim. Pentru acest scop considerăm un eșantion aleator de dimensiune n pentru care determinăm media $\bar{x}$. Media $\bar{x}$ a eșantionului este o estimare punctuală a mediei μ a populației.

Definiția 13.1. O estimare punctuală a parametrului γ a unei populații este o valoare g a unei statistici corespunzătoare.

Remarca 13.1. Dacă $\bar{x}$ este media eșantionului cu care estimăm media necunoscută μ a populației, aceasta nu înseamnă că $\bar{x} = \mu$. În general, $\bar{x} \neq \mu$ și la ceea ce ne putem aștepta este ca $\bar{x}$ să fie aproape de μ . Această apropiere poate fi fixată prin specificarea unui interval (centrat în μ) numit interval de estimare.

Definiția 13.2. Un interval mărginit (a, b) folosit pentru a estima valoarea unui anumit parametru γ a populației se numește **interval de estimare**. Valorile a, b (capetele intervalului) sunt calculate din eșantion care este folosit pentru estimare.

Cum anume se poate specifica un interval centrat în μ care este necunoscut folosind doar date furnizate de un eșantion va fi lămurit în continuare.

Exemplul 13.1. Considerăm o populație având o deviație standard σ cunoscută, o medie μ necunoscută și un eșantion aleator simplu de mărime n și medie $\bar{x}$ cunoscute. Condiția $\bar{x} \in (\mu - 1, \mu + 1)$ înseamnă că scorul standard $\bar{z}$ (pentru mediile eșantioanelor) dat de:

$$\bar{z} = \frac{\bar{x} - \mu_{\bar{x}}}{\sigma_{\bar{x}}} = \frac{\bar{x} - \mu}{\frac{\sigma}{\sqrt{n}}}$$

să verifice:

$$\bar{z} \in \left(-\frac{1}{\frac{\sigma}{\sqrt{n}}}, \frac{1}{\frac{\sigma}{\sqrt{n}}}\right) = \left(-\frac{\sqrt{n}}{\sigma}, \frac{\sqrt{n}}{\sigma}\right)$$

Astfel în termenii scorului standard intervalul de estimare este intervalul (a, b) cu $a = -\frac{\sqrt{n}}{\sigma}$ și $b = \frac{\sqrt{n}}{\sigma}$.

Mai general condiția $\bar{x} \in (\mu - \delta, \mu + \delta)$, înseamnă că scorul standard $\bar{z}$ (pentru mediile eșantioanelor) dat de:

$$\bar{z} = \frac{\bar{x} - \mu_{\bar{x}}}{\sigma_{\bar{x}}} = \frac{\bar{x} - \mu}{\frac{\sigma}{\sqrt{n}}}$$

să verifice:

$$\bar{z} \in \left(-\frac{\delta \cdot \sqrt{n}}{\sigma}, \frac{\delta \cdot \sqrt{n}}{\sigma}\right)$$

Intervalul de estimare este $\left(-\frac{\delta \cdot \sqrt{n}}{\sigma}, \frac{\delta \cdot \sqrt{n}}{\sigma}\right)$.

Definiția 13.3. Nivelul de neîncredere α este probabilitatea ca statistica eșantionului să aibe valoarea în afara intervalului de estimare.

Conform teoremei de limită centrală, repartiția lui $\bar{x}$ este normală sau aproape normală și avem:

$$P(\mu - 1 < \bar{x} < \mu + 1) = P\left(-\frac{\sqrt{n}}{\sigma} < \bar{z} < \frac{\sqrt{n}}{\sigma}\right) =$$

$$2 \cdot P\left(0 < \bar{z} < \frac{\sqrt{n}}{\sigma}\right) = 2 \cdot F\left(\frac{\sqrt{n}}{\sigma}\right)$$

unde $F(z) = \frac{1}{\sqrt{2 \cdot \pi}} \int_0^z e^{-\frac{1}{2}t^2} dt.$

Deci nivelul de neîncredere α este $1 - 2 \cdot F\left(\frac{\sqrt{n}}{\sigma}\right).$

Definiția 13.4. Nivelul de încredere (coeficient de încredere) $1 - \alpha$ este probabilitatea ca statistica eșantionului să se afle în intervalul de estimare ales.

Definiția 13.5. Intervalul de încredere este un interval de estimare cu un nivel de încredere $1 - \alpha$ specificat.

Exemplul 13.2. În cazul exemplului 13.1, intervalul de estimare $\left(-\frac{\sqrt{n}}{\sigma}, \frac{\sqrt{n}}{\sigma}\right)$ este un interval de încredere cu coeficientul de încredere $1 - \alpha = 2 \cdot F\left(\frac{\sqrt{n}}{\sigma}\right).$

Definiția 13.6. Eroarea maximă de estimare este jumătatea lungimii intervalului de încredere cu nivelul de încredere $1 - \alpha.$

În termen de scor standard această eroare se exprimă cu formula:

$$E = \bar{z}\left(\frac{\alpha}{2}\right) \cdot \frac{\sigma}{\sqrt{n}}$$

unde $\bar{z}\left(\frac{\alpha}{2}\right)$ este soluția ecuației $F(\bar{z}) = \frac{1 - \alpha}{2}$, iar intervalul de încredere $1 - \alpha$ pentru μ este:

$$\left(\bar{x} - \bar{z}\left(\frac{\alpha}{2}\right) \cdot \frac{\sigma}{\sqrt{n}}, \bar{x} + \bar{z}\left(\frac{\alpha}{2}\right) \cdot \frac{\sigma}{\sqrt{n}}\right)$$

$\bar{x} - \bar{z}\left(\frac{\alpha}{2}\right) \cdot \frac{\sigma}{\sqrt{n}}$ este limita inferioară de încredere, iar $\bar{x} + \bar{z}\left(\frac{\alpha}{2}\right) \cdot \frac{\sigma}{\sqrt{n}}$ este limita superioară de încredere.

14 Generalități privind ipotezele statistice și problema verificării ipotezelor statistice

Pentru a ilustra analiza care precede luarea unei decizii în privința credibilității unei aserțiuni (numită verificarea ipotezelor statistice) să considerăm următorul exemplu:

Candidatul la admitere Popescu Nicolae trebuie să completeze un formular test cu zece întrebări. Fiecare întrebare are cinci răspunsuri dintre care doar unul este corect. Popescu Nicolae a completat formularul și din cele zece întrebări el a răspuns corect la șapte. El susține că a completat formularul fără să citească întrebările și răspunsurile la ele și a marcat răspunsurile aleator.

Întrebarea este în ce măsură putem da crezare spuselor că el a marcat răspunsurile aleator? O asemenea întrebare ne determină să analizăm și să hotărâm: este sau nu este rezonabil ca Popescu Nicolae să obțină șapte răspunsuri corecte alegând aleator răspunsurile la întrebări? Descriem în cele ce urmează o analiză, care se numește verificarea ipotezelor statistice și care conduce la formularea unei concluzii.

Verificarea ipotezelor statistice, în general, este un procedeu care are 5 etape. Fiecare din aceste etape va fi prezentată și ilustrată în cazul exemplului considerat.

Etapa 1. Formularea ipotezei nule H_0

Prin ipoteză înțelegem o afirmație care susține că ceva este adevărat. În general, ipoteza nulă este o afirmație relativă la un parametru al unei populații și afirmă că parametrul are o valoare dată. Adesea expresia "nu diferă" este folosită în formularea ei, de aici vine numele de ipoteză nulă. (diferența este nulă)

Etapa 2. Formularea ipotezei alternative H_a

Ipoteza alternativă H_a este o afirmație relativă la același parametru al populației care apare în ipoteza nulă H_0 . În ipoteza H_a se afirmă că parametrul are o valoare diferită de cea susținută în H_0 .

Ipoteza H_0 și ipoteza H_a se formulează după o analiză a aserțiunii care trebuie investigată.

În cazul exemplului considerat, aserțiunea care trebuie analizată este: Popescu a completat formularul aleator.

Populația este o mulțime de 5^{10} elemente (distincte). Un element este un sistem ordonat de 10 răspunsuri $(R'_{i_1}, R'_{i_2}, \dots, R'_{i_{10}})$, $i_1, i_2, \dots, i_{10} \in \{1, 2, 3, 4, 5\}$; R'_{i_1} este unul din cele cinci răspunsuri posibile la prima întrebare, $\dots$, $R'_{i_{10}}$ este unul din cele cinci răspunsuri posibile la cea de-a zecea întrebare.

Pentru o persoană care marchează răspunsurile aleator (fără să le citească), toate răspunsurile sunt egal posibile. Altfel spus fiecare din cele cinci răspunsuri la o întrebare are aceeași șansă ca să fie corect. Din afirmația lui Popescu Nicolae rezultă că el a marcat răspunsurile aleator, deci a admis că probabilitatea (parametrul p) este $\frac{1}{5^{10}}$ pentru fiecare element al populației.

Analiza afirmației lui Popescu Nicolae conduce la următoarea formulare a ipotezei nule:

$$\begin{array}{ll} H_0 : p(X) = \frac{1}{5^{10}} = p \text{ pentru orice} & \text{Popescu Nicolae a completat} \\ \text{element } X \text{ al populației} & \Leftrightarrow \text{formularul aleator.} \end{array}$$

Ipoteza alternativă este:

$$H_a : \text{există două elemente } X_1, X_2 \text{ în populație} \quad \Leftrightarrow \quad \begin{array}{l} \text{Popescu Nicolae nu a completat} \\ \text{pentru care } p(X_1) \neq p(X_2) \quad \text{formularul aleator} \end{array}$$

De la acest punct începând se admite că ipoteza nulă este adevărată. Situația poate fi comparată cu un proces la judecătoria, în care acuzatul este presupus nevinovat până când se dovedește contrariul.

Doar în etapa a 5-a a verificării ipotezelor, vom lua una din cele două decizii posibile: vom decide în concordanță cu ipoteza nulă H_0 și spunem că acceptăm H_0 sau decidem în concordanță cu H_a și spunem că respingem ipoteza H_0 .

În funcție de valoarea de adevăr a ipotezei H_0 și de respingerea sau nerespingerea ei deciziile care se iau sunt prezentate în tabelul următor:

Decizia	Ipoteza H_0 este	
	Adevărată	Falsă
Nu respingem H_0 (acceptăm)	decizie corectă Tip A	eroare Tip II
Respingem H_0	eroare Tip I	decizie corectă Tip B

- O decizie corectă de tip A: apare când H_0 este adevărată și nu respingem H_0
- O decizie corectă de tip B: apare când H_0 este falsă și respingem H_0
- O eroare de tip I: apare când H_0 este adevărată și H_0 este respinsă
- O eroare tip II: apare când H_0 este falsă și H_0 nu este respinsă

Ar fi foarte frumos ca de fiecare dată când luăm decizii să luăm decizii corecte, dar aceasta este statistic imposibil pentru că ne bazăm pe informații furnizate de eșantioane. Cel mai bun lucru la ce putem spera este să controlăm riscul sau probabilitatea de a comite o eroare.

Probabilitatea asignată limitării comiterii unei erori de tip I se notează cu α și cea asignată comiterii unei erori de tip II cu β :

Eroarea	Tipul de eroare	Probabilitate
Respingerea unei ipoteze adevărate	I	α
Acceptarea unei ipoteze false	II	β

Etapa 3

Metodologia de verificare a ipotezelor: aceasta constă din (1) identificarea unui test statistic; (2) specificarea valorii lui α ; (3) determinarea regiunii critice.

(1) Un test statistic este o variabilă aleatoare folosită pentru a respinge sau nu ipoteza H_0 . Testul statistic este o statistică de eșantioane sau alte valori rezultate dintr-un eșantion. Probabilitățile care apar în acest test statistic sunt determinate presupunând că H_0 este adevărată.

În cazul exemplului considerat, variabila aleatoare "X= numărul de răspunsuri corecte" este folosit ca test statistic. Probabilitățile pentru fiecare valoare x ale variabilei X în ipoteza că H_0 este adevărată sunt date în tabelul următor:

X	0	1	2	3	4	5
P(X)	0.1074	0.2684	0.302	0.20133	0.0881	0.0264
X	6	7	8	9	10	
P(X)	0.0055	$7.92 \cdot 10^{-4}$	$7.38 \cdot 10^{-5}$	$4.098 \cdot 10^{-6}$	$1.02 \cdot 10^{-7}$	

Această repartiție arată că probabilitatea să ghicești răspunsul corect la 5 sau mai multe întrebări este 0.0327, iar la 4 sau mai puțin decât 4 întrebări este 0.9673. Putem spune că apariția valorilor 5, 6, 7, 8, 9, 10 nu susține ipoteza H_0 . Dacă cineva spune că a ghicit răspunsul corect la 0, 1, 2, 3, 4 întrebări, spunem că este foarte probabil. Dacă cineva spune că a ghicit răspunsul corect la 5, 6, 7, 8, 9, 10 întrebări spunem că este puțin probabil.

Nivelul de semnificație este probabilitatea α de a face o eroare de tip I, adică de a respinge H_0 adevărat. În mod curent α se dă la început și acesta determină regiunea critică. În cazul exemplului, dacă $\alpha = 0.033$, atunci din $P(x \geq 5) = 0.0327$ rezultă regiunea critică $x = 5, 6, 7, 8, 9, 10$.

Regiunea critică: este mulțimea de valori (W) pentru care $P(X \in W) \leq \alpha$ și care ne determină să respingem ipoteza H_0 . (nu susțin ipoteza H_0)

Valoarea critică: este prima valoare din regiunea critică.

Dacă pentru un eșantion valoarea testului statistic X depășește valoarea critică ipoteza H_0 este respinsă.

După ce **Etapa 3** a fost epuizată, putem trece la **Etapa 4**.

Etapa 4. Determinarea valorii testului statistic

După ce am parcurs etapele 1,2,3 observăm sau calculăm valoarea x a testului statistic.

În cazul exemplului $x = 7$ (numărul de răspunsuri corecte) este valoarea testului statistic și este dat. Uzual valoarea testului statistic se calculează pe baza informațiilor oferite de eșantion.

Etapa 5. Luarea unei decizii și interpretarea ei

Decizia se ia comparând valoarea testului statistic determinată la **Etapa 4** cu regiunea critică găsită la **Etapa 3**.

Regula de decizie: Dacă valoarea testului statistic este în regiunea critică respingem ipoteza H_0 , dacă nu, atunci acceptăm ipoteza H_0 .

Ansamblul de valori ale testului statistic care nu sunt în regiunea critică formează regiunea de acceptabilitate. Testul este terminat prin luarea și justificarea deciziei luate.

În cazul exemplului: $x = 7$ este în regiunea critică și respingem ipoteza H_0 .

Remarca 14.1. Cu aceasta nu am demonstrat că Popescu Nicolae nu a ghicit cele 7 răspunsuri. Am arătat doar că dacă el le-a ghicit este foarte norocos pentru că acesta este un eveniment rar și are probabilitatea cel mult 0.033.

15 Verificarea ipotezelor statistice: variantă clasică

În secțiunea precedentă am prezentat generalități privind verificarea ipotezelor statistice. În această secțiune trecem la prezentarea verificării ipotezelor statistice în cazul aserțiunilor referitoare la media μ a unei populații. Pentru a simplifica această prezentare la început presupunem că deviația standard σ a populației este cunoscută.

Următoarele trei exemple se referă la diferite formulări ale ipotezei H_0 și a ipotezei H_a .

Exemplul 15.1. Un ecologist susține că orașul Timișoara are o problemă privind poluarea aerului. Concret, el susține ca nivelul mediu al monoxidului de carbon în aer în centrul orașului depășește valoarea $4,9/10^6$ = valoarea medie normală.

Pentru a formula în acest caz, ipotezele H_0 și H_a , trebuie să identificăm: populația, parametrul populației în cauză și valoarea cu care aceasta urmează să fie comparată. Populația în acest caz poate fi mulțimea locurilor din centrul orașului Timișoara. Variabila X este concentrația monoxidului de carbon ale cărei valori x variază în funcție de loc, iar parametrul populației este valoarea medie μ a acestei variabile. Valoarea specifică cu care această medie trebuie comparată este $4,9/10^6$ egală cu valoarea (medie) normală. Ecologistul face o aserțiune privind valoarea lui μ . Această valoare poate fi: $\mu < 4,9/10^6$ sau $\mu = 4,9/10^6$ sau $\mu > 4,9/10^6$. Cele trei situații pot fi cuprinse în două afirmații dintre care una exprimă ceea ce ecologistul susține, iar cealaltă exprimă contrariul.

Inegalitatea $\mu > 4,9/10^6$ este afirmația: "valoarea medie este mai mare ca $4,9/10^6$ ".

Inegalitatea $\mu \leq 4,9/10^6$ este echivalentă cu " $\mu < 4,9/10^6$ sau $\mu = 4,9/10^6$ " și este afirmația contrară: "valoarea medie nu este mai mare ca $4,9/10^6$ ".

Ecologistul susține că $\mu > 4,9/10^6$. Pentru a formula ipoteza H_0 și ipoteza H_a reamintim că:

- 1) În general, ipoteza H_0 susține că media μ (parametrul în chestiune) are o valoare specifică anume.
- 2) Inferența privind media μ a populației se bazează pe media unui eșantion și mediile eșantioanelor au o distribuție aproximativ normală. (conform teoremei limită centrală).
- 3) O distribuție normală este complet determinată dacă valoarea medie și deviația standard a distribuției sunt cunoscute.

Cele de mai sus sugerează că afirmația $\mu = 4,9/10^6$ ar trebui să fie ipoteza nulă și afirmația $\mu > 4,9/10^6$ ar trebui să fie ipoteza alternativă:

$$\begin{aligned}H_0 : & \mu = 4,9/10^6 \\H_a : & \mu > 4,9/10^6\end{aligned}$$

Reamintim că după ce ipoteza nulă H_0 este formulată, în testul statistic identificat se presupune că H_0 este adevărată. Aceasta înseamnă că $\mu = 4,9/10^6$ este egală cu media

distribuției mediilor eșantioanelor $\mu_{\bar{x}}$ și este o rațiune în plus pentru care ipoteza H_0 trebuie scrisă doar cu semnul egal

$$H_0 : \mu = 4,9/10^6.$$

Dacă admitem că afirmația " $\mu = 4,9/10^6$ sau $\mu < 4,9/10^6$ " este ipoteza nulă H_0 , atunci:

$$\begin{aligned} H_0 : \mu &\leq 4,9/10^6 \\ H_a : \mu &> 4,9/10^6. \end{aligned}$$

Remarca 15.1. Semnul egal trebuie să fie inclus totdeauna în ipoteza nulă. În acest exemplu aserțiunea ecologistului este exprimată de fapt în H_a și aceasta este analizat.

Exemplul 15.2. Vom considera acum o a doua aserțiune; de exemplu al Camerei de Comerț, care susține că nivelul mediu al monoxidului de carbon în centrul orașului Timișoara este mai mic decât $4,9/10^6$ (valoare normală). Aceasta este o reclamă bună pentru turism.

Și în acest caz parametrul este media μ a repartiției monoxidului de carbon. Valoarea specifică este $4,9/10^6$ care este valoare normală.

$$\begin{aligned} "\mu < 4,9/10^6" &\Leftrightarrow \text{"valoarea medie este mai mică decât valoarea medie normală"} \\ "\mu \geq 4,9/10^6" &\Leftrightarrow \text{"valoarea medie este mai mare sau egală decât valoarea medie normală"} \end{aligned}$$

H_0, H_a pot fi formulate astfel:

$$\begin{aligned} H_0 : \mu &\geq 4,9/10^6 \\ H_a : \mu &< 4,9/10^6 \end{aligned}$$

Și de data aceasta aserțiunea Camerei de Comerț este exprimată în H_a și aceasta trebuie analizată.

Exemplul 15.3. O a treia aserțiune (mai neutră) susține doar că nivelul mediu μ al monoxidului de carbon în aerul din centrul orașului Timișoara este diferit de $4,9/10^6$ (valoarea normală diferită de μ).

În acest caz:

$$H_0 : \mu = 4,9/10^6 \quad \text{și} \quad H_a : \mu \neq 4,9/10^6$$

Cele trei exemple arată că aserțiunea care trebuie analizată determină într-un anumit sens formularea ipotezelor H_0, H_a . Mai exact: în aceste cazuri aserțiunea susține că valoarea parametrului μ este diferită de cea normală, iar ipoteza nulă susține că este aceeași (nu diferă).

În cazul acestor exemple, cei care își formulează aserțiunea se așteaptă la respingerea ipotezei nule H_0 și la acceptarea ipotezei alternative H_a care este o afirmație conformă cu aserțiunea lor.

Situațiile de la procesele juridice prezintă o oarecare asemănare cu cele relatate. Dacă procurorul nu crede în vinovăția inculpatului nu intenționează proces (ipoteza H_0 prezumția de nevinovăție este presupusă adevărată). Procesul se declanșează doar dacă procurorul are suficiente probe pentru a face proces.

Și în statistică dacă "experimantatorul" crede în ipoteza H_0 nu face test pentru investigarea lui H_0 . El testează ipoteza nulă doar dacă dorește să arate că H_a este corectă.

Exemplul care urmează ilustrează toate cele cinci etape de verificare a ipotezelor statistice în cazul unei aserțiuni care se referă la media unei populații.

Exemplul 15.4. Un profesor a înregistrat pe mai mulți ani rezultatul elevilor și media μ a acestor rezultate este 72 și abaterea standard este $\sigma = 12$. Clasa de 36 de elevi pe care-i învață la momentul actual are o medie $\bar{x} = 75,2$ (mai ridicată decât media $\mu = 72$) și profesorul afirmă că această clasă este superioară celor de până acum. Întrebarea este dacă media clasei $\bar{x} = 75,2$ este un argument suficient pentru a susține afirmația profesorului la nivelul de semnificație $\alpha = 0,05$.

Menționăm că pentru ca această clasă să fie superioară trebuie să aibe o medie mai mare decât toate clasele dinainte. Dacă media ei este egală sau mai mică decât media unei clase anterioare, atunci ea nu este superioară.

Dacă se consideră eșantioane aleatoare de mărime $n = 36$ dintr-o populație cu media $\mu = 72$, multe eșantioane vor avea media $\bar{x}$ aproape de 72, de exemplu 71; 71,8; 72; 72,5; 73. Doar medii $\bar{x}$ care sunt considerabil mai mari decât 72 vor susține afirmația profesorului. De aceea:

Etapa 1. $H_0 : \mu_{\bar{x}} = \mu = 72 \Leftrightarrow$ clasa nu este superioară

Etapa 2. $H_a : \mu_{\bar{x}} = \mu > 72 \Leftrightarrow$ clasa este superioară

Etapa 3.

- Atunci când în ipoteza nulă H_0 media populației și deviația standard sunt cunoscute scorul standard z este folosit ca și test statistic.
- Nivelul de semnificație $\alpha = 0,05$ este dat;
- Reamintim că în baza teoremei limită centrală distribuția mediilor eșantioanelor este aproape normală. Prin urmare, distribuția normală va fi folosită pentru determinarea regiunii critice. Regiunea critică este egală cu mulțimea valorilor scorului standard z care determină respingerea ipotezei H_0 și este situată la extremitatea dreaptă a distribuției normale. Regiunea critică este la dreapta deoarece valori mari ale mediei eșantionului susțin ipoteza H_0 în timp ce valori apropiate ori sub 72 susțin ipoteza nulă.




Figura 1:

Valoarea critică ce desparte zona valorilor "nu este superior" de zona valorilor "este superior" este determinată de probabilitatea α de a comite o eroare de tip I. $\alpha = 0,05$ a fost dată. Astfel regiunea critică hașurată pe Figura 2. are aria 0,05 și valoarea critică

1,65 este soluția ecuației: $\frac{1}{\sqrt{2 \cdot \pi}} \int_z^{\infty} e^{-\frac{t^2}{2}} dt = 0,05$.




Figura 2:

Etapa 4. Valoarea testului statistic este dat de:

$$z^* = \frac{\bar{x} - \mu}{\frac{\sigma}{\sqrt{n}}} = \frac{75,2 - 72}{12/6} = 1,6$$

Etapa 5. Comparăm valoarea găsită 1,6 cu valoarea critică 1,65 și găsim $1,6 < 1,65$. Decizia este că nu putem respinge ipoteza H_0 . Testul se încheie cu formularea concluziei.

Concluzie: Probele nu sunt suficiente pentru a susține că actuala clasă este superioară claselor anterioare.

Pare această concluzie realistă în condițiile în care în mod evident, 75,2 este mai mare ca 72. Nu trebuie să uităm $\bar{x} = 75,2$ este media unui eșantion de 36 de indivizi extras dintr-o populație cu media $\mu = 72$ și deviația standard $\sigma = 12$ și analiza arată că probabilitatea ca media eșantionului să fie mai mare decât mediile tuturor eșantioanelor este mai mare decât riscul α cu care noi acceptăm o eroare de tip I.

Exemplul 15.5. La un colegiu s-a stabilit că greutatea medie a studentelor este $\mu = 54,4$ kg, iar abaterea standard $\sigma = 5,4$ kg. Profesorul de sport nu crede această afirmație. Pentru a face un test selecționează un eșantion aleator de 100 de studenți și găsește că media $\bar{x} = 53,75$ kg. Este aceasta suficient pentru a respinge afirmația la nivelul de semnificație $\alpha = 0,05$?

Etapa 1. $H_0 : \mu = 54,4$ kg

Etapa 2. $H_a : \mu \neq 54,4$ kg

Etapa 3.

- deoarece folosim o distribuție de medii de eșantioane testul statistic va fi scorul standard.

- nivelul $\alpha = 0,05$ este dat;

- media eșantionului este o estimare a mediei populației. Ipoteza alternativă "nu este egal" este susținută de medii de eșantioane considerabil mai mari sau considerabil mai mici ca 54,4. ipoteza nulă este susținută de medii de eșantioane în jurul valorii 54,4. Regiunea critică este formată din două părți egale situate la cele două extremități ale distribuției normale. Aria corespunzătoare fiecărei porțiuni este $\frac{\alpha}{2}$ și probabilitatea fiecărei părți a regiunii critice este 0,025. Rezultă

$$z\left(\frac{\alpha}{2}\right) = 1,96 \left(z\left(\frac{\alpha}{2}\right) \text{ este soluția ecuației: } \frac{1}{\sqrt{2 \cdot \pi}} \int_z^{\infty} e^{-\frac{t^2}{2}} dt = \frac{\alpha}{2} \right).$$




Figura 3:

Etapa 4.

Se determină valoarea testului statistic:

$$z^* = \frac{\bar{x} - \mu}{\frac{\sigma}{\sqrt{n}}} = -1,204$$

a cărei locație este dată pe figura următoare:




Figura 4:

Reamintim: Dacă valoarea testului statistic este în regiunea critică respingem ipoteza H_0 dacă nu, nu putem respinge ipoteza H_0 .

Etapa 5. Valoarea testului statistic nu este în regiunea critică.

Decizia: Nu respingem ipoteza H_0 .

Justificarea deciziei: Valoarea testului nu este în dezacord cu H_0 la nivel de risc $\alpha = 0,05$. Aceasta nu înseamnă că H_0 este adevărată.

Concluzie: Media $\bar{x}$ găsită de profesor nu contravine ipotezei că media μ este 54,4 kg, când dispersia σ este 5,4 kg.

O decizie de respingere a lui H_0 înseamnă că valoarea testului implică că H_0 este falsă și indică H_a .

Rezumat privind verificarea ipotezelor statistice asupra mediei în variantă clasică:

1. Ipoteza H_0 specifică o valoare particulară a mediei populației.
2. Ipoteza H_a are trei forme. Fiecare dintre acestea determină o locație specifică a regiunii critice așa cum apare în tabelul de mai jos:

Semne în ipoteza alternativă	<	$\neq$	>
Regiunea critică	O regiune la stânga	Două regiuni de fiecare parte câte una	O regiune la dreapta
	test unilateral stânga	test bilateral	test unilateral dreapta

3. Pentru multe cazuri semnul din ipoteza H_a indică direcția în care regiunea critică se găsește

Valoarea lui α se numește nivel de semnificație și reprezintă **riscul (probabilitatea) respingerii lui H_0 atunci când aceasta este adevărată. Nu putem determina**

dacă ipoteza H_0 este adevărată sau falsă. Putem doar decide că o respingem sau că o acceptăm.

Probabilitatea cu care respingem ipoteza adevărată este α , dar nu știm probabilitatea cu care facem o decizie eronată. O eroare de tip I și o eroare în decizie sunt lucruri diferite.