

4 Determinarea frecvenței și gruparea datelor

După colectarea unui set de date urmează prelucrarea primară a datelor. Determinarea frecvenței și gruparea datelor este un procedeu de prelucrare primară a datelor și este utilizat atunci când numărul datelor este mare.

Pentru a prezenta conceptul de frecvență să considerăm următorul set de date:

3 2 2 3 2
4 4 1 2 2
4 3 2 0 2
2 1 3 3 1

Valoarea 0 apare în acest set o singură dată prin urmare frecvența pentru 0 este unu.

Valoarea 1 apare în acest set de trei ori prin urmare frecvența pentru 1 este trei.

Valoarea 2 apare în acest set de opt ori prin urmare frecvența pentru 2 este opt.

Valoarea 3 apare în acest set cinci ori prin urmare frecvența pentru 3 este cinci.

Valoarea 4 apare în acest set de două ori prin urmare frecvența pentru 4 este doi.

Frecvența datelor 0,1,2,3,4 care apar în setul de date este redată în tabelul următor:

x	f
0	1
1	3
2	8
3	5
4	3

Definiția 4.1. Frecvența f (din coloana a doua) arată de câte ori apare valoarea variabilei x în setul de date.

Atunci când într-un set de date multe sunt distincte (în loc de câteva ca în cazul precedent) se grupează datele în clase și apoi se construiesc frecvențe pentru clase.

Pentru a ilustra acest procedeu considerăm următorul set de date:

82 74 88 66 58
62 68 72 92 86
74 78 84 96 76
76 52 76 82 78

Vom pune în aceeași clasă toate datele la care prima cifră este aceeași și obținem următoarele cinci clase:

50 – 59; 60 – 69; 70 – 79; 80 – 89; 90 – 99

(50 – 59 este clasa formată cu toate datele la care prima cifră este 5, ș.a.m.d.).

Aceste clase nu se intersectează (nu există date care să aparțină la două clase) și oricare din date aparține unei clase.

Limitele inferioare ale claselor sunt 50, 60, 70, 80, 90, iar limitele superioare sunt 59, 69, 79, 89, 99.

Datele care aparțin unei clase sunt mai mari decât limita inferioară a clasei și mai mici decât limita superioară a clasei.

Definiția 4.2. *Lățimea unei clase definită ca diferența dintre limita inferioară a clasei următoare și limita inferioară a clasei (este egală cu 10 și este aceeași pentru toate clasele în exemplul de mai sus) lățimea clasei nu este egală cu diferența dintre limita superioară și limita inferioară a clasei.*

Definiția 4.3. *Frontierele unei clase definite ca media aritmetică dintre limita superioară a clasei și limita inferioară a clasei următoare sunt:*

$$49,5; 59,5; 69,5; 79,5; 89,5; 99,5.$$

Definiția 4.4. *Marca unei clase definită ca media aritmetică dintre limita superioară și limita inferioară a clasei, în acest caz este:*

$$54.5 = \frac{50 + 59}{2} \quad \text{în cazul clasei} \quad 50 - 59$$

$$64.5 = \frac{60 + 69}{2} \quad \text{în cazul clasei} \quad 60 - 69$$

$$74.5 = \frac{70 + 79}{2} \quad \text{în cazul clasei} \quad 70 - 79$$

$$84.5 = \frac{80 + 89}{2} \quad \text{în cazul clasei} \quad 80 - 89$$

$$94.5 = \frac{90 + 99}{2} \quad \text{în cazul clasei} \quad 90 - 99$$

Frecvența în acest caz este numărul de date dintr-o clasă. Frecvența datelor pe clase este:

$$\text{în cazul clasei} \quad 50 - 59 \quad 2 \text{ date}$$

$$\text{în cazul clasei} \quad 60 - 69 \quad 3 \text{ date}$$

$$\text{în cazul clasei} \quad 70 - 79 \quad 8 \text{ date}$$

$$\text{în cazul clasei} \quad 80 - 89 \quad 5 \text{ date}$$

$$\text{în cazul clasei} \quad 90 - 99 \quad 2 \text{ date}$$

În general, în cazul grupării datelor pe clase și a determinării frecvenței trebuie respectate următoarele reguli:

- 1) Clasele nu trebuie să se intersecteze și fiecare dată din setul de date trebuie să aparțină la o clasă;
- 2) Fiecare clasă trebuie să aibe aceeași lățime.

Procedeul concret de grupare este următorul:

- i) Se identifică cea mai mare dată H și cea mai mică dată L și se determină plaja:
 $R = H - L$.
- ii) Se alege numărul de clase m și lățimea clasei c (dacă se poate număr impar) astfel ca produsul $m \cdot c$ să fie puțin mai mare ca plaja R .
- iii) Se alege un punct de plecare I care este puțin mai mic decât cea mai mică dată L .
Adăugăm la I multiplii lui c (c este lățimea clasei) și obținem numerele:

$$I, I + c, I + 2c, I + 3c, \dots, I + (m - 1)c$$

Aceste numere sunt limitele inferioare ale claselor.

- iv) Limitele superioare se stabilesc astfel încât să fie respectate condițiile 1) și 2).
- v) Se determină frecvența fiecărei clase numărând elementele din fiecare clasă.

5 Prezentarea datelor

Prezentarea unui set de date poate fi făcută sub diferite forme și face parte din prelucrarea primară a datelor.

Prezentarea datelor sub formă de serii

Definiția 5.1. Seria de distribuție este un ansamblu de două șiruri finite dintre care primul este șirul elementelor distincte din setul de date statistice sau șirul claselor obținute prin gruparea elementelor din setul de date statistice, iar cel de-al doilea este șirul de frecvențe corespunzătoare.

Exemplul 5.1. În cazul setului de date statistice:

3	2	2	3	2
4	4	1	2	2
4	3	2	0	2
2	1	3	3	1

seria de distribuție este:

$$X \begin{pmatrix} 0 & 1 & 2 & 3 & 4 \\ 1 & 3 & 8 & 5 & 3 \end{pmatrix}$$

Exemplul 5.2. În cazul claselor 50 – 59; 60 – 69; 70 – 79; 80 – 89; 90 – 99 obținute prin gruparea datelor din setul de date:

82	74	88	66	58	74	78	84	96	76
62	68	72	92	86	76	52	76	82	78

seria de distribuție este:

$$X \begin{pmatrix} 50 - 59 & 60 - 69 & 70 - 79 & 80 - 89 & 90 - 99 \\ 2 & 3 & 8 & 5 & 2 \end{pmatrix}$$

În general, o serie de distribuție arată în felul următor:

$$X \begin{pmatrix} x_1 & x_2 & x_3 & \cdots & x_n \\ f_1 & f_2 & f_3 & \cdots & f_n \end{pmatrix}$$

și oricare ar fi nivelul de grupare al datelor, x_i având frecvența f_i , se numește termenul seriei de distribuție.

Remarca 5.1. Adesea în prezentarea seriilor de distribuție în locul frecvenței f_i se folosește frecvența relativă:

$$f'_i = \frac{f_i}{\sum_{j=1} f_j}$$

sau sub formă procentuală:

$$f''_i = f'_i \cdot 100$$

Definiția 5.2. Valoarea datei care apare cu cea mai mare frecvență într-o serie de distribuție de date statistice se numește **mod**.

Definiția 5.3. Clasa cu cea mai mare frecvență într-o serie de distribuție de date grupate se numește **clasă modală**.

Definiția 5.4. Serie bimodală este o serie de distribuție de date grupate în care apar două clase modale, separate de clase cu frecvență mai joasă.

Definiția 5.5. Frecvența cumulată a unei clase este suma frecvențelor tuturor claselor cu valori mai mici (marca mai mică).

Definiția 5.6. Seria dinamică (temporală, cronologică) este un șir dublu dintre care primul este șirul de valori ale variabilei de răspuns, iar cel de-al doilea șir este șirul de momente de timp la care variabila are aceste valori. În general, o serie dinamică (temporală) se notează astfel:

$$X \begin{pmatrix} x_1 & x_2 & x_3 & \cdots & x_n \\ t_1 & t_2 & t_3 & \cdots & t_n \end{pmatrix}$$

Prezentarea datelor sub formă de tabele statistice

Tabelele statistice sunt foarte variate și se folosesc pentru ordonarea datelor statistice dintr-un set de date în vederea aplicării metodelor de calcul și de interpretare statistică.

În funcție de numărul de caracteristici prezentate în tabel există tabele simple, tabele cu dublă intrare, tabele pe grupe, etc.

Prezentarea datelor sub formă grafică

Există mai multe metode de prezentare grafică a unui set de date statistice. Metoda de prezentare grafică este determinată de tipul de date și de ideea de prezentare. De la început trebuie să fie clar că există mai multe căi de a dispune grafic anumite date statistice. Judecata analistului și circumstanțele din jurul problemei joacă un rol major în alegerea modului de dispunere grafică a datelor statistice.

Definiția 5.7. Graficele de reprezentare a seriilor statistice fără grupare se numesc **diagrame**.

Definiția 5.8. Diagrama cerc a seriei de distribuție (fără grupare)

$$X \begin{pmatrix} x_1 & x_2 & x_3 & \cdots & x_n \\ f_1 & f_2 & f_3 & \cdots & f_n \end{pmatrix}$$

este un cerc împărțit în n sectoare de cerc $S_1, S_2, \dots, S_n$ astfel încât aria sectorului S_i este egală cu


$$f_i'' = \frac{f_i}{\sum_{j=1}^n f_j} \cdot 100$$

procente din aria cercului.

Exemplul 5.3. În cazul seriei de distribuție din exemplul 5.1

$$X \begin{pmatrix} 0 & 1 & 2 & 3 & 4 \\ 1 & 3 & 8 & 5 & 3 \end{pmatrix}$$

cercul se împarte în cinci sectoare având ariile egale cu 5%, 15%, 40%, 25%, 15% din aria cercului



Definiția 5.9. Diagrama coloană a seriei de distribuție (fără grupare):


$$X \begin{pmatrix} x_1 & x_2 & x_3 & \cdots & x_n \\ f_1 & f_2 & f_3 & \cdots & f_n \end{pmatrix}$$

este un set de n dreptunghiuri. Bazele acestor dreptunghiuri sunt egale și sunt așezate pe axa Ox, iar înălțimile lor sunt $f_1, f_2, \dots, f_n$

Exemplul 5.4. În cazul seriei de distribuție din exemplul 5.1:

$$X \begin{pmatrix} 0 & 1 & 2 & 3 & 4 \\ 1 & 3 & 8 & 5 & 3 \end{pmatrix}$$

diagrama coloană este:



Definiția 5.10. **Diagrama linie (ramură-frunză)** a seriei de distribuție (fără grupare)


$$X \begin{pmatrix} x_1 & x_2 & x_3 & \cdots & x_n \\ f_1 & f_2 & f_3 & \cdots & f_n \end{pmatrix}$$

este un set de n dreptunghiuri. Bazele acestor dreptunghiuri sunt egale și sunt așezate pe axa Oy, iar lungimile lor sunt $f_1, f_2, \dots, f_n$.

Exemplul 5.5. În cazul seriei de distribuție din exemplul 5.1:

$$X \begin{pmatrix} 0 & 1 & 2 & 3 & 4 \\ 1 & 3 & 8 & 5 & 3 \end{pmatrix}$$

diagrama linie este:



Definiția 5.11. **Histograma** seriei de distribuție cu grupare


$$X \begin{pmatrix} x_1 & x_2 & x_3 & \cdots & x_n \\ f_1 & f_2 & f_3 & \cdots & f_n \end{pmatrix}$$

este un set de n dreptunghiuri care reprezintă clasele. Bazele acestor dreptunghiuri sunt egale (clasele au aceeași lățime) și sunt așezate pe axa Ox, iar înălțimile lor sunt $f_1, f_2, \dots, f_n$.

Exemplul 5.6. În cazul seriei de distribuție din exemplul 5.2:

$$X \begin{pmatrix} 50 - 59 & 60 - 69 & 70 - 79 & 80 - 89 & 90 - 99 \\ 2 & 3 & 8 & 5 & 2 \end{pmatrix}$$

histograma este:



Remarca 5.2. În cazul histogramei o coloană reprezintă un număr de date diferite spre deosebire de diagrama coloană.

Remarca 5.3. O histogramă are următoarele componente:

- i) Un titlu care identifică populația la care se referă;
- ii) O scară orizontală pe care se identifică variabila X , valorile limitelor claselor, frontierele claselor, mărcile claselor.
- iii) O scară verticală pe care se identifică frecvențele pentru fiecare clasă.

Definiția 5.12. O **histogramă de frecvențe relative** este o histogramă obținută dintr-o histogramă înlocuind frecvențele cu frecvențe relative.

Frecvența relativă (este o măsură proporțională cu frecvența în cauză) **se obține prin împărțirea frecvenței clasei la numărul total de elemente din setul de date.**

Definiția 5.13. **Ogiva** unei serii de distribuție de clase cu frecvențe relative cumulate este un set de dreptunghiuri. Bazele dreptunghiurilor sunt egale și așezate pe axa Ox , iar înălțimile lor sunt frecvențele relative cumulate.

Ogiva are următoarele componente:

1. Un titlu care identifică populația.
2. O scară orizontală pe care sunt marcate frontierele superioare ale claselor.
3. O scară verticală pe care sunt marcate frecvențele relative cumulate pentru fiecare clasă.

6 Parametrii și statistici ai tendinței centrale

O categorie de caracteristici numerice asociată unui set de date statistice sunt: **parametrii tendinței centrale** în cazul populațiilor și **statistici ale tendinței centrale** în cazul eșantioanelor. Întrucât aceștia au definiții analoage vom prezenta doar statistici ale tendinței centrale.

Definiția 6.1. Statistici ale tendinței centrale sunt valori numerice asociate unui set de date statistice care localizează într-un anumit sens mijlocul mulțimii de date statistice.

Definiția 6.2. Media aritmetică a setului de date statistice $\{x_1, x_2, \dots, x_n\}$ este prin definiție suma acestor date împărțită la numărul datelor

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n}$$

Remarca 6.1. Atunci când datele sunt prezentate sub forma unei serii de distribuție (fără grupare în clase), media aritmetică se găsește cu formula:

$$\bar{x} = \frac{\sum_{j=1}^m x_j \cdot f_j}{\sum_{j=1}^m f_j}$$

Remarca 6.2. În cazul unei serii de distribuție (cu grupare în clase) formula de calcul a mediei este:

$$\bar{x} = \frac{\sum x \cdot f_x}{\sum f_x}$$

în care x reprezintă marca clasei și f_x frecvența corespunzătoare, iar suma se extinde pe ansamblul claselor.

Definiția 6.3. Media pătratică a setului de date statistice $\{x_1, x_2, \dots, x_n\}$ este prin definiție numărul:

$$\bar{x}_p = \sqrt{\frac{\sum_{i=1}^n x_i^2}{n}}$$

Remarca 6.3. Dacă datele sunt prezentate sub forma unei serii de distribuție (fără grupare în clase), media pătratică se găsește cu formula:

$$\bar{x}_p = \sqrt{\frac{\sum_{j=1}^m x_j^2 \cdot f_j}{\sum_{j=1}^m f_j}}$$

Remarca 6.4. În cazul unei serii de distribuție cu grupare în clase media pătratică este prin definiție:

$$\bar{x}_p = \sqrt{\frac{\sum x^2 \cdot f_x}{\sum f_x}}$$

în care x reprezintă marca clasei și f_x frecvența corespunzătoare, iar suma se extinde pe ansamblul claselor.

Definiția 6.4. Media armonică a setului de date statistice $\{x_1, x_2, \dots, x_n\}$ este prin definiție numărul:

$$\bar{x}_h = \frac{n}{\sum_{i=1}^n \frac{1}{x_i}}$$

Remarca 6.5. Dacă datele sunt prezentate sub forma unei serii de distribuție (fără grupare în clase), media armonică se găsește cu formula:

$$\bar{x}_h = \frac{\sum_{j=1}^m f_j}{\sum_{j=1}^m \frac{1}{x_j} \cdot f_j}$$

Remarca 6.6. În cazul unei serii de distribuție cu grupare în clase media armonică este prin definiție:

$$\bar{x}_h = \frac{\sum_{i=1}^n f_x}{\sum_{i=1}^n \frac{1}{x} \cdot f_x}$$

în care x reprezintă marca clasei și f_x frecvența corespunzătoare, iar suma se extinde pe ansamblul claselor.

Definiția 6.5. Media geometrică a setului de date statistice $\{x_1, x_2, \dots, x_n\}$ este prin definiție numărul:

$$\bar{x}_g = \sqrt[n]{\prod_{i=1}^n x_i}$$

Remarca 6.7. Dacă datele sunt prezentate sub forma unei serii de distribuție (fără grupare în clase), media geometrică se găsește cu formula:

$$\bar{x}_g = \sqrt[n]{\prod_{j=1}^m x_j^{f_j}}$$

Remarca 6.8. În cazul unei serii de distribuție cu grupare în clase media geometrică este prin definiție: în care x reprezintă marca clasei și f_x frecvența corespunzătoare, iar suma se extinde pe ansamblul claselor.

$$\bar{x}_g = \frac{\sum f_x}{\sqrt{\prod x^{f_x}}}$$

Definiția 6.6. *Mediana m_e a unui set de date statistice distincte ordonate după mărime $x_1 < x_2 < \dots < x_n$ este numărul care împarte setul de date în două grupe egale ca număr:*

- dacă $n = 2 \cdot k + 1$, atunci m_e este valoarea de rangul $k + 1$: $m_e = x_{k+1}$;
- dacă $n = 2 \cdot k$, atunci orice număr între valorile x_k și x_{k+1} satisface condiția din definiția lui m_e . În acest caz se convine ca m_e să fie media aritmetică a valorilor x_k și x_{k+1} : $m_e = \frac{x_k + x_{k+1}}{2}$.

Exemplul 6.1. În cazul setului de date statistice:

4 7 12 26 32 38 59

mediana este $m_e = 26$.

În cazul setului de date statistice:

4 7 12 26 32 38

mediana este $m_e = \frac{12 + 26}{2} = 19$.

Remarca 6.9. *Mediana m_e în acest caz are proprietatea că suma frecvențelor valorilor mai mari decât m_e este egală cu suma frecvențelor valorilor mai mici decât m_e .*

Remarca 6.10. Dacă datele pot fi egale, atunci proprietatea din Remarca 6.9 a medianei poate să nu fie adevărată. În cazul setului de date statistice:

1 1 1 2 3 3 4

Seria de distribuție corespunzătoare este:

1 2 3 4
3 1 2 1

Conform definiției lui m_e în acest caz $m_e = 2,5$. Această valoare a lui m_e nu răspunde cerinței că m_e este o valoare cu proprietatea că valorile mai mari sau mai mici decât ea apar cu frecvențe cumulate egale; frecvența celor mai mici este 4, iar frecvența celor mai mari este 3.

Remarca 6.11. Când datele sunt prezentate sub forma unei serii de distribuție cu sau fără grupare m_e se calculează prin procedeul interpolării liniare, bazate pe ipoteza repartiției uniforme a frecvențelor în intervalul median.

Definiția 6.7. Mijlocul plăjei este prin definiție numărul:

$$M_r = \frac{L + H}{2}$$

unde L este cea mai mică valoare, iar H este cea mai mare valoare a variabilei X

7 Parametrii și statistici ai dispersiei

După ce "mijlocul" unui set de date a fost stabilit următoarea întrebare naturală este: care sunt parametrii și statisticile care caracterizează dispersia (împrăștierea) datelor.

Parametrii și statisticile dispersiei sunt: plaja, deviația medie absolută, varianța, deviația standard și coeficientul de variație. Aceste valori numerice descriu mărimea împrăștierii ori a variabilităților datelor. Datele strâns grupate vor avea împrăștiere mică, iar cele care nu sunt grupate (sunt împrăștiate) vor avea o dispersie mai mare.

Definiția 7.1. Plaja P este diferența dintre cea mai mare (H) și cea mai mică (L) valoare a valorilor x_i dintr-un set de date:

$$P = H - L$$

Deviația medie absolută, varianța și deviația standard măsoară dispersia față de media aritmetică.

Definiția 7.2. Deviația față de media aritmetică $\bar{x}$ a valorii x_i a variabilei X este $d_i = x_i - \bar{x}$.

Deviația este zero dacă și numai dacă $x_i = \bar{x}$.

Deviația este pozitivă dacă și numai dacă $x_i > \bar{x}$.

Deviația este negativă dacă și numai dacă $x_i < \bar{x}$.

S-ar putea crede că suma deviațiilor $\sum_{i=1}^n (x_i - \bar{x})$ poate servi ca măsură a dispersiei față de media aritmetică. Dar această sumă este zero întotdeauna:

$$\sum_{i=1}^n (x_i - \bar{x}) = \sum_{i=1}^n x_i - n \cdot \bar{x} = n \cdot \bar{x} - n \cdot \bar{x} = 0$$

Reducerea deviațiilor poate fi eliminată prin folosirea valorii absolute a deviațiilor: $|x_i - \bar{x}|$.

Definiția 7.3. Deviația medie absolută a setului de date statistice distincte $\{x_1, x_2, \dots, x_n\}$ este prin definiție:

$$\bar{d} = \frac{\sum_{i=1}^n |x_i - \bar{x}|}{n}$$

Remarca 7.1. Deviația medie absolută, în cazul în care datele sunt prezentate sub forma unei serii de distribuție fără grupare de date se calculează cu formula:

$$\bar{d} = \frac{\sum_{j=1}^m |x_j - \bar{x}| \cdot f_j}{\sum_{j=1}^m f_j}$$

Remarca 7.2. Deviația medie absolută, în cazul în care datele sunt prezentate sub forma unei serii de distribuție cu grupare de date se calculează cu formula:

$$\bar{d} = \frac{\sum |x - \bar{x}| \cdot f_x}{\sum f_x}$$

în care x reprezintă marca clasei și f_x frecvența corespunzătoare, iar suma se extinde pe ansamblul claselor.

Cu toate că acest parametru al împrăstierii nu se folosește frecvent, el este o măsură a împrăstierii și arată distanța medie la care se află o valoare a variabilei X față de media aritmetică.

Mai există o cale de eliminare a reducerii deviațiilor. Ridicând la pătrat deviațiile individuale acestea devin pozitive (sau zero). Când aceste pătrate sunt adunate rezultatul este pozitiv. Suma pătratelor deviațiilor față de media aritmetică $\sum_{i=1}^n (x_i - \bar{x})^2$ este folosită în definirea varianței.

Definiția 7.4. Varianța s^2 a setului de date statistice distincte $\{x_1, x_2, \dots, x_n\}$ este prin definiție:

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}$$

Remarca 7.3. Dacă setul de date este prezentat sub forma unei serii de distribuție fără grupare de date varianța s^2 se calculează cu formula:

$$s^2 = \frac{\sum_{j=1}^m (x_j - \bar{x})^2 \cdot f_j}{\sum_{j=1}^m f_j}$$

Remarca 7.4. Dacă setul de date este prezentat sub forma unei serii de distribuție cu grupare de date varianța s^2 se calculează cu formula:

$$s^2 = \frac{\sum (x - \bar{x})^2 \cdot f_x}{\sum f_x}$$

în care x reprezintă marca clasei și f_x frecvența corespunzătoare, iar suma se extinde pe ansamblul claselor.

Definiția 7.5. Deviația standard (abaterea standard) s a setului de date statistice distincte $\{x_1, x_2, \dots, x_n\}$ este prin definiție:

$$s = \left[\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n} \right]^{\frac{1}{2}}$$

Remarca 7.5. Dacă setul de date este prezentat sub forma unei serii de distribuție fără grupare de date deviația standard s se calculează cu formula:

$$s = \left[\frac{\sum_{j=1}^m (x_j - \bar{x})^2 \cdot f_j}{\sum_{j=1}^m f_j} \right]^{\frac{1}{2}}$$

Remarca 7.6. Dacă setul de date este prezentat sub forma unei serii de distribuție cu grupare de date deviația standard s se calculează cu formula:

$$s = \left[\frac{\sum (x - \bar{x})^2 \cdot f_x}{\sum f_x} \right]^{\frac{1}{2}}$$

în care x reprezintă marca clasei și f_x frecvența corespunzătoare, iar suma se extinde pe ansamblul claselor.

Remarca 7.7. *Deviația standard a fost definită cu o formulă. Se poate pune întrebarea ce reprezintă ea în realitate? Un răspuns la această întrebare poate fi dat cu inegalitatea lui Cebîșev din care rezultă că pentru orice serie de distribuție fracțiunea de date situată la cel mult k unități de deviație standard față de medie este cel puțin $1 - \frac{1}{k^2}$, unde k este un număr pozitiv oarecare mai mare ca 1. Rezultă în particular că pentru orice serie de distribuție fracțiunea de date situată la cel mult $k = 2$ unități de deviație standard față de medie este de cel puțin 75% din totalul de date. Dacă $k = 3$ atunci este 89% din totalul de date.*

Conform regulii empirice dacă o serie de repartitie este normală atunci fracțiunea de date situate la cel mult o unitate de deviație standard σ față de medie este aproximativ 68%, iar fracțiunea de date situate la cel mult două unități de deviație standard σ față de medie este aproximativ 95%.

Definiția 7.6. Coeficientul de variație V este prin definiție:

$$V = \frac{s}{\bar{x}} \cdot 100$$

Remarca 7.8. Coeficientul de variație este o statistică relativă a dispersiei și se folosește la compararea dispersiei diferitelor variabile (caracteristici).

Remarca 7.9. V poate lua valori între 0 și 100%. Dacă V este aproape de zero ($V < 35\%$), atunci populația studiată statistic este omogenă și media $\bar{x}$ este reprezentativă pentru această populație. Dacă V este aproape de 100% ($V > 75\%$), atunci populația studiată statistic este eterogenă și media $\bar{x}$ nu este reprezentativă. De cele mai multe ori în asemenea cazuri este necesară separarea populației statistice în mai multe grupe omogene, care se studiază separat.

8 Parametrii și statistici factoriali ai varianței

În analiza varianței unui set de date statistice se folosesc următorii parametri factoriali ai varianței:

- varianța de grupă (parțială) s_j^2
- media varianțelor de grupă $\bar{s}^2$
- varianța mediilor de grupă față de media generală δ^2
- varianța totală (generală) s^2 .

Definiția 8.1. Pentru o grupă de m date $x_1, x_2, \dots, x_m$, **varianța de grupă** este definită cu formula:

$$s_j^2 = \frac{\sum_{i=1}^m (x_i - \bar{x}_j)^2 \cdot n_{ij}}{\sum_{i=1}^m n_{ij}}$$

în care j este indicele grupei, $\bar{x}_j$ este media grupei, x_i sunt datele din grupa j având frecvențele n_{ij}

Remarca 8.1. Varianțele de grupă sunt mai mici decât varianța și au valori mai mari sau mai mici în funcție de eterogenitatea grupei.

Definiția 8.2. Prin definiție **media varianțelor de grupă** este:

$$\bar{s}^2 = \frac{\sum_{j=1}^k s_j^2 \cdot n_j}{\sum_{j=1}^k n_j}$$

în care k este numărul de grupe, $n_j = \sum_{i=1}^m n_{ij}$ este numărul de date din grupă.

Definiția 8.3. **Varianța mediilor de grupă față de media generală** este prin definiție:

$$\delta^2 = \frac{\sum_{j=1}^k (\bar{x}_j - \bar{x})^2 \cdot n_j}{\sum_{j=1}^k n_j}$$

9 Parametrii și statistici ale poziției

Parametrii și statistici ai poziției se folosesc pentru a descrie locația unei date în raport cu celelalte date.

Definiția 9.1. **Quantilele** sunt valori numerice care împart setul de date în q grupe egale. Constanta q se numește ordinul quantilei.

Mediana este quantila de ordinul doi.

Quantilele de ordinul patru împart setul de date în patru grupe egale și se numesc **quartile**. Quartilele sunt în număr de trei, notate de obicei cu Q_1, Q_2, Q_3 .

Quartila Q_1 este un număr cu proprietatea că o pătrime din date au valori mai mici decât Q_1 și trei pătrimi din date au valori mai mari decât Q_1 .

Quartila Q_2 este un număr cu proprietatea că jumătate din date au valori mai mici decât Q_2 și jumătate din date au valori mai mari decât Q_2 . Quartila Q_2 este chiar mediana.

Quartila Q_3 este un număr cu proprietatea că trei pătrimi din date au valori mai mici decât Q_3 și o pătrime din date au valori mai mari decât Q_3 .

Alte categorii de quantile folosite sunt:

- decilele care împart setul de date în 10 grupe egale.
- centilele care împart setul de date în 100 grupe egale.
- promilele care împart setul de date în 1000 grupe egale.

Orice set de date are 99 de centile $P_k, k = 1..99$. Centila P_k este o valoare numerică cu proprietatea că $k\%$ din date are valori mai mici decât P_k , iar $(100 - k)\%$ din date au valori mai mari decât P_k .

Remarca 9.1. $Q_1 = P_{25}; Q_3 = P_{75}; m_e = Q_2 = P_{50}$

Remarca 9.2. Procedul de determinare a centilei P_k este următorul:

- 1) datele se ordonează crescător;
- 2) trebuie găsită poziția i a centilei k . Prima oară se determină numărul $\frac{n \cdot k}{100}$, unde n este numărul de date. Dacă $\frac{n \cdot k}{100}$ nu este un număr întreg, atunci i este numărul întreg următor ($\frac{n \cdot k}{100} = 17.2 \rightarrow i = 18$). Dacă $\frac{n \cdot k}{100}$ este un număr întreg, atunci i este $\frac{n \cdot k}{100} + 0.5$ ($\frac{n \cdot k}{100} = 23 \rightarrow i = 23.5$).
- 3) localizarea valorii P_k : se numără de la valoarea L (cea mai mică valoare a datelor) i valori dacă i este întreg. Dacă i nu este întreg atunci este un întreg plus o jumătate. În acest caz valoarea P_k este semisuma datelor de pe locurile $\frac{n \cdot k}{100}$ și $\frac{n \cdot k}{100} + 1$

O statistică adițională a poziției este scorul standard sau z-scor.

Definiția 9.2. Scorul standard sau **z-scorul** este poziția valorii x față de mediana $\bar{x}$ în unități de deviație standard:

$$z = \frac{x - \bar{x}}{s}$$

10 Seria de distribuție a statisticilor de eșantioane

Pentru a face inferență (predicție) asupra parametrilor populației, este necesar să analizăm statisticile de eșantioane. Media $\bar{x}$ în cazul unui eșantion nu este neapărat egală cu media μ a populației. Suntem însă mulțumiți dacă media $\bar{x}$ este apropiată de μ . Dacă se consideră media $\bar{x}'$ în cazul unui al doilea eșantion aceasta poate să fie diferită de $\bar{x}$ și de μ . Ceea ce putem spera este ca aceasta să fie apropiată de valoarea μ și de $\bar{x}$. Valabilitatea acestui tip de comportament interesează pentru orice populație și orice statistică.

Întrebarea care se naște în mod natural este ce înseamnă aproape? Cum se măsoară și se determină această apropiere? Care este seria de distribuție a statisticilor de eșantioane?

Definiția 10.1. Seria de distribuție a statisticilor de eșantioane este seria de distribuție a statisticilor de un anumit tip obținute pentru eșantioane de aceeași mărime. Tipul de statistică poate fi oricare din statisticile prezentate în secțiunile 6 și 7.

Exemplul 10.1. Se consideră o populație de N elemente de la care se pot obține următoarele date statistice distincte: $\{0, 2, 4, 6, 8\}$. În cazul acestei populații formăm eșantioane de mărime 2 de la care putem avea următoarele date statistice:

(0, 0)	(2, 0)	(4, 0)	(6, 0)	(8, 0)
(0, 2)	(2, 2)	(4, 2)	(6, 2)	(8, 2)
(0, 4)	(2, 4)	(4, 4)	(6, 4)	(8, 4)
(0, 6)	(2, 6)	(4, 6)	(6, 6)	(8, 6)
(0, 8)	(2, 8)	(4, 8)	(6, 8)	(8, 8)


Pentru aceste eșantioane mediile $\bar{x}$ sunt:

0	1	2	3	4
1	2	3	4	5
2	3	4	5	6
3	4	5	6	7
4	5	6	7	8

Eșantioanele fiind aleatoare fiecare eșantion, are probabilitatea $1/25$ să fie ales și seria de distribuție a mediilor acestor eșantioane este:

$\bar{x}$	$f'(\bar{x})$
0	0.04
1	0.08
2	0.12
3	0.16
4	0.20
5	0.16
6	0.12
7	0.08
8	0.04

unde $f'(\bar{x})$ este frecvența relativă a mediei $\bar{x}$. Diagrama coloană a mediilor eșantioanelor este:



Pentru același set de 25 de eșantioane putem determina seria de distribuție a plajelor R a acestor eșantioane.


Plajele R ale eșantioanelor sunt date în tabelul următor:

0	2	4	6	8
2	0	2	4	6
4	2	0	2	4
6	4	2	0	2
8	6	4	2	0

Seria de distribuție a plajelor acestor eșantioane este:

R	$f'(R)$
0	0.20
2	0.32
4	0.24
6	0.16
8	0.08

iar diagrama coloană a plajei eșantioanelor este:




Exemplul 10.2. În cazul aruncării zarului de un număr de N ori, setul de date statistice care se referă la numărul de pe față care apare este 1, 2, 3, 4, 5, 6.

Formăm eșantioane care constau din 5 aruncări. Fiecare din aceste eșantioane are media $\bar{x}$. Considerăm 30 de eșantioane de acest fel (înseamnă $30 \times 5 = 150$ aruncări) și într-un tabel reprezentăm rezultatele precum și mediile corespunzătoare:

Încercare	Eșantion	$\bar{x}$	Încercare	Eșantion	$\bar{x}$
1	1 2 3 2 2	2.0	16	5 2 1 3 5	3.2
2	4 5 5 4 5	4.6	17	6 1 3 3 5	3.6
3	3 1 5 2 4	3.0	18	6 5 5 2 6	4.8
4	5 6 6 4 2	4.6	19	1 3 5 5 6	4.0
5	5 4 1 6 4	4.0	20	3 1 5 3 1	2.6
6	3 5 6 1 5	4.0	21	5 1 1 4 3	2.8
7	2 3 6 3 2	3.2	22	4 6 3 1 2	3.2
8	5 3 4 6 2	4.0	23	1 5 3 4 5	3.6
9	1 5 5 3 4	3.6	24	3 4 1 3 3	2.8
10	4 1 5 2 6	3.6	25	1 2 4 1 4	2.4
11	5 1 3 3 2	2.8	26	5 2 1 6 3	3.4
12	1 5 2 3 1	2.4	27	4 2 5 6 3	4.0
13	2 1 1 5 3	2.4	28	4 3 1 3 4	3.0
14	5 1 4 4 6	4.0	29	2 6 5 3 3	3.8
15	5 5 6 3 3	4.4	30	6 3 5 1 1	3.2

Histograma seriei de distribuție a mediilor celor 30 de eșantioane este reprezentată în figura următoare:



Această lege de repartiție pare să aibe caracteristicile unei legi de repartiție normală; este maxim și este simetric față de media proprie 3.5.